

AI Boom Premium

Czy spółki silnie powiązane z infrastrukturą AI osiągnęły wyższe średnie zwroty i lepszy profil ryzyko–zwrot po rozpoczęciu boomu generatywnej AI?

Projekt zaliczeniowy IAD — Metody Badań w Finansach, ćwiczenia 3

Roksana Kulawiec (454474)

Sylwia Malinowska (487648)

Mateusz Konopka (487528)

Antoni Grabowski (452622)

20 maja 2026

Repozytorium kodu i danych: github.com/Smalou/metody_badania_w_finansach
Wszystkie skrypty Pythona, cache danych (parquet/csv), wygenerowane wykresy i źródło niniejszego raportu LaTeX są publicznie dostępne w powyższym repozytorium.

Wprowadzenie i hipoteza projektowa

Premiera ChatGPT (30 listopada 2022) jest powszechnie uznawana za moment, w którym generatywna sztuczna inteligencja przestała być tematem niszowym, a stała się masowym trendem inwestycyjnym. W kolejnych kwartałach hyperscalerzy chmurowi ogłaszali wielomiliardowe inwestycje kapitałowe w GPU i klastry treningowe, a NVIDIA stała się jedną z najwyżej wycenianych spółek świata. Niniejszy projekt weryfikuje empirycznie, czy ten narracyjny „AI Boom” przełożył się na mierzalne różnice w średnich zwrotach i profilu ryzyko–zwrot między spółkami o różnym stopniu ekspozycji na sztuczną inteligencję.

Główna teza. *Spółki silnie powiązane z infrastrukturą AI (producenci półprzewodników i sprzętu) osiągnęły po 30.11.2022 istotnie wyższe średnie zwroty względem benchmarku rynkowego (SPY) oraz lepszy profil ryzyko–zwrot niż grupy kontrolne (Defensive, Broad Tech, AI Platforms).*

Trzy zadania spójne tematycznie.


- **Zadanie 1** — porównanie średnich miesięcznych *abnormal returns* (AR względem SPY) portfela AI infrastructure i portfela Defensive control po rozpoczęciu boomu (próby niezależne).
- **Zadanie 2** — porównanie średnich metryk efektywności ryzyko–zwrot (*Sharpe Ratio* jako zmienna główna, *CAPM alpha* jako uzupełnienie) między czterema grupami spółek.
- **Zadanie 3** — A/B testing na próbach zależnych: średnie dzienne AR tej samej spółki w oknie przed (wariant A) i po (wariant B) 30.11.2022, z analizą wrażliwości na długość okna i *placebo test*.

Dane. Źródło: Yahoo Finance (`yfinance` 1.3.0). 41 spółek notowanych na NYSE/NASDAQ podzielonych na cztery grupy (definicje w `data_cache/metadata_tickers.csv`) plus benchmark SPY i stopa wolna od ryzyka $\sim$ IRX (13-tygodniowy T-bill). Okres: 04.01.2021–14.05.2026 (1347 dni sesyjnych). Ceny skorygowane (`auto_adjust=True`), brak braków danych.

Grupy spółek ($15+10+10+10 = 41$).

- **AI infrastructure / półprzewodniki (11):** NVDA, AMD, AVGO, TSM, ASML, AMAT, LRCX, KLAC, MU, MRVL, SMCI.
- **AI platforms / cloud / software (10):** MSFT, GOOGL, AMZN, META, ORCL, CRM, NOW, ADBE, IBM, SNOW.
- **Broad technology control (10):** AAPL, CSCO, INTC, TXN, QCOM, INTU, ACN, PANW, CDNS, ADSK.
- **Defensive control (10):** KO, PEP, PG, WMT, JNJ, MRK, MCD, COST, CL, GIS.

Kontekst graficzny — skumulowane abnormal returns per grupa. Poniższy wykres przedstawia skumulowany dzienny abnormal return portfela równoważonego (EW) każdej grupy względem SPY. Pionowa linia oznacza moment zdarzenia 30.11.2022.



Widoczne jest wyraźne rozejście trajektorii AI infrastructure od pozostałych grup po listopadzie 2022 — ten obraz motywuje formalne testy statystyczne przeprowadzone w trzech zadaniach poniżej.

1 Zadanie 1 — AI infrastructure vs Defensive: miesięczne abnormal returns

1.1 Opis zmiennych

Dla każdej grupy zbudowano portfel równoważony (EW). Dzienna stopa zwrotu portfela: $r_t^{\text{port}} = \frac{1}{N} \sum_{i=1}^N r_{i,t}$ (gdzie $r_{i,t}$ to dzienna log-stopa zwrotu spółki i). Następnie:

- agregacja miesięczna: $r_m^{\text{port}} = \sum_{t \in m} r_t^{\text{port}}$ (suma log-zwrotów, ekwiwalentnie miesięczny log-zwrot);
- *abnormal return*: $AR_m^{\text{port}} = r_m^{\text{port}} - r_m^{\text{SPY}}$;
- filtracja czasowa: tylko obserwacje po 30.11.2022.

Porównywane zmienne (próby niezależne, $n_1 = n_2 = 42$ miesięcy):

- X : miesięczne AR portfela **AI infrastructure** (11 spółek),
- Y : miesięczne AR portfela **Defensive control** (10 spółek).

1.2 Hipotezy badawcze

- H_0 : średnie miesięczne AR obu portfeli są równe, $\mu_{AR, AI} = \mu_{AR, Def}$.
- H_1 : średnie różnią się, $\mu_{AR, AI} \neq \mu_{AR, Def}$.

1.3 Procedura statystyczna

1. Sprawdzenie założeń: Shapiro-Wilk (normalność) + Levene (homogeniczność wariancji).
2. **Test główny**: *Welch t-test* dla dwóch prób niezależnych (bez założenia równych wariancji).
3. **Analiza odporności**: bootstrap ($B = 10\,000$, ziarno 42) 95% przedziału ufności różnicy średnich.
4. Wielkość efektu: *Hedges' g* (poprawiona Cohen's d dla małych prób).
5. **Test pomocniczy**: Mann-Whitney U — różnica w położeniu rozkładów (*nie* test średnich, dla kompletności).

1.4 Kod źródłowy (fragment)

```
1
2
3 def hedges_g(x, y):
4     n1, n2 = len(x), len(y)
5     s1, s2 = x.std(ddof=1), y.std(ddof=1)
6     sp = np.sqrt(((n1 - 1) * s1 ** 2 + (n2 - 1) * s2 ** 2) / (n1 + n2 - 2))
7     d = (x.mean() - y.mean()) / sp
8     J = 1 - 3 / (4 * (n1 + n2) - 9)
9     return float(d * J)
10
11
12 def welch_with_ci(x, y, alpha=ALPHA):
13     n1, n2 = len(x), len(y)
14     m1, m2 = float(x.mean()), float(y.mean())
15     v1, v2 = float(x.var(ddof=1)), float(y.var(ddof=1))
16     diff = m1 - m2
17     se = np.sqrt(v1 / n1 + v2 / n2)
18     df = (v1 / n1 + v2 / n2) ** 2 / ((v1 / n1) ** 2 / (n1 - 1) + (v2 / n2) ** 2 / (n2 - 1))
19     t_stat = diff / se
```

```

20 p = 2 * (1 - st.t.cdf(abs(t_stat), df))
21 t_crit = st.t.ppf(1 - alpha / 2, df)
22 return {
23     "t": float(t_stat), "df": float(df), "p_value": float(p),
24     "mean_x": m1, "mean_y": m2, "mean_diff": diff, "se_diff": float(se),
25     "ci_low": float(diff - t_crit * se), "ci_high": float(diff + t_crit * se),
26 }
27
28
29 def bootstrap_ci_diff(x, y, n_boot=N_BOOT, alpha=ALPHA, seed=SEED):
30     rng = np.random.default_rng(seed)
31     xa, ya = np.asarray(x), np.asarray(y)
32     n1, n2 = len(xa), len(ya)
33     boot = np.empty(n_boot)
34     for i in range(n_boot):
35         boot[i] = rng.choice(xa, size=n1, replace=True).mean() - rng.choice(ya, size=n2,
36                                     replace=True).mean()
37     lo, hi = np.percentile(boot, [100 * alpha / 2, 100 * (1 - alpha / 2)])
38     return {"boot_mean_diff": float(boot.mean()), "boot_ci_low": float(lo),
39             "boot_ci_high": float(hi), "n_boot": n_boot}
40
41 def main():
42     prices = load_prices()
43     meta = load_metadata()

```

1.5 Wyniki

Statystyki opisowe.

Portfel	n	średnia AR_m	odch. std.
AI infrastructure	42	0,02638	0,07774
Defensive control	42	-0,01089	0,04133


Założenia.

- Shapiro-Wilk AI infra: $W = 0,956$; $p = 0,1053$ (rozkład zbliżony do normalnego);
- Shapiro-Wilk Defensive: $W = 0,987$; $p = 0,9141$ (rozkład zbliżony do normalnego);
- Levene (median): stat = 13,23; $p = 0,0005$ (wariancje istotnie różne → uzasadnia *Welch*, a nie klasyczny *t*-Student).

Test główny — Welch t-test, bootstrap i Mann-Whitney.

Test	wartość	uwaga
Welch t ($df \approx 62,5$)	2,744	
p -value	0,00792	odrzućenie H_0
Różnica średnich ($\bar{X} - \bar{Y}$)	+0,03728	na korzyść AI infra
95% CI (Welch)	[+0,01012; +0,06443]	nie zawiera 0
Hedges' g	+0,593	umiarkowany efekt
95% CI bootstrap ($B = 10\,000$)	[+0,01199; +0,06365]	spójne z Welch
Mann-Whitney U (<i>pomocniczy</i>)	1122,0	różnica w położeniu rozkładów
p -value (M-W)	0,0321	spójne z H_1

Wykres rozkładów.



1.6 Interpretacja

- **Zmienna:** miesięczny abnormal return portfela EW vs SPY, $n = 42$ miesięcy (12.2022–05.2026).
- **Test zastosowany:** Welch t-test (główny) + bootstrap (odporność) + Mann-Whitney U (pomocniczy).
- **Wynik:** $p = 0,0079$; $\bar{X} - \bar{Y} = +3,73$ p.p. miesięcznie; 95% CI Welch $[+1,01; +6,44]$ p.p.; Hedges' $g = 0,59$. Bootstrap CI praktycznie pokrywa się z Welch.
- **Decyzja statystyczna:** odrzucamy H_0 przy $\alpha = 0,05$.
- **Interpretacja ekonomiczna:** w okresie 42 miesięcy po premierze ChatGPT portfel AI infrastructure dostarczył średnio ok. 3,7 p.p. *na miesiąc* wyższego abnormal returnu względem SPY niż portfel defensywny. Wynik jest spójny z hipotezą *AI Boom Premium*, choć wyższa zmienność portfela AI ($\sigma = 7,8\%$) wskazuje, że premia ta wiąże się z istotnie większym ryzykiem (do oceny w Zadaniu 2).

2 Zadanie 2 — Metryki efektywności w czterech grupach spółek

2.1 Opis zmiennych

Dla każdej z 41 spółek obliczono komplet 7 metryk na bazie dziennych log-zwrotów za cały okres 04.01.2021–14.05.2026:

- *Annualized return* = $\bar{r}_t \cdot 252$,
- *Annualized volatility* = $s(r_t) \cdot \sqrt{252}$,
- *Sharpe Ratio* = $(\overline{r_t - r_f}) / s(r_t - r_f) \cdot \sqrt{252}$,
- *Sortino Ratio* (downside deviation względem $MAR = 0$),
- *Maximum drawdown* liczony na wealth-curve $\exp(\sum r_t)$,
- *CAPM beta* z regresji nadwyżkowych zwrotów na SPY,
- *CAPM alpha* (annualized).

Główna zmienna testowana : **Sharpe Ratio** (najszerzej akceptowana miara ryzyko–zwrot w finansach). Dla kompletności — równolegle ten sam test przeprowadzono dla **CAPM alpha**, bezpośrednio mierzącego „nadwyżkę po kontroli ryzyka systematycznego” i najbliższego pojęciu *AI Premium*.

Statystyki opisowe (średnie metryk per grupa).

Grupa	Ann. ret	Ann. vol	Sharpe	Sortino	Max DD	alpha
AI infrastructure	0,362	0,501	0,674	0,684	−0,584	+0,119
AI platforms	0,072	0,374	0,154	0,159	−0,567	−0,107
Broad tech	0,111	0,349	0,228	0,228	−0,452	−0,064
Defensive	0,082	0,192	0,250	0,244	−0,297	+0,011

2.2 Hipotezy badawcze

- H_0 : średnie Sharpe Ratio (alpha) są równe we wszystkich czterech grupach.
- H_1 : co najmniej jedna grupa ma średnią różną od pozostałych.

2.3 Procedura statystyczna — drzewo decyzyjne

1. Shapiro-Wilk per grupa → czy rozkłady normalne?
2. Levene (median) → czy wariancje jednorodne?
3. Decyzja:
 - normalne + jednorodne → **ANOVA** + Tukey HSD,
 - normalne + nierówne wariancje → **Welch ANOVA** + Games-Howell,
 - nienormalne → **Kruskal-Wallis** + Dunn (Bonferroni).
4. Wielkość efektu: η^2 i ω^2 (mniej obciążone dla małych prób).

2.4 Kod źródłowy (fragment)

```
1 from common import CACHE, BENCHMARK, load_prices, load_metadata, log_returns, daily_rf
2 from metrics import compute_all_metrics
3 from plot_utils import setup_style, savefig
4
5 ALPHA = 0.05
6 GROUP_ORDER = ["AI_infra", "AI_platforms", "Broad_tech", "Defensive"]
7 GROUP_PAL = {
8     "AI_infra": "#1f77b4",
9     "AI_platforms": "#9467bd",
10    "Broad_tech": "#2ca02c",
11    "Defensive": "#d62728",
12 }
13
14
15 def compute_metrics_df(prices, meta) -> pd.DataFrame:
16     rets = log_returns(prices)
17     rf_d = daily_rf(prices)
18     bench = rets[BENCHMARK]
19     frames = []
20     for g in GROUP_ORDER:
21         tickers = meta.loc[meta["group"] == g, "ticker"].tolist()
22         frames.append(compute_all_metrics(rets, bench, rf_d, tickers, g))
23     return pd.concat(frames, ignore_index=True)
24
25
26 def normality_per_group(df: pd.DataFrame, col: str) -> pd.DataFrame:
27     rows = []
28     for g, sub in df.groupby("group"):
29         W, p = st.shapiro(sub[col].dropna())
30         rows.append({"group": g, "n": len(sub), "W": W, "p": p, "normal": p > ALPHA})
31     return pd.DataFrame(rows)
32
33
34 def variance_homogeneity(df: pd.DataFrame, col: str):
35     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
36     stat, p = st.levene(*groups, center="median")
37     return {"stat": float(stat), "p_value": float(p), "homogeneous": p > ALPHA}
38
39
40 def anova_with_tukey(df, col):
41     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
42     F, p = st.f_oneway(*groups)
43     all_vals = np.concatenate(groups)
44     N, k = len(all_vals), len(groups)
45     grand = all_vals.mean()
46     ss_b = sum(len(g) * (g.mean() - grand) ** 2 for g in groups)
47     ss_w = sum(((g - g.mean()) ** 2).sum() for g in groups)
48     ss_t = ss_b + ss_w
49     eta2 = ss_b / ss_t
50     ms_w = ss_w / (N - k)
51     omega2 = (ss_b - (k - 1) * ms_w) / (ss_t + ms_w)
52     tuk = pairwise_tukeyhsd(endog=df[col].values, groups=df["group"].values, alpha=ALPHA)
53     return {"test": "ANOVA", "F": float(F), "df_b": k - 1, "df_w": N - k,
54           "p_value": float(p), "eta_squared": float(eta2), "omega_squared": float(omega2)},
55     tuk
56
57 def welch_anova_with_games_howell(df, col):
58     res = anova_oneway(df[col].values, df["group"].values, use_var="unequal",
59                       welch_correction=True)
60     gh = sp.posthoc_games_howell(df, val_col=col, group_col="group")
61     return {"test": "Welch ANOVA", "F": float(res.statistic), "df_b": float(res.df_num),
```

```

61         "df_w": float(res.df_denom), "p_value": float(res.pvalue)}, gh
62
63
64 def kruskal_with_dunn(df, col):

```

2.5 Wyniki — zmienna główna: Sharpe Ratio


Założenia. Shapiro-Wilk: wszystkie cztery grupy spełniają normalność ($p > 0,05$). Levene: $\text{stat} = 1,25$; $p = 0,299$ — wariacje jednorodne. Decyzja: **ANOVA + Tukey HSD**.

ANOVA jednoczynnikowa. $F(3, 37) = 4,956$; $p = 0,00543$; $\eta^2 = 0,287$; $\omega^2 = 0,225$. Odrzucamy H_0 . Wartość $\omega^2 \approx 0,22$ wskazuje na duży efekt (konwencja Cohena: $\omega^2 \geq 0,14$ duży).

Tukey HSD (FWER = 0,05).

Grupa 1	Grupa 2	różnica	p_{adj}	95% CI	istotne
AI infra	AI platforms	−0,519	0,0076	[−0,925; −0,113]	tak
AI infra	Broad tech	−0,445	0,0269	[−0,851; −0,039]	tak
AI infra	Defensive	−0,424	0,0380	[−0,829; −0,018]	tak
AI platforms	Broad tech	+0,074	0,9633	[−0,341; +0,489]	nie
AI platforms	Defensive	+0,096	0,9253	[−0,320; +0,511]	nie
Broad tech	Defensive	+0,022	0,9990	[−0,394; +0,437]	nie

Wykres — Sharpe per grupa.



2.6 Wyniki — zmienna uzupełniająca: CAPM alpha


Założenia. Wszystkie grupy spełniają normalność (Shapiro $p > 0,05$); Levene $\text{stat} = 2,57$; $p = 0,066$ — nieznacznie powyżej α , wariacje uznajemy za jednorodne. Decyzja: **ANOVA + Tukey HSD**.

ANOVA jednoczynnikowa. $F(3, 37) = 7,621$; $p = 4,3 \cdot 10^{-4}$; $\eta^2 = 0,382$; $\omega^2 = 0,326$. Odrzucamy H_0 z silnym efektem ($\omega^2 \approx 0,33$).


Tukey HSD (FWER = 0,05).

Grupa 1	Grupa 2	różnica α	p_{adj}	95% CI	istotne
AI infra	AI platforms	-0,226	0,0004	$[-0,363; -0,089]$	tak
AI infra	Broad tech	-0,183	0,0049	$[-0,320; -0,046]$	tak
AI infra	Defensive	-0,108	0,1665	$[-0,245; +0,029]$	nie
AI platforms	Broad tech	+0,043	0,8450	$[-0,098; +0,183]$	nie
AI platforms	Defensive	+0,118	0,1247	$[-0,022; +0,259]$	nie
Broad tech	Defensive	+0,076	0,4791	$[-0,065; +0,216]$	nie

Wykres — CAPM alpha per grupa.



Forest plot — różnice metryk vs grupa Defensive.



2.7 Interpretacja

- **Zmienna:** Sharpe Ratio (główna) oraz CAPM alpha (uzupełniająca) liczone per spółka na dziennych log-zwrotach 2021–2026; $n = 41$ spółek w 4 grupach.
- **Test zastosowany:** ANOVA + Tukey HSD (oba przypadki: założenia spełnione).
- **Wynik (Sharpe):** $F(3, 37) = 4,96$; $p = 0,005$; $\omega^2 = 0,23$. Tukey lokalizuje różnice: AI infrastructure istotnie wyższy niż każda z pozostałych grup; pozostałe trzy grupy nie różnią się między sobą.

- **Wynik (alpha):** $F(3, 37) = 7,62$; $p = 4,3 \cdot 10^{-4}$; $\omega^2 = 0,33$. AI infrastructure ma istotnie wyższą α niż AI platforms i Broad tech; różnica vs Defensive nie jest istotna ($p = 0,17$ — Defensive ma $\alpha \approx 0$, ale również niskie ryzyko).
- **Decyzja statystyczna:** odrzucamy H_0 w obu testach.
- **Interpretacja ekonomiczna:** wyniki sugerują, że premia AI ma wyraźny charakter *sektorowy* (półprzewodniki i sprzęt) — platformy chmurowe (MSFT, GOOGL, AMZN itd.) nie wyróżniły się istotnie ani Sharpe Ratio, ani α względem reszty rynku. To prawdopodobnie skutek tego, że hyperscalerzy ponoszą *koszty kapitałowe* boomu AI (capex na klastry GPU), a dostawcy infrastruktury są jego bezpośrednimi beneficjentami przychodowymi.

Ograniczenie próby. 15 (najczęściej kilkanaście) spółek w każdej grupie to próba dobrana *celowo* (reprezentatywne nazwy z S&P 500), a nie losowo z populacji. Wnioski statystyczne dotyczą analizowanej próby i okresu 2021–2026 — nie należy ich uogólniać na „cały rynek”. Dodatkowo grupa Broad tech i Defensive jest sektorowo niejednorodna wewnętrznie, co zwiększa wariancję wewnątrzgrupową i tym samym zmniejsza moc testu.

3 Zadanie 3 — A/B testing na próbach zależnych wokół 30.11.2022

3.1 Opis zmiennych i schemat A/B

Zdarzenie: **publiczna premiera ChatGPT, 30.11.2022** — przyjęta jako data rozpoczęcia masowej fazy boomu generatywnej AI. Próba: 21 spółek z połączonej grupy „AI” = AI infrastructure $\cup$ AI platforms (11 + 10 = 21 spółek).

Dla każdej spółki i liczymy dwie wartości:

- **Wariant A:** $\bar{AR}_i^{(A)}$ — średni dzienny abnormal return (vs SPY) w oknie K sesji *przed* 30.11.2022,
- **Wariant B:** $\bar{AR}_i^{(B)}$ — średni dzienny abnormal return w oknie K sesji *po* 30.11.2022.

Jednostką pary jest *ta sama spółka*. Próby są więc zależne (paired). Statystyka testowa: $d_i = \bar{AR}_i^{(B)} - \bar{AR}_i^{(A)}$.

3.2 Hipotezy badawcze

- $H_0: \mu_d = 0$ — średnia różnica AR między wariantem B i A wynosi zero.
- $H_1: \mu_d \neq 0$.

3.3 Procedura statystyczna

1. Test normalności różnic d_i (Shapiro-Wilk).
2. **Test główny:** paired t -test (jeśli różnice normalne).
3. **Test odporności:** Wilcoxon signed-rank (zawsze raportowany). W przypadku odrzucenia normalności Wilcoxon staje się testem głównym.
4. Wielkość efektu: Cohen's $d_z = \bar{d}/s_d$; 95% przedział ufności dla $\bar{d}$ (rozkład t z $n - 1$ stopniami swobody).
5. **Analiza wrażliwości** na długość okna: $K \in \{30, 60, 120, 250\}$ sesji. Okno bazowe: $K = 120$ (6 miesięcy ekspozycji *ex post*).
6. **Placebo test:** cała procedura powtórzona dla daty 30.11.2021 (rok przed boomem AI). Jeśli wynik dla eventu nie pojawia się „przypadkowo” — placebo nie powinien dawać analogicznie istotnego efektu *w tym samym kierunku*.

3.4 Kod źródłowy (fragment)

```
1 WINDOWS = [30, 60, 120, 250]
2 PRIMARY_WINDOW = 120
3
4
5 def select_windows(returns_idx: pd.DatetimeIndex, event: pd.Timestamp, k: int):
6     days = returns_idx[returns_idx != event]
7     before = days[days < event][-k:]
8     after = days[days > event][:k]
9     return before, after
10
11
12 def per_stock_paired(ar_df: pd.DataFrame, event: pd.Timestamp, k: int) -> pd.DataFrame:
13     before, after = select_windows(ar_df.index, event, k)
14     rows = []
15     for t in ar_df.columns:
```

```

16     mb = ar_df.loc[before, t].dropna().mean()
17     ma = ar_df.loc[after, t].dropna().mean()
18     rows.append({"ticker": t, "mean_A_before": mb, "mean_B_after": ma, "diff_B_minus_A": ma
    - mb})
19 df = pd.DataFrame(rows)
20 df["window_sessions"] = k
21 df.attrs["window_before"] = (before[0], before[-1]) if len(before) else None
22 df.attrs["window_after"] = (after[0], after[-1]) if len(after) else None
23 return df
24
25
26 def paired_summary(diffs: np.ndarray, alpha=ALPHA) -> dict:
27     diffs = np.asarray(diffs, dtype=float)
28     n = len(diffs)
29     mean_d = float(diffs.mean())
30     sd_d = float(diffs.std(ddof=1))
31     se_d = sd_d / np.sqrt(n)
32     W_sh, p_sh = st.shapiro(diffs)
33     t_crit = st.t.ppf(1 - alpha / 2, n - 1)
34     ci_low, ci_high = mean_d - t_crit * se_d, mean_d + t_crit * se_d
35     cohen_dz = mean_d / sd_d if sd_d > 0 else np.nan
36     t_stat, t_p = st.ttest_1samp(diffs, 0.0)
37     w_stat, w_p = st.wilcoxon(diffs, alternative="two-sided")
38     use_t = p_sh > alpha
39     main_test = "Paired t-test" if use_t else "Wilcoxon signed-rank"
40     main_stat = float(t_stat) if use_t else float(w_stat)
41     main_p = float(t_p) if use_t else float(w_p)
42     return {
43         "n": n, "mean_diff": mean_d, "sd_diff": sd_d, "se_diff": se_d,
44         "ci_low": ci_low, "ci_high": ci_high, "cohen_dz": cohen_dz,
45         "shapiro_W": float(W_sh), "shapiro_p": float(p_sh), "normal_diffs": bool(use_t),
46         "t_stat": float(t_stat), "t_p_value": float(t_p),
47         "wilcoxon_stat": float(w_stat), "wilcoxon_p_value": float(w_p),
48         "main_test": main_test, "main_stat": main_stat, "main_p_value": main_p,
49     }
50
51
52 def run_sensitivity(ar_df, event, windows, label):
53     rows = []
54     pairs_by_window = {}

```

3.5 Wyniki

Główny test — okno bazowe $K = 120$ sesji. Shapiro-Wilk: $W = 0,897$; $p = 0,0227$ — różnice odbiegają od rozkładu normalnego, więc testem głównym jest Wilcoxon, a paired t -test raportujemy jako wspierający.

$$\bar{d} = +0,00243; \quad 95\% \text{ CI: } [+0,00123; +0,00363]; \quad d_z = +0,92 \text{ (duży efekt);}$$


$$\text{Wilcoxon } p = 8,4 \cdot 10^{-5}; \quad \text{paired } t(20) = 4,11; \quad p = 4,2 \cdot 10^{-4}.$$

Oba testy zgodnie odrzucają H_0 .


Pełna analiza wrażliwości + placebo.

Wariant	K	$\bar{d}$	95% CI	d_z	p (główny)	test
Event: 30.11.2022 (premiera ChatGPT)						
event	30	-0,00177	$[-0,00502; +0,00149]$	-0,25	0,2707	paired t
event	60	+0,00147	$[-0,00024; +0,00317]$	+0,39	0,0760	Wilcoxon
event	120	+0,00243	$[+0,00123; +0,00363]$	+0,92	$8,4 \cdot 10^{-5}$	Wilcoxon
event	250	+0,00231	$[+0,00143; +0,00319]$	+1,20	$< 10^{-4}$	paired t
Placebo: 30.11.2021 (rok przed boomem AI)						
placebo	30	-0,00385	$[-0,00672; -0,00098]$	-0,61	0,0110	paired t
placebo	60	-0,00290	$[-0,00447; -0,00134]$	-0,84	0,0010	paired t
placebo	120	-0,00260	$[-0,00412; -0,00108]$	-0,78	0,0020	paired t
placebo	250	-0,00156	$[-0,00248; -0,00064]$	-0,77	0,0021	paired t

Wykres — histogram różnic + sensitivity z placebo.



Event-window CAR — portfele EW per grupa wokół 30.11.2022.



3.6 Interpretacja

- **Zmienna:** $d_i = \bar{AR}_i^{(B)} - \bar{AR}_i^{(A)}$ dla $n = 21$ spółek z grupy AI; $\bar{AR}$ to średni dzienny abnormal return (vs SPY) w oknie K sesji.
- **Test zastosowany:** Wilcoxon signed-rank (główny, bo Shapiro odrzucił normalność dla okna 120) + paired t -test (wspierający).
- **Wynik (okno bazowe $K = 120$):** $\bar{d} = +0,243$ p.p. *dziennie*; 95% CI $[+0,123; +0,363]$ p.p.; $d_z = +0,92$ (duży efekt); Wilcoxon $p = 8,4 \cdot 10^{-5}$.

- **Decyzja statystyczna:** odrzucamy H_0 z wysokim marginesem dla okien 120 i 250 sesji. Dla okna 60 efekt graniczny ($p = 0,076$), dla okna 30 nieistotny (*ex post* rynek potrzebował kilku miesięcy, aby „wycenić” premię AI).
- **Placebo:** dla 30.11.2021 efekt jest *ujemny i istotny* we wszystkich oknach. Kierunek przeciwny do eventu rzeczywistego silnie wzmacnia interpretację — gdyby istotny dodatni efekt z eventu wynikał z artefaktu czasowego lub trendu, oczekivalibyśmy podobnie dodatniego sygnału także dla placebo. Sygnał placebo jest jednak ujemny, co świadczy, że dodatni $\bar{d}$ wokół 30.11.2022 jest powiązany czasowo z tym konkretnym zdarzeniem, a nie z ogólnym trendem AI sprzed boomu.
- **Interpretacja ekonomiczna:** po publicznej premierze ChatGPT spółki z grupy AI generowały średnio o ok. 0,24 p.p. *dziennie* wyższy abnormal return niż w analogicznym oknie przed premierą. W ujęciu zannualizowanym to ok. 60 p.p. nadwyżki dziennej skumulowanej — wynik niezwykle duży, ale spójny z trajektoriami obserwowanymi na wykresie skumulowanych AR i wzroście NVIDIA z 2023–2025.

Ograniczenia. Analiza ma charakter *uproszczonego testu A/B przed-po*: nie modeluje oczekiwanego abnormal returnu względem modelu czynnikowego (Fama-French 3/5 czynników); raportujemy AR jedynie względem SPY. Wybór grupy zdarzeniowej (infra + platforms) jest definicyjny — nie jest to próba losowa.

Wnioski końcowe i decyzja inwestora

Wnioski statystyczne.

- **Zad 1.** Welch t-test odrzuca H_0 ($p = 0,0079$, Hedges' $g = 0,59$): portfel AI infrastructure ma istotnie wyższą średnią miesięczną nadwyżkę względem SPY niż portfel Defensive po 30.11.2022 (+3,7 p.p./miesiąc).
- **Zad 2.** ANOVA odrzuca H_0 dla obu zmiennych: Sharpe ($F = 4,96$; $p = 0,005$; $\omega^2 = 0,23$) i CAPM α ($F = 7,62$; $p = 4 \cdot 10^{-4}$; $\omega^2 = 0,33$). Tukey lokalizuje przewagę po stronie AI infrastructure; trzy pozostałe grupy nie różnią się istotnie między sobą.
- **Zad 3.** Wilcoxon ($K = 120$): $p = 8,4 \cdot 10^{-5}$; $\bar{d} = +0,24$ p.p./dzień; 95% CI [+0,12; +0,36] p.p.; $d_z = +0,92$. Placebo test daje efekt w kierunku przeciwnym, co wzmacnia interpretację przyczynową.

Decyzja inwestora — praktyczny take-away.

- Trzy niezależne testy zgodnie wspierają tezę *AI Boom Premium* — ale *tylko* w segmencie infrastruktury (półprzewodniki, sprzęt), nie w platformach chmurowych.
- Premium wiąże się z istotnie wyższym ryzykiem: portfel AI infrastructure miał volatylity 50% rocznie (vs 19% Defensive) i max drawdown -58% . Inwestor neutralny ryzykownie powinien stosować mniejszą wagę w portfelu niż sugerowałyby sama wielkość średniej nadwyżki.
- Wyniki są *ex post* i odzwierciedlają konkretny okres 2021–2026. Standardowe ostrzeżenie: „past performance is not indicative of future results”. Czy premia utrzyma się po fazie szczytowej AI capex — pozostaje otwartą kwestią.

Reproducibility note

Środowisko. Python 3.13.11; pandas 3.0.3, numpy 2.4.6, scipy 1.17.1, statsmodels 0.14.6, scikit-posthocs 0.13.0, matplotlib 3.10.9, seaborn 0.13.2, yfinance 1.3.0, pyarrow 24.0.0. Pełna lista zależności: `requirements.txt`.

Dane. Źródło: Yahoo Finance via `yfinance`. Pobranie: 2026-05-20. Cache lokalny: `data_cache/prices.parquet` (43 tickery $\times$ 1347 dni sesyjnych). Mapowanie ticker $\rightarrow$ grupa: `data_cache/metadata_tickers.csv`.

Skrypty (kolejność wykonania).

1. `src/data_fetch.py` — pobranie i zapis do parquet.
2. `src/task1_two_portfolios.py` — Zadanie 1.
3. `src/task2_four_groups.py` — Zadanie 2 (Sharpe i alpha).
4. `src/task3_paired_event.py` — Zadanie 3 (event + placebo).
5. `src/plots_extra.py` — wykresy zaawansowane.

Moduły wspólne: `src/common.py` (wczytywanie, log returns, portfele EW, abnormal returns, RF), `src/metrics.py` (7 metryk per spółka), `src/plot_utils.py` (style i zapis wykresów).

Ziarno losowe. Bootstrap w Zad. 1 używa `numpy.random.default_rng(seed=42)` i $B = 10\,000$ powtórzeń. Pozostałe analizy są deterministyczne.


Repozytorium. github.com/Smalou/metody_badania_w_finansach — pełny kod, dane cache i źródło LaTeX dostępne publicznie.

Limitations

- **Selection bias / próby celowe.** Wszystkie cztery grupy spółek dobrane są ręcznie na bazie ekspertowej oceny ekspozycji na AI — nie są losowymi próbami z populacji. Wnioski dotyczą tej konkretnej próby.
- **Niejednorodność wewnątrzgrupowa.** Grupy Broad tech i Defensive zawierają spółki o zróżnicowanych modelach biznesowych, co zwiększa wewnętrzną wariancję metryk.
- **Single-factor benchmark.** Abnormal returns liczone są jako prosty spread względem SPY. Nie kontrolujemy ekspozycji na czynniki Fama-French (HML, SMB, momentum) ani na czynniki sektorowe.
- **Definicja zdarzenia.** Premiera ChatGPT (30.11.2022) jest symbolicznym punktem startu boomu AI, ale realna fala kapitałowa następowała stopniowo przez kolejne 6–12 miesięcy. Stąd wrażliwość wyników Zad. 3 na długość okna.
- **Dane yfinance.** Ceny są korygowane wstecznie (split, dywidenda); dostawca może okresowo modyfikować historyczne wartości. Cache lokalny zapewnia reprodukowalność tej analizy, ale ponowne pobranie może dać minimalnie inne wyniki.
- **Spojrzenie ex-post.** Cały kierunek hipotezy („AI Premium”) jest motywowany obserwacjami z lat 2023–2025. Test jest confirmacyjny, nie predykcyjny.


Dodatek — wykresy uzupełniające

Heatmapa korelacji dziennych log-zwrotów.



Wizualnie widoczne są bloki wysokiej korelacji wewnątrz grup AI (infra, platforms) oraz niska korelacja grupy Defensive z technologiami.

Rolling annualized volatility (okno 63 sesji).



AI infrastructure utrzymuje najwyższy poziom zmienności w całym okresie, ze szczytami wokół wybuchu AI capex 2023 i fazy korekt 2024–2025.

Bibliografia

1. Sharpe, W. F. (1994). The Sharpe Ratio. *The Journal of Portfolio Management*, 21(1), 49–58.
2. Sortino, F. A., & Price, L. N. (1994). Performance measurement in a downside risk framework. *Journal of Investing*, 3(3), 59–64.
3. Welch, B. L. (1947). The generalization of „Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35.
4. Games, P. A., & Howell, J. F. (1976). Pairwise multiple comparison procedures with unequal N ’s and/or variances. *Journal of Educational Statistics*, 1(2), 113–125.
5. Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed., Lawrence Erlbaum Associates.
6. Hedges, L. V. (1981). Distribution theory for Glass’s estimator of effect size and related estimators. *Journal of Educational Statistics*, 6(2), 107–128.
7. MacKinlay, A. C. (1997). Event Studies in Economics and Finance. *Journal of Economic Literature*, 35(1), 13–39.
8. Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
9. Yahoo Finance / `yfinance` 1.3 — dokumentacja API, <https://github.com/ranaroussi/yfinance>.