

AI Boom Premium?

Czy spółki silnie powiązane z infrastrukturą AI osiągnęły wyższe zwroty po rozpoczęciu boomu generatywnej AI — i ile z tego może wynikać z ryzyka rynkowego?

Projekt zaliczeniowy IAD — Metody Badań w Finansach, ćwiczenia 3

Roksana Kulawiec (454474)

Sylwia Malinowska (487648)

Mateusz Konopka (487528)

Antoni Grabowski (452622)

20 maja 2026

Repozytorium kodu i danych

github.com/Smalou/metody_badania_w_finansach

Wszystkie skrypty Pythona, cache danych (parquet/csv), wygenerowane wykresy i źródło niniejszego raportu LaTeX są dostępne w powyższym repozytorium.

Streszczenie dla czytelnika

Raport sprawdza, czy po premierze ChatGPT spółki infrastruktury AI osiągały wyższe zwroty niż grupy kontrolne. Wyniki wskazują silną przewagę segmentu **AI infrastructure** w analizowanym okresie, jednak pogłębiona diagnostyka metodologiczna pokazuje, że proste spready względem SPY nie kontrolują różnic w becie, test placebo w Zadaniu 3 ujawnia misspecification, a dobór spółek ma charakter ex post. Najmocniejszym elementem raportu pozostaje porównanie metryk ryzyko-zwrot i CAPM alpha w Zadaniu 2; Zadania 1 i 3 traktujemy jako opisowe, a nie przyczynowe.

Spis treści

1	Zadanie 1 — AI infrastructure vs Defensive: miesięczne zwroty względem SPY	5
1.1	Opis zmiennych	5
1.2	Hipotezy badawcze	5
1.3	Procedura statystyczna	5
1.4	Kod źródłowy (fragment)	6
1.5	Wyniki	6
1.6	Interpretacja	7
2	Zadanie 2 — Metryki efektywności w czterech grupach spółek	9
2.1	Opis zmiennych	9
2.2	Hipotezy badawcze	9
2.3	Procedura statystyczna — drzewo decyzyjne	9
2.4	Kod źródłowy (fragment)	10
2.5	Wyniki — zmienna główna: Sharpe Ratio	11
2.6	Wyniki — zmienna uzupełniająca: CAPM alpha	12
2.7	Kontrola odporności — Kruskal-Wallis + Dunn	13
2.8	Interpretacja	13

3	Zadanie 3 — A/B testing na próbach zależnych wokół 30.11.2022	15
3.1	Opis zmiennych i schemat A/B	15
3.2	Hipotezy badawcze	15
3.3	Procedura statystyczna	15
3.4	Kod źródłowy (fragment)	15
3.5	Wyniki	16
3.6	Interpretacja	17
3.7	Dodatkowa kontrola odporności — CAPM-adjusted returns	18

Wprowadzenie i hipoteza projektowa

W projekcie przyjęto premierę ChatGPT (30 listopada 2022) jako symboliczny punkt startu masowej fazy boomu generatywnej AI. W kolejnych kwartałach temat AI stał się jednym z głównych motywów inwestycyjnych na rynku amerykańskim, szczególnie w segmencie półprzewodników, infrastruktury obliczeniowej i usług chmurowych. Niniejszy projekt sprawdza empirycznie, czy po tej dacie wystąpiły mierzalne różnice w średnich zwrotach oraz profilu ryzyko–zwrot między spółkami o różnym stopniu ekspozycji na sztuczną inteligencję. Analiza ma charakter statystyczny i porównawczy; nie jest dowodem przyczynowym w ścisłym sensie ekonometrycznym.

Hipoteza badawcza. *Spółki silnie powiązane z infrastrukturą AI (producenci półprzewodników i sprzętu) osiągnęły po 30.11.2022 wyższe średnie zwroty i/lub lepszy profil ryzyko–zwrot niż grupy kontrolne (Defensive, Broad Tech, AI Platforms). Hipotezę tę traktujemy jako przedmiot testu, a nie tezę do udowodnienia.*

Uwaga interpretacyjna: Najważniejsze ograniczenie metodologiczne dotyczy definicji spreadów w Zadaniach 1 i 3. Użyty spread względem SPY zakłada implícite $\beta = 1$. Tymczasem estymowane bety dziennych portfeli EW są bardzo różne: po ewencie AI infrastructure ma $\beta \approx 1,98$, a Defensive tylko $\beta \approx 0,24$. Oznacza to, że część przewagi AI infrastructure może być premią za wysokie ryzyko systematyczne, a nie czystą premią związaną z AI.

Trzy zadania spójne tematycznie.


- **Zadanie 1** — porównanie średnich miesięcznych zwrotów względem SPY portfela AI infrastructure i portfela Defensive control *po* rozpoczęciu boomu (próby niezależne). To test opisowy, nie pełne CAPM event study.
- **Zadanie 2** — porównanie średnich metryk efektywności ryzyko–zwrot (*Sharpe Ratio* jako zmienna główna, *CAPM alpha* jako uzupełnienie) między czterema grupami spółek.
- **Zadanie 3** — A/B testing na próbach zależnych: średnie dzienne zwroty względem SPY tej samej spółki w oknie przed (wariant A) i po (wariant B) 30.11.2022, z analizą wrażliwości i testem placebo. Wynik placebo traktujemy jako ostrzeżenie o misspecification.

Dane. Źródło: Yahoo Finance przez bibliotekę `yfinance`. 41 spółek notowanych na NYSE/NASDAQ podzielonych na cztery grupy (definicje w `data_cache/metadata_tickers.csv`) plus benchmark SPY i stopa wolna od ryzyka $\sim$ IRX (13-tygodniowy T-bill). Okres: 04.01.2021–14.05.2026 (1347 dni sesyjnych). Ceny skorygowane (`auto_adjust=True`), brak braków danych.

Grupy spółek (11+10+10+10 = 41).

- **AI infrastructure / półprzewodniki (11):** NVDA, AMD, AVGO, TSM, ASML, AMAT, LRCX, KLAC, MU, MRVL, SMCI.
- **AI platforms / cloud / software (10):** MSFT, GOOGL, AMZN, META, ORCL, CRM, NOW, ADBE, IBM, SNOW.
- **Broad technology control (10):** AAPL, CSCO, INTC, TXN, QCOM, INTU, ACN, PANW, CDNS, ADSK.
- **Defensive control (10):** KO, PEP, PG, WMT, JNJ, MRK, MCD, COST, CL, GIS.

Kontekst graficzny — skumulowane zwroty względem SPY per grupa. Poniższy wykres przedstawia skumulowany dzienny spread portfela równoważonego (EW) każdej grupy względem SPY. Pionowa linia oznacza moment zdarzenia 30.11.2022.



Widoczne jest wyraźne rozejście trajektorii AI infrastructure od pozostałych grup po listopadzie 2022. Wykres pełni jednak wyłącznie funkcję diagnostyczną i opisową. Nie rozstrzyga, czy przewaga wynika z ekspozycji na AI, z wysokiej bety względem rynku, czy z innych czynników wspólnych dla spółek technologicznych.

Uwaga interpretacyjna: Wykres skumulowanych spreadów względem SPY pomaga zrozumieć kontekst, ale nie zastępuje testów statystycznych. Dodatkowo jest liczony względem SPY bez korekty o indywidualną betę, dlatego nie powinien być czytany jako pełny abnormal return w sensie CAPM.

1 Zadanie 1 — AI infrastructure vs Defensive: miesięczne zwroty względem SPY

1.1 Opis zmiennych

Dla każdej grupy zbudowano portfel równoważony (EW). Dzienna stopa zwrotu portfela:

$$r_t^{\text{port}} = \frac{1}{N} \sum_{i=1}^N r_{i,t},$$

gdzie $r_{i,t}$ to dzienna log-stopa zwrotu spółki i . Następnie:

- agregacja miesięczna: $r_m^{\text{port}} = \sum_{t \in m} r_t^{\text{port}}$ (suma log-zwrotów, ekwiwalentnie miesięczny log-zwrot);
- spread względem SPY: $S_m^{\text{port}} = r_m^{\text{port}} - r_m^{\text{SPY}}$. W kodzie część zmiennych i plików ma historyczną nazwę z wcześniejszej wersji projektu, ale w interpretacji finansowej traktujemy tę zmienną jako *spread vs SPY*, nie jako pełny abnormal return z modelu CAPM;
- filtracja czasowa: tylko obserwacje *po* 30.11.2022.
Porównywane zmienne (próby niezależne, $n_1 = n_2 = 42$ miesiące):
- X : miesięczny spread vs SPY portfela **AI infrastructure** (11 spółek),
- Y : miesięczny spread vs SPY portfela **Defensive control** (10 spółek).

Ostatni miesiąc w próbie (maj 2026) jest miesiącem częściowym ze względu na datę pobrania danych. W głównym wyniku zachowano go dla zgodności z cache danych; w praktycznej analizie inwestycyjnej warto dodatkowo sprawdzić wariant z jego wykluczeniem.

Ograniczenie specyfikacji. Definicja $S_m^{\text{port}} = r_m^{\text{port}} - r_m^{\text{SPY}}$ jest prosta i czytelna, ale narzuca ukryte założenie $\beta = 1$ względem rynku. To założenie jest mało realistyczne dla porównywanych portfeli: dzienna beta EW portfela AI infrastructure po 30.11.2022 wynosi ok. 1,98, a portfela Defensive ok. 0,24. W silnej hossie technologicznej wysoka beta może mechanicznie generować przewagę nad SPY. Wynik Zadania 1 należy więc traktować jako test różnicy prostych zwrotów względem benchmarku, a nie jako dowód czystej alfy AI.

1.2 Hipotezy badawcze

- H_0 : średnie miesięczne spready vs SPY obu portfeli są równe, $\mu_{\text{spread,AI}} = \mu_{\text{spread,Def}}$.
- H_1 : średnie różnią się, $\mu_{\text{spread,AI}} \neq \mu_{\text{spread,Def}}$.

1.3 Procedura statystyczna

1. Sprawdzenie założeń: Shapiro-Wilk (normalność) + Levene (homogeniczność wariancji).
2. **Test główny:** *Welch t-test* dla dwóch prób niezależnych (bez założenia równych wariancji).
3. **Analiza odporności:** bootstrap ($B = 10\,000$, ziarno 42) 95% przedziału ufności różnicy średnich.
4. Wielkość efektu: *Hedges' g* (poprawiona Cohen's d dla małych prób).
5. **Test pomocniczy:** Mann-Whitney U. Przy nierównych wariancjach nie interpretujemy go jako czystego testu median; traktujemy go jako test różnic w rangach / stochastycznej dominacji.

1.4 Kod źródłowy (fragment)

```
1 N_BOOT = 10_000
2
3
4 def hedges_g(x, y):
5     n1, n2 = len(x), len(y)
6     s1, s2 = x.std(ddof=1), y.std(ddof=1)
7     sp = np.sqrt(((n1 - 1) * s1 ** 2 + (n2 - 1) * s2 ** 2) / (n1 + n2 - 2))
8     d = (x.mean() - y.mean()) / sp
9     J = 1 - 3 / (4 * (n1 + n2) - 9)
10    return float(d * J)
11
12
13 def welch_with_ci(x, y, alpha=ALPHA):
14     n1, n2 = len(x), len(y)
15     m1, m2 = float(x.mean()), float(y.mean())
16     v1, v2 = float(x.var(ddof=1)), float(y.var(ddof=1))
17     diff = m1 - m2
18     se = np.sqrt(v1 / n1 + v2 / n2)
19     df = (v1 / n1 + v2 / n2) ** 2 / ((v1 / n1) ** 2 / (n1 - 1) + (v2 / n2) ** 2 / (n2 - 1))
20     t_stat = diff / se
21     p = 2 * (1 - st.t.cdf(abs(t_stat), df))
22     t_crit = st.t.ppf(1 - alpha / 2, df)
23     return {
24         "t": float(t_stat), "df": float(df), "p_value": float(p),
25         "mean_x": m1, "mean_y": m2, "mean_diff": diff, "se_diff": float(se),
26         "ci_low": float(diff - t_crit * se), "ci_high": float(diff + t_crit * se),
27     }
28
29
30 def bootstrap_ci_diff(x, y, n_boot=N_BOOT, alpha=ALPHA, seed=SEED):
31     rng = np.random.default_rng(seed)
32     xa, ya = np.asarray(x), np.asarray(y)
33     n1, n2 = len(xa), len(ya)
34     boot = np.empty(n_boot)
35     for i in range(n_boot):
36         boot[i] = rng.choice(xa, size=n1, replace=True).mean() - rng.choice(ya, size=n2,
37                                     replace=True).mean()
38     lo, hi = np.percentile(boot, [100 * alpha / 2, 100 * (1 - alpha / 2)])
39     return {"boot_mean_diff": float(boot.mean()), "boot_ci_low": float(lo),
40             "boot_ci_high": float(hi), "n_boot": n_boot}
41
42 def main():
43     prices = load_prices()
```

1.5 Wyniki

Statystyki opisowe.

Portfel	n	średni spread vs SPY	odch. std.
AI infrastructure	42	0,02638	0,07774
Defensive control	42	-0,01089	0,04133

Założenia.

- Shapiro-Wilk AI infra: $W = 0,956$; $p = 0,1053$ (rozkład zbliżony do normalnego);
- Shapiro-Wilk Defensive: $W = 0,987$; $p = 0,9141$ (rozkład zbliżony do normalnego);


- Levene (median): stat = 13,23; $p = 0,0005$ (wariancje istotnie różne → uzasadnia *Welch*, a nie klasyczny *t*-Student).

Test główny — Welch t-test, bootstrap i Mann-Whitney.

Test	wartość	uwaga
Welch t (df $\approx 62,5$)	2,744	
p -value	0,00792	odrzućenie H_0
Różnica średnich ($\bar{X} - \bar{Y}$)	+0,03728	na korzyść AI infra
95% CI (Welch)	[+0,01012; +0,06443]	nie zawiera 0
Hedges' g	+0,593	umiarkowany efekt
95% CI bootstrap (B = 10 000)	[+0,01199; +0,06365]	spójne z Welch
Mann-Whitney U (pomocniczy)	1122,0	różnica rang / dominacja stochastyczna
p -value (M-W)	0,0321	spójne z H_1

Najważniejszy wynik: Portfel AI infrastructure miał średnio o +3,73 p.p. miesięcznie wyższy zwrot względem SPY niż portfel Defensive, a 95% przedziały ufności nie obejmują zera. Nie jest to jednak wynik skorygowany o różnice w beczie.

Wykres rozkładów.



1.6 Interpretacja

- **Zmienna:** miesięczny zwrot portfela EW względem SPY, $n = 42$ miesięcy (12.2022–05.2026).
- **Test zastosowany:** Welch t-test (główny) + bootstrap (odporność) + Mann-Whitney U (pomocniczy; przy nierównych wariancjach nie jako prosty test median).
- **Wynik:** $p = 0,0079$; $\bar{X} - \bar{Y} = +3,73$ p.p. miesięcznie; 95% CI Welch [+1,01; +6,44] p.p.; Hedges' $g = 0,59$. Bootstrap CI praktycznie pokrywa się z Welch.
- **Decyzja statystyczna:** odrzucamy H_0 przy $\alpha = 0,05$.
- **Interpretacja ekonomiczna:** w okresie 42 miesięcy po premierze ChatGPT portfel AI infrastructure dostarczył średnio ok. 3,7 p.p. *na miesiąc* wyższego zwrotu względem SPY niż portfel defensywny. Wynik jest spójny z obserwacją silnej przewagi segmentu infrastruktury AI, ale nie pozwala samodzielnie oddzielić efektu AI od premii za wysoką betę i wyższe ryzyko systematyczne.

Uwaga interpretacyjna: Wynik z Zadania 1 pokazuje istotną różnicę średnich spreadów względem SPY, ale nie kontroluje ryzyka systematycznego. Dlatego wniosek powinien brzmieć: „AI infrastructure pobiło SPY i Defensive w prostym porównaniu”, a nie: „AI infrastructure wygenerowało czystą alfę związaną wyłącznie z AI”.

2 Zadanie 2 — Metryki efektywności w czterech grupach spółek

2.1 Opis zmiennych

Dla każdej z 41 spółek obliczono komplet 7 metryk na bazie dziennych log-zwrotów za cały okres 04.01.2021–14.05.2026:

- *Annualized return* = $\bar{r}_t \cdot 252$,
- *Annualized volatility* = $s(r_t) \cdot \sqrt{252}$,
- *Sharpe Ratio* = $(\bar{r}_t - r_f) / s(r_t - r_f) \cdot \sqrt{252}$,
- *Sortino Ratio* (downside deviation względem $MAR = 0$),
- *Maximum drawdown* liczony na wealth-curve $\exp(\sum r_t)$,
- *CAPM beta* z regresji nadwyżkowych zwrotów na SPY,
- *CAPM alpha* (annualized).

Główna zmienna testowana : **Sharpe Ratio** (najszerzej akceptowana miara ryzyko–zwrot w finansach). Dla kompletności — równolegle ten sam test przeprowadzono dla **CAPM alpha**, bezpośrednio mierzącego „nadwyżkę po kontroli ryzyka systematycznego” i najbliższego pojęciu *AI Premium*.

Statystyki opisowe (średnie metryk per grupa).

Grupa	Ann. ret	Ann. vol	Sharpe	Sortino	Max DD	beta	alpha
AI infrastructure	0,362	0,501	0,674	0,684	−0,584	1,854	+0,119
AI platforms	0,072	0,374	0,154	0,159	−0,567	1,296	−0,107
Broad tech	0,111	0,349	0,228	0,228	−0,452	1,262	−0,064
Defensive	0,082	0,192	0,250	0,244	−0,297	0,336	+0,011

Tabela pokazuje jednocześnie, dlaczego interpretacja Zadania 1 wymaga ostrożności: AI infrastructure ma znacznie wyższą średnią betę niż grupa Defensive, więc część przewagi w prostym spreadzie względem SPY jest naturalną konsekwencją wyższej ekspozycji na rynek.

2.2 Hipotezy badawcze

- H_0 : średnie Sharpe Ratio (alpha) są równe we wszystkich czterech grupach.
- H_1 : co najmniej jedna grupa ma średnią różną od pozostałych.

2.3 Procedura statystyczna — drzewo decyzyjne

1. Shapiro-Wilk per grupa → czy rozkłady normalne?
2. Levene (median) → czy wariancje jednorodne?
3. Decyzja:
 - normalne + jednorodne → **ANOVA** + Tukey HSD,
 - normalne + nierówne wariancje → **Welch ANOVA** + Games-Howell,
 - nienormalne → **Kruskal-Wallis** + Dunn (Bonferroni).
4. Wielkość efektu: η^2 i ω^2 (mniej obciążone dla małych prób).

5. Ze względu na małe liczebności grup ($n = 10\text{--}11$) raportujemy także kontrolę odporności: Kruskal-Wallis + Dunn (Bonferroni).

Uwaga interpretacyjna: Przy $n \approx 10$ test Shapiro-Wilka ma niską moc. Brak odrzucenia normalności nie jest silnym dowodem normalności rozkładów metryk finansowych. Dlatego wyniki ANOVA traktujemy jako główne zgodnie z drzewem decyzyjnym, ale weryfikujemy je nieparametrycznie.

2.4 Kod źródłowy (fragment)

```
1 from common import CACHE, BENCHMARK, load_prices, load_metadata, log_returns, daily_rf
2 from metrics import compute_all_metrics
3 from plot_utils import setup_style, savefig
4
5 ALPHA = 0.05
6 GROUP_ORDER = ["AI_infra", "AI_platforms", "Broad_tech", "Defensive"]
7 GROUP_PAL = {
8     "AI_infra": "#1f77b4",
9     "AI_platforms": "#9467bd",
10    "Broad_tech": "#2ca02c",
11    "Defensive": "#d62728",
12 }
13
14
15 def compute_metrics_df(prices, meta) -> pd.DataFrame:
16     rets = log_returns(prices)
17     rf_d = daily_rf(prices)
18     bench = rets[BENCHMARK]
19     frames = []
20     for g in GROUP_ORDER:
21         tickers = meta.loc[meta["group"] == g, "ticker"].tolist()
22         frames.append(compute_all_metrics(rets, bench, rf_d, tickers, g))
23     return pd.concat(frames, ignore_index=True)
24
25
26 def normality_per_group(df: pd.DataFrame, col: str) -> pd.DataFrame:
27     rows = []
28     for g, sub in df.groupby("group"):
29         W, p = st.shapiro(sub[col].dropna())
30         rows.append({"group": g, "n": len(sub), "W": W, "p": p, "normal": p > ALPHA})
31     return pd.DataFrame(rows)
32
33
34 def variance_homogeneity(df: pd.DataFrame, col: str):
35     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
36     stat, p = st.levene(*groups, center="median")
37     return {"stat": float(stat), "p_value": float(p), "homogeneous": p > ALPHA}
38
39
40 def anova_with_tukey(df, col):
41     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
42     F, p = st.f_oneway(*groups)
43     all_vals = np.concatenate(groups)
44     N, k = len(all_vals), len(groups)
45     grand = all_vals.mean()
46     ss_b = sum(len(g) * (g.mean() - grand) ** 2 for g in groups)
47     ss_w = sum(((g - g.mean()) ** 2).sum() for g in groups)
48     ss_t = ss_b + ss_w
49     eta2 = ss_b / ss_t
50     ms_w = ss_w / (N - k)
51     omega2 = (ss_b - (k - 1) * ms_w) / (ss_t + ms_w)
52     tuk = pairwise_tukeyhsd(endog=df[col].values, groups=df["group"].values, alpha=ALPHA)
53     return {"test": "ANOVA", "F": float(F), "df_b": k - 1, "df_w": N - k,
```

```

54         "p_value": float(p), "eta_squared": float(eta2), "omega_squared": float(omega2)},
    tuk
55
56
57 def welch_anova_with_games_howell(df, col):
58     res = anova_oway(df[col].values, df["group"].values, use_var="unequal",
59                     welch_correction=True)
60     gh = sp.posthoc_games_howell(df, val_col=col, group_col="group")
61     return {"test": "Welch ANOVA", "F": float(res.statistic), "df_b": float(res.df_num),
62            "df_w": float(res.df_denom), "p_value": float(res.pvalue)}, gh
63
64 def kruskal_with_dunn(df, col):

```

2.5 Wyniki — zmienna główna: Sharpe Ratio

Założenia. Shapiro-Wilk: wszystkie cztery grupy spełniają normalność ($p > 0,05$). Levene: $\text{stat} = 1,25$; $p = 0,299$ — wariancje jednorodne. Decyzja: **ANOVA + Tukey HSD**.


ANOVA jednoczynnikowa. $F(3, 37) = 4,956$; $p = 0,00543$; $\eta^2 = 0,287$; $\omega^2 = 0,225$. Odrzucamy H_0 . Wartość $\omega^2 \approx 0,22$ wskazuje na duży efekt (próg 0,14 pochodzi z konwencji Cohena dla η^2 ; ω^2 traktujemy tu jako mniej obciążony estymator tej samej populacyjnej wielkości efektu).

Tukey HSD (FWER = 0,05). Różnica oznacza średnią grupy 1 minus średnią grupy 2.

Grupa 1	Grupa 2	różnica (1-2)	p_{adj}	95% CI	istotne
AI infra	AI platforms	+0,519	0,0076	[+0,113; +0,925]	tak
AI infra	Broad tech	+0,445	0,0269	[+0,039; +0,851]	tak
AI infra	Defensive	+0,424	0,0380	[+0,018; +0,829]	tak
AI platforms	Broad tech	-0,074	0,9633	[-0,489; +0,341]	nie
AI platforms	Defensive	-0,096	0,9253	[-0,511; +0,320]	nie
Broad tech	Defensive	-0,022	0,9990	[-0,437; +0,394]	nie

Najważniejszy wynik: AI infrastructure ma istotnie wyższy średni Sharpe Ratio niż każda z trzech pozostałych grup. Między AI platforms, Broad tech i Defensive nie widać istotnych różnic w parach.

Wykres — Sharpe per grupa.



2.6 Wyniki — zmienna uzupełniająca: CAPM alpha

Założenia. Wszystkie grupy spełniają normalność (Shapiro $p > 0,05$); Levene stat = 2,57; $p = 0,066$ — nieznacznie powyżej α , wariancje uznajemy za jednorodne. Decyzja: **ANOVA + Tukey HSD**.


ANOVA jednoczynnikowa. $F(3, 37) = 7,621$; $p = 4,3 \cdot 10^{-4}$; $\eta^2 = 0,382$; $\omega^2 = 0,326$. Odrzucamy H_0 z silnym efektem ($\omega^2 \approx 0,33$).

Tukey HSD (FWER = 0,05). Różnica oznacza średnią grupy 1 minus średnią grupy 2.


Grupa 1	Grupa 2	różnica α (1–2)	p_{adj}	95% CI	istotne
AI infra	AI platforms	+0,226	0,0004	[+0,089; +0,363]	tak
AI infra	Broad tech	+0,183	0,0049	[+0,046; +0,320]	tak
AI infra	Defensive	+0,108	0,1665	[−0,029; +0,245]	nie
AI platforms	Broad tech	−0,043	0,8450	[−0,183; +0,098]	nie
AI platforms	Defensive	−0,118	0,1247	[−0,259; +0,022]	nie
Broad tech	Defensive	−0,076	0,4791	[−0,216; +0,065]	nie

Najważniejszy wynik: Dla CAPM alpha przewaga AI infrastructure jest istotna względem AI platforms i Broad tech, ale nie względem Defensive. To sugeruje, że sama premia AI nie jest równomiernie rozłożona między wszystkie spółki technologiczne.

Wykres — CAPM alpha per grupa.



Forest plot — różnice metryk vs grupa Defensive.



2.7 Kontrola odporności — Kruskal-Wallis + Dunn

Ze względu na małe próby w grupach ($n = 10-11$) dodatkowo sprawdzono nieparametryczny odpowiednik analizy wariancji. Wyniki są spójne z ANOVA:

Zmienna	Kruskal H	p -value	Wniosek
Sharpe Ratio	12,880	0,0049	różnice między grupami istotne
CAPM alpha	13,971	0,0029	różnice między grupami istotne

Test Dunna z korektą Bonferroniego lokalizuje różnice podobnie jak Tukey: dla Sharpe istotne są pary AI infrastructure vs AI platforms ($p = 0,0104$), AI infrastructure vs Broad tech ($p = 0,0317$) oraz AI infrastructure vs Defensive ($p = 0,0424$). Dla CAPM alpha istotne są AI infrastructure vs AI platforms ($p = 0,0036$) oraz AI infrastructure vs Broad tech ($p = 0,0202$), natomiast różnica AI infrastructure vs Defensive pozostaje nieistotna ($p = 0,3445$).

Najważniejszy wynik: Nieparametryczna kontrola odporności potwierdza główną strukturę wniosków z ANOVA. Zadanie 2 jest więc silniejsze metodologicznie niż Zadania 1 i 3, ponieważ łączy ocenę relacji zysku do zmienności przez Sharpe Ratio z kontrolą ryzyka systematycznego przez CAPM alpha.

2.8 Interpretacja

- **Zmienna:** Sharpe Ratio (główna) oraz CAPM alpha (uzupełniająca) liczone per spółka na dziennych log-zwrotach 2021–2026; $n = 41$ spółek w 4 grupach.
- **Test zastosowany:** ANOVA + Tukey HSD (oba przypadki: założenia spełnione według testów formalnych) oraz kontrola nieparametryczna Kruskal-Wallis + Dunn.
- **Wynik (Sharpe):** $F(3, 37) = 4,96$; $p = 0,005$; $\omega^2 = 0,23$. Tukey lokalizuje różnice: AI infrastructure ma istotnie wyższy średni Sharpe Ratio niż każda z pozostałych grup; pozostałe trzy grupy nie różnią się między sobą.
- **Wynik (alpha):** $F(3, 37) = 7,62$; $p = 4,3 \cdot 10^{-4}$; $\omega^2 = 0,33$. AI infrastructure ma istotnie wyższą α niż AI platforms i Broad tech; różnica względem Defensive jest dodatnia, ale nie osiąga istotności statystycznej ($p = 0,17$). Defensive ma $\alpha \approx 0$, przy wyraźnie niższym poziomie ryzyka.

- **Decyzja statystyczna:** odrzucamy H_0 w obu testach.
- **Interpretacja ekonomiczna:** wyniki sugerują, że premia AI ma wyraźny charakter *sektorowy* (półprzewodniki i sprzęt) — platformy chmurowe (MSFT, GOOGL, AMZN itd.) nie wyróżniły się istotnie ani Sharpe Ratio, ani α względem reszty rynku. Jedną z możliwych interpretacji jest taka, że hyperscalerzy ponoszą wysokie nakłady inwestycyjne na infrastrukturę AI, natomiast dostawcy półprzewodników i sprzętu są jej bezpośrednimi beneficjentami przychodowymi.

Ograniczenie próby. Liczebności grup są niewielkie i nierówne (11 spółek w AI infrastructure oraz po 10 spółek w pozostałych grupach). Jest to próba dobrana *celowo* (reprezentatywne spółki z ekspozycją na dany typ ryzyka/tematu inwestycyjnego), a nie losowo z populacji. Wnioski statystyczne dotyczą analizowanej próby i okresu 2021–2026 — nie należy ich uogólniać na „cały rynek”. Dodatkowo grupy Broad tech i Defensive są sektorowo niejednorodne wewnętrznie, co zwiększa wariancję wewnątrzgrupową i tym samym zmniejsza moc testu.

3 Zadanie 3 — A/B testing na próbach zależnych wokół 30.11.2022

3.1 Opis zmiennych i schemat A/B

Zdarzenie: **publiczna premiera ChatGPT, 30.11.2022** — przyjęta jako data rozpoczęcia masowej fazy boomu generatywnej AI. Próba: 21 spółek z połączonej grupy „AI” = AI infrastructure $\cup$ AI platforms (11 + 10 = 21 spółek).

Dla każdej spółki i liczymy dwie wartości prostego zwrotu względem SPY:

- **Wariant A:** $\bar{S}_i^{(A)}$ — średni dzienny spread względem SPY w oknie K sesji *przed* 30.11.2022,
- **Wariant B:** $\bar{S}_i^{(B)}$ — średni dzienny spread względem SPY w oknie K sesji *po* 30.11.2022.

Jednostką pary jest *ta sama spółka*. Próby są więc zależne (paired). Statystyka testowa: $d_i = \bar{S}_i^{(B)} - \bar{S}_i^{(A)}$.

Ograniczenie doboru próby. Grupa zdarzeniowa została zdefiniowana z perspektywy projektu przygotowanego po boomie AI. Oznacza to ryzyko *look-ahead bias*: w zestawie znajdują się spółki rozpoznane już *ex post* jako beneficjenci trendu AI (np. infrastruktura GPU i serwerów). Test przed-po dla tak dobranej grupy może zawyżać efekt zdarzenia, bo analizuje częściowo historycznych zwycięzców, a nie portfel skonstruowany wyłącznie na podstawie informacji dostępnych 30.11.2022.

3.2 Hipotezy badawcze

- H_0 : $\mu_d = 0$ — średnia różnica spreadów względem SPY między wariantem B i A wynosi zero.
- H_1 : $\mu_d \neq 0$.

3.3 Procedura statystyczna

1. Test normalności różnic d_i (Shapiro-Wilk).
2. **Test główny:** paired t -test (jeśli różnice normalne).
3. **Test odporności:** Wilcoxon signed-rank (zawsze raportowany). W przypadku odrzucenia normalności Wilcoxon staje się testem głównym.
4. Wielkość efektu: Cohen’s $d_z = \bar{d}/s_d$; 95% przedział ufności dla $\bar{d}$ (rozkład t z $n - 1$ stopniami swobody).
5. **Analiza wrażliwości** na długość okna: $K \in \{30, 60, 120, 250\}$ sesji. Okno bazowe: $K = 120$ (6 miesięcy ekspozycji *ex post*).
6. **Placebo test:** cała procedura powtórzona dla daty 30.11.2021 (rok przed boomem AI). W dobrze wyspecyfikowanym modelu placebo powinno być nieistotne. Istotny wynik placebo interpretujemy jako ostrzeżenie, że prosty spread względem SPY nie usuwa trendów i różnic w ryzyku systematycznym.

3.4 Kod źródłowy (fragment)

```
1
2 ALPHA = 0.05
3 WINDOWS = [30, 60, 120, 250]
4 PRIMARY_WINDOW = 120
5
6
7 def select_windows(returns_idx: pd.DatetimeIndex, event: pd.Timestamp, k: int):
8     days = returns_idx[returns_idx != event]
9     before = days[days < event][-k:]
```

```

10     after = days[days > event][:k]
11     return before, after
12
13
14 def per_stock_paired(ar_df: pd.DataFrame, event: pd.Timestamp, k: int) -> pd.DataFrame:
15     before, after = select_windows(ar_df.index, event, k)
16     rows = []
17     for t in ar_df.columns:
18         mb = ar_df.loc[before, t].dropna().mean()
19         ma = ar_df.loc[after, t].dropna().mean()
20         rows.append({"ticker": t, "mean_A_before": mb, "mean_B_after": ma, "diff_B_minus_A": ma
21                     - mb})
22     df = pd.DataFrame(rows)
23     df["window_sessions"] = k
24     df.attrs["window_before"] = (before[0], before[-1]) if len(before) else None
25     df.attrs["window_after"] = (after[0], after[-1]) if len(after) else None
26     return df
27
28 def paired_summary(diffs: np.ndarray, alpha=ALPHA) -> dict:
29     diffs = np.asarray(diffs, dtype=float)
30     n = len(diffs)
31     mean_d = float(diffs.mean())
32     sd_d = float(diffs.std(ddof=1))
33     se_d = sd_d / np.sqrt(n)
34     W_sh, p_sh = st.shapiro(diffs)
35     t_crit = st.t.ppf(1 - alpha / 2, n - 1)
36     ci_low, ci_high = mean_d - t_crit * se_d, mean_d + t_crit * se_d
37     cohen_dz = mean_d / sd_d if sd_d > 0 else np.nan
38     t_stat, t_p = st.ttest_1samp(diffs, 0.0)
39     w_stat, w_p = st.wilcoxon(diffs, alternative="two-sided")
40     use_t = p_sh > alpha
41     main_test = "Paired t-test" if use_t else "Wilcoxon signed-rank"
42     main_stat = float(t_stat) if use_t else float(w_stat)
43     main_p = float(t_p) if use_t else float(w_p)
44     return {
45         "n": n, "mean_diff": mean_d, "sd_diff": sd_d, "se_diff": se_d,
46         "ci_low": ci_low, "ci_high": ci_high, "cohen_dz": cohen_dz,
47         "shapiro_W": float(W_sh), "shapiro_p": float(p_sh), "normal_diffs": bool(use_t),
48         "t_stat": float(t_stat), "t_p_value": float(t_p),
49         "wilcoxon_stat": float(w_stat), "wilcoxon_p_value": float(w_p),
50         "main_test": main_test, "main_stat": main_stat, "main_p_value": main_p,
51     }
52
53
54 def run_sensitivity(ar_df, event, windows, label):

```

3.5 Wyniki

Główny test — okno bazowe $K = 120$ sesji. Shapiro-Wilk: $W = 0,897$; $p = 0,0227$ — różnice odbiegają od rozkładu normalnego, więc testem głównym jest Wilcoxon, a paired t -test raportujemy jako wspierający.

$$\bar{d} = +0,00243; \quad 95\% \text{ CI: } [+0,00123; +0,00363]; \quad d_z = +0,92 \text{ (duży efekt);}$$

$$\text{Wilcoxon } p = 8,4 \cdot 10^{-5}; \quad \text{paired } t(20) = 4,11; \quad p = 4,2 \cdot 10^{-4}.$$


Oba testy zgodnie odrzucają H_0 .

Najważniejszy wynik: W oknie bazowym 120 sesji różnica po-przed jest dodatnia i istotna, ale istotny test placebo oznacza, że model referencyjny jest zbyt prosty. Wynik Zadania 3 jest sygnałem opisowym, nie mocnym dowodem event-study.


Pełna analiza wrażliwości + placebo.

Wariant	K	$\bar{d}$	95% CI	d_z	p (główny)	test
Event: 30.11.2022 (premiera ChatGPT)						
event	30	-0,00177	[-0,00502; +0,00149]	-0,25	0,2707	paired t
event	60	+0,00147	[-0,00024; +0,00317]	+0,39	0,0760	Wilcoxon
event	120	+0,00243	[+0,00123; +0,00363]	+0,92	$8,4 \cdot 10^{-5}$	Wilcoxon
event	250	+0,00231	[+0,00143; +0,00319]	+1,20	$< 10^{-4}$	paired t
Placebo: 30.11.2021 (rok przed boomem AI)						
placebo	30	-0,00385	[-0,00672; -0,00098]	-0,61	0,0110	paired t
placebo	60	-0,00290	[-0,00447; -0,00134]	-0,84	0,0010	paired t
placebo	120	-0,00260	[-0,00412; -0,00108]	-0,78	0,0020	paired t
placebo	250	-0,00156	[-0,00248; -0,00064]	-0,77	0,0021	paired t

Wykres — histogram różnic + sensitivity z placebo.



Event-window spread vs SPY — portfele EW per grupa wokół 30.11.2022.



3.6 Interpretacja

- **Zmienna:** $d_i = \bar{S}_i^{(B)} - \bar{S}_i^{(A)}$ dla $n = 21$ spółek z grupy AI; $\bar{S}$ to średni dzienny spread względem SPY w oknie K sesji.
- **Test zastosowany:** Wilcoxon signed-rank (główny, bo Shapiro odrzucił normalność dla okna 120) + paired t -test (wspierający).

- **Wynik (okno bazowe $K = 120$):** $\bar{d} = +0,243$ p.p. *dziennie*; 95% CI $[+0,123; +0,363]$ p.p.; $d_z = +0,92$ (duży efekt); Wilcoxon $p = 8,4 \cdot 10^{-5}$.
- **Decyzja statystyczna:** odrzucamy H_0 z wysokim marginesem dla okien 120 i 250 sesji. Brak istotności dla okna 30 sesji i istotność dla dłuższych okien sugerują, że dodatni efekt w danych rozwijał się stopniowo, ale przy obecnej specyfikacji nie można rozstrzygnąć, czy wynikał z samego zdarzenia, zmiany reżimu rynkowego, czy innych czynników technologicznych.
- **Placebo:** dla 30.11.2021 efekt jest *ujemny i istotny* we wszystkich oknach. Nie wzmacnia to interpretacji przyczynowej. Przeciwnie: falsyfikuje prostą specyfikację spreadów względem SPY i pokazuje, że metoda przed-po wychwytyje także silne trendy rynkowe, np. spadki technologii w okresie 2021/2022.
- **Interpretacja ekonomiczna:** po publicznej premierze ChatGPT spółki z grupy AI generowały średnio o ok. 0,24 p.p. *dziennie* wyższy spread względem SPY niż w analogicznym oknie przed premierą. Prosta annualizacja tej średniej ($0,243\% \times 252$) daje ok. 61 p.p. rocznie. Ponieważ operujemy na log-zwrotach, taka liniowa agregacja jest matematycznie spójna jako przybliżenie addytywne. Nie należy jej jednak czytać jako prognozy ani jako oczekiwanej rocznej stopy zwrotu; to historyczny, lokalny efekt w bardzo specyficznym oknie.

Ograniczenia. Analiza ma charakter *uproszczonego testu A/B przed-po*: nie modeluje oczekiwanego abnormal returnu względem CAPM ani modelu czynnikowego (Fama-French 3/5 czynników); raportujemy jedynie spready względem SPY. Istotny wynik placebo oraz dobór grupy zdarzeniowej ex post istotnie ograniczają siłę wnioskowania.

Uwaga interpretacyjna: Po uwzględnieniu testu placebo wniosek z Zadania 3 musi być sceptyczny: dodatni efekt po 30.11.2022 istnieje w danych, ale prosta specyfikacja nie pozwala przypisać go jednoznacznie premierze ChatGPT ani „czystej” premii AI.

3.7 Dodatkowa kontrola odporności — CAPM-adjusted returns

Jako minimalną kontrolę problemu $\beta \neq 1$ przeliczono kluczowe wyniki po korekcie CAPM. Dla portfeli i spółek estymowano betę na danych *przed* analizowaną datą: dla eventu przed 30.11.2022, a dla placebo przed 30.11.2021, aby ograniczyć look-ahead bias w samej korekcie. Dzienny komponent skorygowany liczono jako:

$$AR_t^{CAPM} = (r_t - r_{f,t}) - \hat{\beta}_{pre} (r_t^{SPY} - r_{f,t}).$$

Korekta CAPM zakłada zerową alfę w modelu CAPM; nie jest to pełny market model z estymowanym interceptem. Nie jest to także event study z modelem wieloczynnikowym, ale pozwala sprawdzić, czy podstawowe wnioski przetrwają najprostszą korektę o ryzyko systematyczne.

Analiza	Metryka	Spread vs SPY	CAPM-adjusted
Zad. 1	różnica średnich	+3,73 p.p./mies.	+2,23 p.p./mies.
Zad. 1	p -value	0,0079	0,0685
Zad. 3 event $K = 120$	mean_d	+0,243 p.p./dzień	+0,225 p.p./dzień
Zad. 3 event $K = 120$	95% CI	$[+0,123; +0,363]$	$[+0,107; +0,342]$
Zad. 3 event $K = 120$	d_z	+0,921	+0,871
Zad. 3 event $K = 120$	p -value / test	$8,4 \cdot 10^{-5}$ / Wilcoxon	$1,6 \cdot 10^{-4}$ / Wilcoxon
Zad. 3 placebo $K = 120$	mean_d	−0,260 p.p./dzień	−0,162 p.p./dzień
Zad. 3 placebo $K = 120$	95% CI	$[-0,412; -0,108]$	$[-0,309; -0,015]$
Zad. 3 placebo $K = 120$	d_z	−0,777	−0,501
Zad. 3 placebo $K = 120$	p -value / test	0,0020 / paired t	0,0327 / paired t

W Zadaniu 1 korekta CAPM istotnie osłabia wynik: różnica pozostaje dodatnia, ale przy $\alpha = 0,05$ nie jest już statystycznie istotna. To potwierdza, że część prostego spreadu względem SPY była związana z wysoką betą portfela AI infrastructure. W Zadaniu 3 wynik pozostaje dodatni i istotny także po korekcie CAPM. Jednocześnie CAPM-adjusted placebo nadal jest istotne statystycznie ($p = 0,0327$), choć słabsze niż placebo na prostym spreadzie. Oznacza to, że korekta CAPM nie wystarcza do usunięcia problemu placebo: metoda nadal wychwytyuje reżimy rynkowe/trendy, więc nie pozwala na mocne wnioskowanie przyczynowe. Nadal obowiązują wcześniejsze zastrzeżenia: look-ahead bias w doborze spółek, model jednoczynnikowy oraz brak pełnego modelu Fama-French / market model z interceptem.

Wnioski końcowe i decyzja inwestora

Wnioski statystyczne po korekcie metodologicznej.

- **Zad 1.** Welch t-test odrzuca H_0 ($p = 0,0079$, Hedges' $g = 0,59$): portfel AI infrastructure ma istotnie wyższą średnią miesięczną nadwyżkę względem SPY niż portfel Defensive po 30.11.2022 (+3,7 p.p./miesiąc). Jest to jednak wynik obciążony różnicą bet: AI infrastructure ma dużo wyższą ekspozycję rynkową niż Defensive. Po korekcie CAPM różnica spada do +2,23 p.p./miesiąc i nie jest już istotna na poziomie 5% ($p = 0,0685$).
- **Zad 2.** ANOVA odrzuca H_0 dla obu zmiennych: Sharpe ($F = 4,96$; $p = 0,005$; $\omega^2 = 0,23$) i CAPM α ($F = 7,62$; $p = 4 \cdot 10^{-4}$; $\omega^2 = 0,33$). Dla Sharpe Tukey wskazuje istotną przewagę AI infrastructure nad wszystkimi pozostałymi grupami; dla CAPM α przewaga AI infrastructure jest istotna względem AI platforms i Broad tech, ale nie względem Defensive. Kontrola Kruskal-Wallis + Dunn potwierdza ten układ wyników.
- **Zad 3.** Wilcoxon ($K = 120$): $p = 8,4 \cdot 10^{-5}$; $\bar{d} = +0,24$ p.p./dzień; 95% CI [+0,12; +0,36] p.p.; $d_z = +0,92$. Jednocześnie placebo test jest istotny statystycznie w przeciwnym kierunku, co jest sygnałem błędnej specyfikacji, a nie argumentem wzmacniającym przyczynowość. CAPM-adjusted robustness pozostaje dodatni i istotny ($\bar{d} \approx +0,225$ p.p./dzień, $p \approx 1,6 \cdot 10^{-4}$), ale CAPM-adjusted placebo również pozostaje istotne ($\bar{d} \approx -0,162$ p.p./dzień, $p \approx 0,0327$). Wynik jest spójny z hipotezą, ale jego interpretacja zależy od kontroli placebo i specyfikacji modelu.

Werdykt metodologiczny.

- Raport pokazuje silną historyczną przewagę spółek infrastruktury AI, ale nie dowodzi jednoznacznie istnienia czystej *AI Boom Premium* po kontroli wszystkich czynników ryzyka.
- Najbardziej wiarygodna część badania to Zadanie 2, ponieważ łączy ocenę relacji zysku do zmienności przez Sharpe Ratio z kontrolą ryzyka systematycznego przez CAPM α oraz przechodzi dodatkową kontrolę nieparametryczną.
- Zadania 1 i 3 należy traktować jako analizę opisową spreadów względem SPY. Ich wyniki są informacyjne, ale metodologicznie słabsze przez ukryte założenie $\beta = 1$, istotne placebo oraz look-ahead bias. Mini-kontrola CAPM pokazuje, że Zad. 1 jest wrażliwe na korektę bety, natomiast Zad. 3 zachowuje dodatni efekt mimo tej korekty. Ponieważ CAPM-adjusted placebo także jest istotne, nie traktujemy wyniku jako dowodu przyczynowego wpływu premiery ChatGPT.
- Praktyczny take-away dla inwestora jest ostrożny: segment AI infrastructure był historycznie bardzo silny, ale przewaga była związana z wysoką zmiennością, wysoką betą i dużymi obsunięciami. Sama wielkość zwrotu nie uzasadnia dużej alokacji bez kontroli ryzyka.

Reproducibility note

Środowisko. Analizy wykonano w Pythonie. Dokładne wersje bibliotek należy utrzymywać automatycznie w pliku `requirements.txt` lub przez `pip freeze`, zamiast przepisywać je ręcznie do raportu. Kluczowe pakiety: `pandas`, `numpy`, `scipy`, `statsmodels`, `scikit-posthocs`, `matplotlib`, `seaborn`, `yfinance`, `pyarrow`.

Dane. Źródło: Yahoo Finance via `yfinance`. Pobranie: 2026-05-20. Cache lokalny: `data_cache/prices.parquet` (43 tickery $\times$ 1347 dni sesyjnych). Mapowanie ticker $\rightarrow$ grupa: `data_cache/metadata_tickers.csv`.

Skrypty (kolejność wykonania).

1. `src/data_fetch.py` — pobranie i zapis do `parquet`.

2. `src/task1_two_portfolios.py` — Zadanie 1.
3. `src/task2_four_groups.py` — Zadanie 2 (Sharpe i alpha).
4. `src/task3_paired_event.py` — Zadanie 3 (event + placebo).
5. `src/plots_extra.py` — wykresy zaawansowane.

Moduły wspólne: `src/common.py` (wczytywanie, log returns, portfele EW, spready względem SPY, RF), `src/metrics.py` (7 metryk per spółka), `src/plot_utils.py` (style i zapis wykresów).

Ziarno losowe. Bootstrap w Zad. 1 używa `numpy.random.default_rng(seed=42)` i $B = 10\,000$ powtórzeń. Pozostałe analizy są deterministyczne.


Repozytorium. github.com/Smalou/metody_badania_w_finansach — pełny kod, dane cache i źródło LaTeX dostępne publicznie.

Limitations

- **Selection bias / próby celowe.** Wszystkie cztery grupy spółek dobrane są ręcznie na bazie eksperckiej oceny ekspozycji na AI — nie są losowymi próbami z populacji. Wnioski dotyczą tej konkretnej próby.
- **Look-ahead bias.** Skład grup, szczególnie AI infrastructure i grupa eventowa w Zadaniu 3, powstał z perspektywy 2026 roku. Oznacza to ryzyko, że do analizy trafiły spółki rozpoznane ex post jako zwycięzcy boomu AI.
- **Niejednorodność wewnątrzgrupowa.** Grupy Broad tech i Defensive zawierają spółki o zróżnicowanych modelach biznesowych, co zwiększa wewnętrzną wariancję metryk.
- **Założenie $\beta = 1$ w Zad. 1 i 3.** Zwroty względne liczone są jako prosty spread względem SPY. To jest równoważne założeniu, że beta portfela względem rynku wynosi 1. W danych beta AI infrastructure jest dużo wyższa niż beta Defensive, więc część wyniku może być premią za ryzyko systematyczne.
- **Single-factor benchmark.** Nie kontrolujemy ekspozycji na czynniki Fama-French (HML, SMB, momentum), czynniki sektorowe ani model oczekiwanego zwrotu estymowany w oknie przed zdarzeniem.
- **Istotny test placebo.** Placebo 30.11.2021 daje istotne wyniki, co wskazuje, że prosta metoda przed-po nie usuwa trendów rynkowych. To osłabia interpretację przyczynową Zadania 3.
- **Małe próby w Zad. 2.** Grupy mają tylko 10–11 obserwacji. Testy normalności mają niską moc, dlatego wyniki ANOVA uzupełniono kontrolą nieparametryczną Kruskal-Wallis + Dunn.
- **Definicja zdarzenia.** Premiera ChatGPT (30.11.2022) jest symbolicznym punktem startu boomu AI, ale realna fala kapitałowa następowała stopniowo przez kolejne 6–12 miesięcy. Stąd wrażliwość wyników Zad. 3 na długość okna.
- **Częściowy ostatni miesiąc.** W Zad. 1 maj 2026 jest miesiącem częściowym. Nie zmienia to głównej logiki testu, ale w wersji produkcyjnej warto dodać wariant z wykluczeniem niepełnego miesiąca.
- **Dane yfinance.** Ceny są korygowane wstecznie (split, dywidenda); dostawca może okresowo modyfikować historyczne wartości. Cache lokalny zapewnia reprodukowalność tej analizy, ale ponowne pobranie może dać minimalnie inne wyniki.
- **Spojrzenie ex-post.** Cały kierunek hipotezy („AI Premium”) jest motywowany obserwacjami z lat 2023–2025. Test jest confirmacyjny, nie predykcyjny.


Dodatek — wykresy uzupełniające

Heatmapa korelacji dziennych log-zwrotów.



Wizualnie widoczne są bloki wysokiej korelacji wewnątrz grup AI (infra, platforms) oraz niska korelacja grupy Defensive z technologiami.

Rolling annualized volatility (okno 63 sesji).



AI infrastructure utrzymuje najwyższy poziom zmienności w całym okresie, ze szczytami wokół wybuchu AI capex 2023 i fazy korekt 2024–2025.

Bibliografia

1. Sharpe, W. F. (1994). The Sharpe Ratio. *The Journal of Portfolio Management*, 21(1), 49–58.
2. Sortino, F. A., & Price, L. N. (1994). Performance measurement in a downside risk framework. *Journal of Investing*, 3(3), 59–64.
3. Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35.
4. Games, P. A., & Howell, J. F. (1976). Pairwise multiple comparison procedures with unequal N ’s and/or variances. *Journal of Educational Statistics*, 1(2), 113–125.
5. Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed., Lawrence Erlbaum Associates.
6. Hedges, L. V. (1981). Distribution theory for Glass’s estimator of effect size and related estimators. *Journal of Educational Statistics*, 6(2), 107–128.
7. MacKinlay, A. C. (1997). Event Studies in Economics and Finance. *Journal of Economic Literature*, 35(1), 13–39.
8. Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
9. OpenAI (2022). *Introducing ChatGPT*, <https://openai.com/index/chatgpt/>.
10. Yahoo Finance / yfinance — dokumentacja API, <https://github.com/ranaroussi/yfinance>.