

AI Boom Premium

Czy spółki silnie powiązane z infrastrukturą AI osiągnęły wyższe średnie zwroty i lepszy profil ryzyko-zwrot po rozpoczęciu boomu generatywnej AI?

Projekt zaliczeniowy IAD — Metody Badań w Finansach, ćwiczenia 3

Roksana Kulawiec (454474)

Sylwia Malinowska (487648)

Mateusz Konopka (487528)

Antoni Grabowski (452622)

20 maja 2026

Repozytorium kodu i danych

github.com/Smalou/metody_badania_w_finansach

Wszystkie skrypty Pythona, cache danych (parquet/csv), wygenerowane wykresy i źródło niniejszego raportu LaTeX są dostępne w powyższym repozytorium.

Streszczenie dla czytelnika

Raport sprawdza, czy po premierze ChatGPT spółki infrastruktury AI osiągały wyższe zwroty ponad benchmark SPY i lepszy profil ryzyko-zwrot niż grupy kontrolne. Wszystkie trzy zadania wskazują na przewagę segmentu **AI infrastructure**, ale wyniki są historyczne, ex post i nie stanowią prognozy przyszłych stóp zwrotu.

Spis treści

1	Zadanie 1 — AI infrastructure vs Defensive: miesięczne abnormal returns	5
1.1	Opis zmiennych	5
1.2	Hipotezy badawcze	5
1.3	Procedura statystyczna	5
1.4	Kod źródłowy (fragment)	5
1.5	Wyniki	6
1.6	Interpretacja	7
2	Zadanie 2 — Metryki efektywności w czterech grupach spółek	8
2.1	Opis zmiennych	8
2.2	Hipotezy badawcze	8
2.3	Procedura statystyczna — drzewo decyzyjne	8
2.4	Kod źródłowy (fragment)	9
2.5	Wyniki — zmienna główna: Sharpe Ratio	10
2.6	Wyniki — zmienna uzupełniająca: CAPM alpha	10
2.7	Interpretacja	12
3	Zadanie 3 — A/B testing na próbach zależnych wokół 30.11.2022	13
3.1	Opis zmiennych i schemat A/B	13
3.2	Hipotezy badawcze	13
3.3	Procedura statystyczna	13
3.4	Kod źródłowy (fragment)	13

3.5	Wyniki	14
3.6	Interpretacja	15

Wprowadzenie i hipoteza projektowa

W projekcie przyjęto premierę ChatGPT (30 listopada 2022) jako symboliczny punkt startu masowej fazy boomu generatywnej AI. W kolejnych kwartałach temat AI stał się jednym z głównych motywów inwestycyjnych na rynku amerykańskim, szczególnie w segmencie półprzewodników, infrastruktury obliczeniowej i usług chmurowych. Niniejszy projekt sprawdza empirycznie, czy po tej dacie wystąpiły mierzalne różnice w średnich zwrotach oraz profilu ryzyko–zwrot między spółkami o różnym stopniu ekspozycji na sztuczną inteligencję. Analiza ma charakter statystyczny i porównawczy; nie jest dowodem przyczynowym w ścisłym sensie ekonometrycznym.

Główna teza. *Spółki silnie powiązane z infrastrukturą AI (producenci półprzewodników i sprzętu) osiągnęły po 30.11.2022 istotnie wyższe średnie zwroty względem benchmarku rynkowego (SPY) oraz lepszy profil ryzyko–zwrot niż grupy kontrolne (Defensive, Broad Tech, AI Platforms).*

Trzy zadania spójne tematycznie.


- **Zadanie 1** — porównanie średnich miesięcznych *abnormal returns* (AR względem SPY) portfela AI infrastructure i portfela Defensive control *po* rozpoczęciu boomu (próby niezależne).
- **Zadanie 2** — porównanie średnich metryk efektywności ryzyko–zwrot (*Sharpe Ratio* jako zmienna główna, *CAPM alpha* jako uzupełnienie) między czterema grupami spółek.
- **Zadanie 3** — A/B testing na próbach zależnych: średnie dzienne AR tej samej spółki w oknie przed (wariant A) i po (wariant B) 30.11.2022, z analizą wrażliwości na długość okna i *placebo test*.

Dane. Źródło: Yahoo Finance przez bibliotekę `yfinance`. 41 spółek notowanych na NYSE/NASDAQ podzielonych na cztery grupy (definicje w `data_cache/metadata_tickers.csv`) plus benchmark SPY i stopa wolna od ryzyka $\sim$ IRX (13-tygodniowy T-bill). Okres: 04.01.2021–14.05.2026 (1347 dni sesyjnych). Ceny skorygowane (`auto_adjust=True`), brak braków danych.

Grupy spółek (11+10+10+10 = 41).

- **AI infrastructure / półprzewodniki (11):** NVDA, AMD, AVGO, TSM, ASML, AMAT, LRCX, KLAC, MU, MRVL, SMCI.
- **AI platforms / cloud / software (10):** MSFT, GOOGL, AMZN, META, ORCL, CRM, NOW, ADBE, IBM, SNOW.
- **Broad technology control (10):** AAPL, CSCO, INTC, TXN, QCOM, INTU, ACN, PANW, CDNS, ADSK.
- **Defensive control (10):** KO, PEP, PG, WMT, JNJ, MRK, MCD, COST, CL, GIS.

Kontekst graficzny — skumulowane abnormal returns per grupa. Poniższy wykres przedstawia skumulowany dzienny abnormal return portfela równoważonego (EW) każdej grupy względem SPY. Pionowa linia oznacza moment zdarzenia 30.11.2022.



Widoczne jest wyraźne rozejście trajektorii AI infrastructure od pozostałych grup po listopadzie 2022. Wykres pełni jednak wyłącznie funkcję diagnostyczną i opisową; formalne wnioski oparto na testach statystycznych, wielkościach efektu i analizach odporności przedstawionych w trzech zadaniach poniżej.

Uwaga interpretacyjna: Wykres skumulowanych AR pomaga zrozumieć kontekst, ale nie zastępuje testów statystycznych. Formalne decyzje w raporcie opierają się na testach, przedziałach ufności i wielkościach efektu.

1 Zadanie 1 — AI infrastructure vs Defensive: miesięczne abnormal returns

1.1 Opis zmiennych

Dla każdej grupy zbudowano portfel równoważony (EW). Dzienna stopa zwrotu portfela:

$$r_t^{\text{port}} = \frac{1}{N} \sum_{i=1}^N r_{i,t},$$

gdzie $r_{i,t}$ to dzienna log-stopa zwrotu spółki i . Następnie:

- agregacja miesięczna: $r_m^{\text{port}} = \sum_{t \in m} r_t^{\text{port}}$ (suma log-zwrotów, ekwiwalentnie miesięczny log-zwrot);
- *abnormal return*: $AR_m^{\text{port}} = r_m^{\text{port}} - r_m^{\text{SPY}}$;
- filtracja czasowa: tylko obserwacje po 30.11.2022.
Porównywane zmienne (próby niezależne, $n_1 = n_2 = 42$ miesiące):
- X : miesięczne AR portfela **AI infrastructure** (11 spółek),
- Y : miesięczne AR portfela **Defensive control** (10 spółek).

Ostatni miesiąc w próbie (maj 2026) jest miesiącem częściowym ze względu na datę pobrania danych. W głównym wyniku zachowano go dla zgodności z cache danych; w praktycznej analizie inwestycyjnej warto dodatkowo sprawdzić wariant z jego wykluczeniem.

1.2 Hipotezy badawcze

- H_0 : średnie miesięczne AR obu portfeli są równe, $\mu_{AR, AI} = \mu_{AR, Def}$.
- H_1 : średnie różnią się, $\mu_{AR, AI} \neq \mu_{AR, Def}$.

1.3 Procedura statystyczna

1. Sprawdzenie założeń: Shapiro-Wilk (normalność) + Levene (homogeniczność wariancji).
2. **Test główny**: *Welch t-test* dla dwóch prób niezależnych (bez założenia równych wariancji).
3. **Analiza odporności**: bootstrap ($B = 10\,000$, ziarno 42) 95% przedziału ufności różnicy średnich.
4. Wielkość efektu: *Hedges' g* (poprawiona Cohen's d dla małych prób).
5. **Test pomocniczy**: Mann-Whitney U — różnica w położeniu rozkładów (*nie* test średnich, dla kompletności).

1.4 Kod źródłowy (fragment)

```
1
2
3 def hedges_g(x, y):
4     n1, n2 = len(x), len(y)
5     s1, s2 = x.std(ddof=1), y.std(ddof=1)
6     sp = np.sqrt(((n1 - 1) * s1 ** 2 + (n2 - 1) * s2 ** 2) / (n1 + n2 - 2))
7     d = (x.mean() - y.mean()) / sp
8     J = 1 - 3 / (4 * (n1 + n2) - 9)
9     return float(d * J)
10
11
```

```

12 def welch_with_ci(x, y, alpha=ALPHA):
13     n1, n2 = len(x), len(y)
14     m1, m2 = float(x.mean()), float(y.mean())
15     v1, v2 = float(x.var(ddof=1)), float(y.var(ddof=1))
16     diff = m1 - m2
17     se = np.sqrt(v1 / n1 + v2 / n2)
18     df = (v1 / n1 + v2 / n2) ** 2 / ((v1 / n1) ** 2 / (n1 - 1) + (v2 / n2) ** 2 / (n2 - 1))
19     t_stat = diff / se
20     p = 2 * (1 - st.t.cdf(abs(t_stat), df))
21     t_crit = st.t.ppf(1 - alpha / 2, df)
22     return {
23         "t": float(t_stat), "df": float(df), "p_value": float(p),
24         "mean_x": m1, "mean_y": m2, "mean_diff": diff, "se_diff": float(se),
25         "ci_low": float(diff - t_crit * se), "ci_high": float(diff + t_crit * se),
26     }
27
28
29 def bootstrap_ci_diff(x, y, n_boot=N_BOOT, alpha=ALPHA, seed=SEED):
30     rng = np.random.default_rng(seed)
31     xa, ya = np.asarray(x), np.asarray(y)
32     n1, n2 = len(xa), len(ya)
33     boot = np.empty(n_boot)
34     for i in range(n_boot):
35         boot[i] = rng.choice(xa, size=n1, replace=True).mean() - rng.choice(ya, size=n2,
36                                     replace=True).mean()
37     lo, hi = np.percentile(boot, [100 * alpha / 2, 100 * (1 - alpha / 2)])
38     return {"boot_mean_diff": float(boot.mean()), "boot_ci_low": float(lo),
39             "boot_ci_high": float(hi), "n_boot": n_boot}
40
41 def main():
42     prices = load_prices()
43     meta = load_metadata()

```

1.5 Wyniki

Statystyki opisowe.

Portfel	n	średnia AR_m	odch. std.
AI infrastructure	42	0,02638	0,07774
Defensive control	42	-0,01089	0,04133

Założenia.


- Shapiro-Wilk AI infra: $W = 0,956$; $p = 0,1053$ (rozkład zbliżony do normalnego);
- Shapiro-Wilk Defensive: $W = 0,987$; $p = 0,9141$ (rozkład zbliżony do normalnego);
- Levene (median): stat = 13,23; $p = 0,0005$ (wariancje istotnie różne $\rightarrow$ uzasadnia *Welch*, a nie klasyczny *t*-Student).

Test główny — Welch t-test, bootstrap i Mann-Whitney.

Test	wartość	uwaga
Welch t ($df \approx 62,5$)	2,744	
p -value	0,00792	odrzućenie H_0
Różnica średnich ($\bar{X} - \bar{Y}$)	+0,03728	na korzyść AI infra
95% CI (Welch)	[+0,01012; +0,06443]	nie zawiera 0
Hedges' g	+0,593	umiarkowany efekt
95% CI bootstrap ($B = 10\,000$)	[+0,01199; +0,06365]	spójne z Welch
Mann-Whitney U (pomocniczy)	1122,0	różnica w położeniu rozkładów
p -value (M-W)	0,0321	spójne z H_1

Najważniejszy wynik: Portfel AI infrastructure miał średnio o +3,73 p.p. miesięcznie wyższy abnormal return niż portfel Defensive, a 95% przedziały ufności nie obejmują zera.

Wykres rozkładów.



1.6 Interpretacja

- **Zmienna:** miesięczny abnormal return portfela EW vs SPY, $n = 42$ miesięcy (12.2022–05.2026).
- **Test zastosowany:** Welch t -test (główny) + bootstrap (odporność) + Mann-Whitney U (pomocniczy).
- **Wynik:** $p = 0,0079$; $\bar{X} - \bar{Y} = +3,73$ p.p. miesięcznie; 95% CI Welch [+1,01; +6,44] p.p.; Hedges' $g = 0,59$. Bootstrap CI praktycznie pokrywa się z Welch.
- **Decyzja statystyczna:** odrzucamy H_0 przy $\alpha = 0,05$.
- **Interpretacja ekonomiczna:** w okresie 42 miesięcy po premierze ChatGPT portfel AI infrastructure dostarczył średnio ok. 3,7 p.p. *na miesiąc* wyższego abnormal returnu względem SPY niż portfel defensywny. Wynik jest spójny z hipotezą *AI Boom Premium*, choć wyższa zmienność portfela AI ($\sigma = 7,8\%$) wskazuje, że premia ta wiąże się z istotnie większym ryzykiem (do oceny w Zadaniu 2).

Uwaga interpretacyjna: Wynik z Zadania 1 pokazuje istotną różnicę średnich AR, ale portfel AI infrastructure miał też wyraźnie wyższą zmienność. Dlatego sama premia zwrotu nie wystarcza do decyzji inwestycyjnej bez oceny ryzyka.

2 Zadanie 2 — Metryki efektywności w czterech grupach spółek

2.1 Opis zmiennych

Dla każdej z 41 spółek obliczono komplet 7 metryk na bazie dziennych log-zwrotów za cały okres 04.01.2021–14.05.2026:

- *Annualized return* $= \bar{r}_t \cdot 252$,
- *Annualized volatility* $= s(r_t) \cdot \sqrt{252}$,
- *Sharpe Ratio* $= (\bar{r}_t - r_f) / s(r_t - r_f) \cdot \sqrt{252}$,
- *Sortino Ratio* (downside deviation względem $MAR = 0$),
- *Maximum drawdown* liczony na wealth-curve $\exp(\sum r_t)$,
- *CAPM beta* z regresji nadwyżkowych zwrotów na SPY,
- *CAPM alpha* (annualized).

Główna zmienna testowana : **Sharpe Ratio** (najszerzej akceptowana miara ryzyko–zwrot w finansach). Dla kompletności — równolegle ten sam test przeprowadzono dla **CAPM alpha**, bezpośrednio mierzącego „nadwyżkę po kontroli ryzyka systematycznego” i najbliższego pojęciu *AI Premium*.

Statystyki opisowe (średnie metryk per grupa).

Grupa	Ann. ret	Ann. vol	Sharpe	Sortino	Max DD	alpha
AI infrastructure	0,362	0,501	0,674	0,684	−0,584	+0,119
AI platforms	0,072	0,374	0,154	0,159	−0,567	−0,107
Broad tech	0,111	0,349	0,228	0,228	−0,452	−0,064
Defensive	0,082	0,192	0,250	0,244	−0,297	+0,011

2.2 Hipotezy badawcze

- H_0 : średnie Sharpe Ratio (alpha) są równe we wszystkich czterech grupach.
- H_1 : co najmniej jedna grupa ma średnią różną od pozostałych.

2.3 Procedura statystyczna — drzewo decyzyjne

1. Shapiro-Wilk per grupa → czy rozkłady normalne?
2. Levene (median) → czy wariancje jednorodne?
3. Decyzja:
 - normalne + jednorodne → **ANOVA** + Tukey HSD,
 - normalne + nierówne wariancje → **Welch ANOVA** + Games-Howell,
 - nienormalne → **Kruskal-Wallis** + Dunn (Bonferroni).
4. Wielkość efektu: η^2 i ω^2 (mniej obciążone dla małych prób).

2.4 Kod źródłowy (fragment)

```
1 from common import CACHE, BENCHMARK, load_prices, load_metadata, log_returns, daily_rf
2 from metrics import compute_all_metrics
3 from plot_utils import setup_style, savefig
4
5 ALPHA = 0.05
6 GROUP_ORDER = ["AI_infra", "AI_platforms", "Broad_tech", "Defensive"]
7 GROUP_PAL = {
8     "AI_infra": "#1f77b4",
9     "AI_platforms": "#9467bd",
10    "Broad_tech": "#2ca02c",
11    "Defensive": "#d62728",
12 }
13
14
15 def compute_metrics_df(prices, meta) -> pd.DataFrame:
16     rets = log_returns(prices)
17     rf_d = daily_rf(prices)
18     bench = rets[BENCHMARK]
19     frames = []
20     for g in GROUP_ORDER:
21         tickers = meta.loc[meta["group"] == g, "ticker"].tolist()
22         frames.append(compute_all_metrics(rets, bench, rf_d, tickers, g))
23     return pd.concat(frames, ignore_index=True)
24
25
26 def normality_per_group(df: pd.DataFrame, col: str) -> pd.DataFrame:
27     rows = []
28     for g, sub in df.groupby("group"):
29         W, p = st.shapiro(sub[col].dropna())
30         rows.append({"group": g, "n": len(sub), "W": W, "p": p, "normal": p > ALPHA})
31     return pd.DataFrame(rows)
32
33
34 def variance_homogeneity(df: pd.DataFrame, col: str):
35     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
36     stat, p = st.levene(*groups, center="median")
37     return {"stat": float(stat), "p_value": float(p), "homogeneous": p > ALPHA}
38
39
40 def anova_with_tukey(df, col):
41     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
42     F, p = st.f_oneway(*groups)
43     all_vals = np.concatenate(groups)
44     N, k = len(all_vals), len(groups)
45     grand = all_vals.mean()
46     ss_b = sum(len(g) * (g.mean() - grand) ** 2 for g in groups)
47     ss_w = sum(((g - g.mean()) ** 2).sum() for g in groups)
48     ss_t = ss_b + ss_w
49     eta2 = ss_b / ss_t
50     ms_w = ss_w / (N - k)
51     omega2 = (ss_b - (k - 1) * ms_w) / (ss_t + ms_w)
52     tuk = pairwise_tukeyhsd(endog=df[col].values, groups=df["group"].values, alpha=ALPHA)
53     return {"test": "ANOVA", "F": float(F), "df_b": k - 1, "df_w": N - k,
54           "p_value": float(p), "eta_squared": float(eta2), "omega_squared": float(omega2)},
55     tuk
56
57 def welch_anova_with_games_howell(df, col):
58     res = anova_oneway(df[col].values, df["group"].values, use_var="unequal",
59                       welch_correction=True)
60     gh = sp.posthoc_games_howell(df, val_col=col, group_col="group")
61     return {"test": "Welch ANOVA", "F": float(res.statistic), "df_b": float(res.df_num),
```

```

61         "df_w": float(res.df_denom), "p_value": float(res.pvalue)}, gh
62
63
64 def kruskal_with_dunn(df, col):

```

2.5 Wyniki — zmienna główna: Sharpe Ratio

Założenia. Shapiro-Wilk: wszystkie cztery grupy spełniają normalność ($p > 0,05$). Levene: $\text{stat} = 1,25$; $p = 0,299$ — wariacje jednorodne. Decyzja: **ANOVA + Tukey HSD**.


ANOVA jednoczynnikowa. $F(3, 37) = 4,956$; $p = 0,00543$; $\eta^2 = 0,287$; $\omega^2 = 0,225$. Odrzucamy H_0 . Wartość $\omega^2 \approx 0,22$ wskazuje na duży efekt (konwencja Cohena: $\omega^2 \geq 0,14$ duży).

Tukey HSD (FWER = 0,05). Różnica oznacza średnią grupy 1 minus średnią grupy 2.

Grupa 1	Grupa 2	różnica (1-2)	p_{adj}	95% CI	istotne
AI infra	AI platforms	+0,519	0,0076	[+0,113; +0,925]	tak
AI infra	Broad tech	+0,445	0,0269	[+0,039; +0,851]	tak
AI infra	Defensive	+0,424	0,0380	[+0,018; +0,829]	tak
AI platforms	Broad tech	-0,074	0,9633	[-0,489; +0,341]	nie
AI platforms	Defensive	-0,096	0,9253	[-0,511; +0,320]	nie
Broad tech	Defensive	-0,022	0,9990	[-0,437; +0,394]	nie

Najważniejszy wynik: AI infrastructure ma istotnie wyższy średni Sharpe Ratio niż każda z trzech pozostałych grup. Między AI platforms, Broad tech i Defensive nie widać istotnych różnic w parach.

Wykres — Sharpe per grupa.



2.6 Wyniki — zmienna uzupełniająca: CAPM alpha

Założenia. Wszystkie grupy spełniają normalność (Shapiro $p > 0,05$); Levene $\text{stat} = 2,57$; $p = 0,066$ — nieznacznie powyżej α , wariacje uznajemy za jednorodne. Decyzja: **ANOVA + Tukey HSD**.


ANOVA jednoczynnikowa. $F(3, 37) = 7,621$; $p = 4,3 \cdot 10^{-4}$; $\eta^2 = 0,382$; $\omega^2 = 0,326$. Odrzucamy H_0 z silnym efektem ($\omega^2 \approx 0,33$).

Tukey HSD (FWER = 0,05). Różnica oznacza średnią grupy 1 minus średnią grupy 2.


Grupa 1	Grupa 2	różnica α (1-2)	p_{adj}	95% CI	istotne
AI infra	AI platforms	+0,226	0,0004	[+0,089; +0,363]	tak
AI infra	Broad tech	+0,183	0,0049	[+0,046; +0,320]	tak
AI infra	Defensive	+0,108	0,1665	[-0,029; +0,245]	nie
AI platforms	Broad tech	-0,043	0,8450	[-0,183; +0,098]	nie
AI platforms	Defensive	-0,118	0,1247	[-0,259; +0,022]	nie
Broad tech	Defensive	-0,076	0,4791	[-0,216; +0,065]	nie

Najważniejszy wynik: Dla CAPM alpha przewaga AI infrastructure jest istotna względem AI platforms i Broad tech, ale nie względem Defensive. To sugeruje, że sama premia AI nie jest równomiernie rozłożona między wszystkie spółki technologiczne.

Wykres — CAPM alpha per grupa.



Forest plot — różnice metryk vs grupa Defensive.



2.7 Interpretacja

- **Zmienna:** Sharpe Ratio (główna) oraz CAPM alpha (uzupełniająca) liczone per spółka na dziennych log-zwrotach 2021–2026; $n = 41$ spółek w 4 grupach.
- **Test zastosowany:** ANOVA + Tukey HSD (oba przypadki: założenia spełnione).
- **Wynik (Sharpe):** $F(3, 37) = 4,96$; $p = 0,005$; $\omega^2 = 0,23$. Tukey lokalizuje różnice: AI infrastructure ma istotnie wyższy średni Sharpe Ratio niż każda z pozostałych grup; pozostałe trzy grupy nie różnią się między sobą.
- **Wynik (alpha):** $F(3, 37) = 7,62$; $p = 4,3 \cdot 10^{-4}$; $\omega^2 = 0,33$. AI infrastructure ma istotnie wyższą α niż AI platforms i Broad tech; różnica względem Defensive jest dodatnia, ale nie osiąga istotności statystycznej ($p = 0,17$). Defensive ma $\alpha \approx 0$, przy wyraźnie niższym poziomie ryzyka.
- **Decyzja statystyczna:** odrzucamy H_0 w obu testach.
- **Interpretacja ekonomiczna:** wyniki sugerują, że premia AI ma wyraźny charakter *sektorowy* (półprzewodniki i sprzęt) — platformy chmurowe (MSFT, GOOGL, AMZN itd.) nie wyróżniły się istotnie ani Sharpe Ratio, ani α względem reszty rynku. Jedną z możliwych interpretacji jest taka, że hyperscalerzy ponoszą wysokie nakłady inwestycyjne na infrastrukturę AI, natomiast dostawcy półprzewodników i sprzętu są jej bezpośrednimi beneficjentami przychodowymi.

Ograniczenie próby. Liczebności grup są niewielkie i nierówne (11 spółek w AI infrastructure oraz po 10 spółek w pozostałych grupach). Jest to próba dobrana *celowo* (reprezentatywne spółki z ekspozycją na dany typ ryzyka/tematu inwestycyjnego), a nie losowo z populacji. Wnioski statystyczne dotyczą analizowanej próby i okresu 2021–2026 — nie należy ich uogólniać na „cały rynek”. Dodatkowo grupy Broad tech i Defensive są sektorowo niejednorodne wewnętrznie, co zwiększa wariancję wewnątrzgrupową i tym samym zmniejsza moc testu.

3 Zadanie 3 — A/B testing na próbach zależnych wokół 30.11.2022

3.1 Opis zmiennych i schemat A/B

Zdarzenie: **publiczna premiera ChatGPT, 30.11.2022** — przyjęta jako data rozpoczęcia masowej fazy boomu generatywnej AI. Próba: 21 spółek z połączonej grupy „AI” = AI infrastructure $\cup$ AI platforms (11 + 10 = 21 spółek).

Dla każdej spółki i liczymy dwie wartości:

- **Wariant A:** $\bar{AR}_i^{(A)}$ — średni dzienny abnormal return (vs SPY) w oknie K sesji *przed* 30.11.2022,
- **Wariant B:** $\bar{AR}_i^{(B)}$ — średni dzienny abnormal return w oknie K sesji *po* 30.11.2022.

Jednostką pary jest *ta sama spółka*. Próby są więc zależne (paired). Statystyka testowa: $d_i = \bar{AR}_i^{(B)} - \bar{AR}_i^{(A)}$.

3.2 Hipotezy badawcze

- $H_0: \mu_d = 0$ — średnia różnica AR między wariantem B i A wynosi zero.
- $H_1: \mu_d \neq 0$.

3.3 Procedura statystyczna

1. Test normalności różnic d_i (Shapiro-Wilk).
2. **Test główny:** paired t -test (jeśli różnice normalne).
3. **Test odporności:** Wilcoxon signed-rank (zawsze raportowany). W przypadku odrzucenia normalności Wilcoxon staje się testem głównym.
4. Wielkość efektu: Cohen's $d_z = \bar{d}/s_d$; 95% przedział ufności dla $\bar{d}$ (rozkład t z $n - 1$ stopniami swobody).
5. **Analiza wrażliwości** na długość okna: $K \in \{30, 60, 120, 250\}$ sesji. Okno bazowe: $K = 120$ (6 miesięcy ekspozycji *ex post*).
6. **Placebo test:** cała procedura powtórzona dla daty 30.11.2021 (rok przed boomem AI). Jeżeli wynik dla eventu nie pojawia się „przypadkowo”, placebo nie powinien dawać analogicznie istotnego efektu *w tym samym kierunku*.

3.4 Kod źródłowy (fragment)

```
1 WINDOWS = [30, 60, 120, 250]
2 PRIMARY_WINDOW = 120
3
4
5 def select_windows(returns_idx: pd.DatetimeIndex, event: pd.Timestamp, k: int):
6     days = returns_idx[returns_idx != event]
7     before = days[days < event][-k:]
8     after = days[days > event][:k]
9     return before, after
10
11
12 def per_stock_paired(ar_df: pd.DataFrame, event: pd.Timestamp, k: int) -> pd.DataFrame:
13     before, after = select_windows(ar_df.index, event, k)
14     rows = []
15     for t in ar_df.columns:
16         mb = ar_df.loc[before, t].dropna().mean()
17         ma = ar_df.loc[after, t].dropna().mean()
```

```

18     rows.append({"ticker": t, "mean_A_before": mb, "mean_B_after": ma, "diff_B_minus_A": ma
19                 - mb})
20 df = pd.DataFrame(rows)
21 df["window_sessions"] = k
22 df.attrs["window_before"] = (before[0], before[-1]) if len(before) else None
23 df.attrs["window_after"] = (after[0], after[-1]) if len(after) else None
24 return df
25
26 def paired_summary(diffs: np.ndarray, alpha=ALPHA) -> dict:
27     diffs = np.asarray(diffs, dtype=float)
28     n = len(diffs)
29     mean_d = float(diffs.mean())
30     sd_d = float(diffs.std(ddof=1))
31     se_d = sd_d / np.sqrt(n)
32     W_sh, p_sh = st.shapiro(diffs)
33     t_crit = st.t.ppf(1 - alpha / 2, n - 1)
34     ci_low, ci_high = mean_d - t_crit * se_d, mean_d + t_crit * se_d
35     cohen_dz = mean_d / sd_d if sd_d > 0 else np.nan
36     t_stat, t_p = st.ttest_1samp(diffs, 0.0)
37     w_stat, w_p = st.wilcoxon(diffs, alternative="two-sided")
38     use_t = p_sh > alpha
39     main_test = "Paired t-test" if use_t else "Wilcoxon signed-rank"
40     main_stat = float(t_stat) if use_t else float(w_stat)
41     main_p = float(t_p) if use_t else float(w_p)
42     return {
43         "n": n, "mean_diff": mean_d, "sd_diff": sd_d, "se_diff": se_d,
44         "ci_low": ci_low, "ci_high": ci_high, "cohen_dz": cohen_dz,
45         "shapiro_W": float(W_sh), "shapiro_p": float(p_sh), "normal_diffs": bool(use_t),
46         "t_stat": float(t_stat), "t_p_value": float(t_p),
47         "wilcoxon_stat": float(w_stat), "wilcoxon_p_value": float(w_p),
48         "main_test": main_test, "main_stat": main_stat, "main_p_value": main_p,
49     }
50
51
52 def run_sensitivity(ar_df, event, windows, label):
53     rows = []
54     pairs_by_window = {}

```

3.5 Wyniki

Główny test — okno bazowe $K = 120$ sesji. Shapiro-Wilk: $W = 0,897$; $p = 0,0227$ — różnice odbiegają od rozkładu normalnego, więc testem głównym jest Wilcoxon, a paired t -test raportujemy jako wspierający.

$$\bar{d} = +0,00243; \quad 95\% \text{ CI: } [+0,00123; +0,00363]; \quad d_z = +0,92 \text{ (duży efekt);}$$

$$\text{Wilcoxon } p = 8,4 \cdot 10^{-5}; \quad \text{paired } t(20) = 4,11; \quad p = 4,2 \cdot 10^{-4}.$$


Oba testy zgodnie odrzucają H_0 .

Najważniejszy wynik: W oknie bazowym 120 sesji średnia różnica po-przed jest dodatnia i istotna statystycznie. Efekt pojawia się mocno dopiero w dłuższych oknach, co jest spójne z narastającą wyceną tematu AI po premierze ChatGPT.


Pełna analiza wrażliwości + placebo.

Wariant	K	$\bar{d}$	95% CI	d_z	p (główny)	test
Event: 30.11.2022 (premiera ChatGPT)						
event	30	-0,00177	[-0,00502; +0,00149]	-0,25	0,2707	paired t
event	60	+0,00147	[-0,00024; +0,00317]	+0,39	0,0760	Wilcoxon
event	120	+0,00243	[+0,00123; +0,00363]	+0,92	$8,4 \cdot 10^{-5}$	Wilcoxon
event	250	+0,00231	[+0,00143; +0,00319]	+1,20	$< 10^{-4}$	paired t
Placebo: 30.11.2021 (rok przed boomem AI)						
placebo	30	-0,00385	[-0,00672; -0,00098]	-0,61	0,0110	paired t
placebo	60	-0,00290	[-0,00447; -0,00134]	-0,84	0,0010	paired t
placebo	120	-0,00260	[-0,00412; -0,00108]	-0,78	0,0020	paired t
placebo	250	-0,00156	[-0,00248; -0,00064]	-0,77	0,0021	paired t

Wykres — histogram różnic + sensitivity z placebo.



Event-window CAR — portfele EW per grupa wokół 30.11.2022.



3.6 Interpretacja

- **Zmienna:** $d_i = \bar{AR}_i^{(B)} - \bar{AR}_i^{(A)}$ dla $n = 21$ spółek z grupy AI; $\bar{AR}$ to średni dzienny abnormal return (vs SPY) w oknie K sesji.
- **Test zastosowany:** Wilcoxon signed-rank (główny, bo Shapiro odrzucił normalność dla okna 120) + paired t -test (wspierający).

- **Wynik (okno bazowe $K = 120$):** $\bar{d} = +0,243$ p.p. *dziennie*; 95% CI $[+0,123; +0,363]$ p.p.; $d_z = +0,92$ (duży efekt); Wilcoxon $p = 8,4 \cdot 10^{-5}$.
- **Decyzja statystyczna:** odrzucamy H_0 z wysokim marginesem dla okien 120 i 250 sesji. Dla okna 60 efekt graniczny ($p = 0,076$), dla okna 30 nieistotny. Jest to spójne z interpretacją, że rynek nie wycenił całej premii AI natychmiast, lecz w kolejnych miesiącach po zdarzeniu.
- **Placebo:** dla 30.11.2021 efekt jest *ujemny i istotny* we wszystkich oknach. Kierunek przeciwny do eventu rzeczywistego wzmacnia interpretację czasowego związku z 30.11.2022 i ogranicza ryzyko, że dodatni wynik jest prostym artefaktem wybranej metody przed-po. Nie jest to jednak samodzielny dowód przyczynowości.
- **Interpretacja ekonomiczna:** po publicznej premierze ChatGPT spółki z grupy AI generowały średnio o ok. 0,24 p.p. *dziennie* wyższy abnormal return niż w analogicznym oknie przed premierą. Prosta annualizacja tej średniej ($0,243\% \times 252$) daje ok. 61 p.p. rocznie, dlatego wynik należy traktować jako bardzo duży efekt historyczny, a nie jako prognozę przyszłych stóp zwrotu. Dla okna 120 sesji liniowa kumulacja odpowiada ok. 29 p.p. przewagi abnormal returnu.

Ograniczenia. Analiza ma charakter *uproszczonego testu A/B przed-po*: nie modeluje oczekiwanego abnormal returnu względem modelu czynnikowego (Fama-French 3/5 czynników); raportujemy AR jedynie względem SPY. Wybór grupy zdarzeniowej (infra + platforms) jest definicyjny — nie jest to próba losowa.

Uwaga interpretacyjna: Test A/B przed-po jest czytelny i intuicyjny, ale nie kontroluje pełnego zestawu czynników rynkowych. Wynik należy traktować jako mocny sygnał historyczny, a nie jako dowód przyczynowości ani prognozę przyszłych zwrotów.

Wnioski końcowe i decyzja inwestora

Wnioski statystyczne.

- **Zad 1.** Welch t-test odrzuca H_0 ($p = 0,0079$, Hedges' $g = 0,59$): portfel AI infrastructure ma istotnie wyższą średnią miesięczną nadwyżkę względem SPY niż portfel Defensive po 30.11.2022 (+3,7 p.p./miesiąc).
- **Zad 2.** ANOVA odrzuca H_0 dla obu zmiennych: Sharpe ($F = 4,96$; $p = 0,005$; $\omega^2 = 0,23$) i CAPM α ($F = 7,62$; $p = 4 \cdot 10^{-4}$; $\omega^2 = 0,33$). Dla Sharpe Tukey wskazuje istotną przewagę AI infrastructure nad wszystkimi pozostałymi grupami; dla CAPM α przewaga AI infrastructure jest istotna względem AI platforms i Broad tech, ale nie względem Defensive.
- **Zad 3.** Wilcoxon ($K = 120$): $p = 8,4 \cdot 10^{-5}$; $\bar{d} = +0,24$ p.p./dzień; 95% CI [+0,12; +0,36] p.p.; $d_z = +0,92$. Placebo test daje efekt w kierunku przeciwnym, co wzmacnia interpretację czasowego związku wyniku z datą zdarzenia, ale nie stanowi samodzielnego dowodu przyczynowości.

Decyzja inwestora — praktyczny take-away.

- Trzy niezależne testy zgodnie wspierają tezę *AI Boom Premium* — ale przede wszystkim w segmencie infrastruktury (półprzewodniki, sprzęt), nie w platformach chmurowych.
- Premium wiąże się z istotnie wyższym ryzykiem: portfel AI infrastructure miał volatylity 50% rocznie (vs 19% Defensive) i max drawdown -58% . Inwestor awersyjny wobec ryzyka powinien stosować mniejszą wagę w portfelu niż sugerowałyby sama wielkość średniej nadwyżki.
- Wyniki są *ex post* i odzwierciedlają konkretny okres 2021–2026. Standardowe ostrzeżenie: „past performance is not indicative of future results”. Czy premia utrzyma się po fazie szczytowej AI capex — pozostaje otwartą kwestią.

Reproducibility note

Środowisko. Analizy wykonano w Pythonie. Dokładne wersje bibliotek należy utrzymywać automatycznie w pliku `requirements.txt` lub przez `pip freeze`, zamiast przepisywać je ręcznie do raportu. Kluczowe pakiety: `pandas`, `numpy`, `scipy`, `statsmodels`, `scikit-posthocs`, `matplotlib`, `seaborn`, `yfinance`, `pyarrow`.

Dane. Źródło: Yahoo Finance via `yfinance`. Pobranie: 2026-05-20. Cache lokalny: `data_cache/prices.parquet` (43 tickery $\times$ 1347 dni sesyjnych). Mapowanie ticker $\rightarrow$ grupa: `data_cache/metadata_tickers.csv`.

Skrypty (kolejność wykonania).

1. `src/data_fetch.py` — pobranie i zapis do parquet.
2. `src/task1_two_portfolios.py` — Zadanie 1.
3. `src/task2_four_groups.py` — Zadanie 2 (Sharpe i alpha).
4. `src/task3_paired_event.py` — Zadanie 3 (event + placebo).
5. `src/plots_extra.py` — wykresy zaawansowane.

Moduły wspólne: `src/common.py` (wczytywanie, log returns, portfele EW, abnormal returns, RF), `src/metrics.py` (7 metryk per spółka), `src/plot_utils.py` (style i zapis wykresów).

Ziarno losowe. Bootstrap w Zad. 1 używa `numpy.random.default_rng(seed=42)` i $B = 10\,000$ powtórzeń. Pozostałe analizy są deterministyczne.


Repozytorium. github.com/Smalou/metody_badania_w_finansach — pełny kod, dane cache i źródło LaTeX dostępne publicznie.

Limitations

- **Selection bias / próby celowe.** Wszystkie cztery grupy spółek dobrane są ręcznie na bazie eksperckiej oceny ekspozycji na AI — nie są losowymi próbami z populacji. Wnioski dotyczą tej konkretnej próby.
- **Niejednorodność wewnątrzgrupowa.** Grupy Broad tech i Defensive zawierają spółki o zróżnicowanych modelach biznesowych, co zwiększa wewnętrzną wariancję metryk.
- **Single-factor benchmark.** Abnormal returns liczone są jako prosty spread względem SPY. Nie kontrolujemy ekspozycji na czynniki Fama-French (HML, SMB, momentum) ani na czynniki sektorowe.
- **Definicja zdarzenia.** Premiera ChatGPT (30.11.2022) jest symbolicznym punktem startu boomu AI, ale realna fala kapitałowa następowała stopniowo przez kolejne 6–12 miesięcy. Stąd wrażliwość wyników Zad. 3 na długość okna.
- **Częściowy ostatni miesiąc.** W Zad. 1 maj 2026 jest miesiącem częściowym. Nie zmienia to głównej logiki testu, ale w wersji produkcyjnej warto dodać wariant z wykluczeniem niepełnego miesiąca.
- **Dane yfinance.** Ceny są korygowane wstecznie (split, dywidenda); dostawca może okresowo modyfikować historyczne wartości. Cache lokalny zapewnia reprodukowalność tej analizy, ale ponowne pobranie może dać minimalnie inne wyniki.
- **Spojrzenie ex-post.** Cały kierunek hipotezy („AI Premium”) jest motywowany obserwacjami z lat 2023–2025. Test jest confirmacyjny, nie predykcyjny.


Dodatek — wykresy uzupełniające

Heatmapa korelacji dziennych log-zwrotów.



Wizualnie widoczne są bloki wysokiej korelacji wewnątrz grup AI (infra, platforms) oraz niska korelacja grupy Defensive z technologiami.

Rolling annualized volatility (okno 63 sesji).



AI infrastructure utrzymuje najwyższy poziom zmienności w całym okresie, ze szczytami wokół wybuchu AI capex 2023 i fazy korekt 2024–2025.

Bibliografia

1. Sharpe, W. F. (1994). The Sharpe Ratio. *The Journal of Portfolio Management*, 21(1), 49–58.
2. Sortino, F. A., & Price, L. N. (1994). Performance measurement in a downside risk framework. *Journal of Investing*, 3(3), 59–64.
3. Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35.
4. Games, P. A., & Howell, J. F. (1976). Pairwise multiple comparison procedures with unequal N ’s and/or variances. *Journal of Educational Statistics*, 1(2), 113–125.
5. Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed., Lawrence Erlbaum Associates.
6. Hedges, L. V. (1981). Distribution theory for Glass’s estimator of effect size and related estimators. *Journal of Educational Statistics*, 6(2), 107–128.
7. MacKinlay, A. C. (1997). Event Studies in Economics and Finance. *Journal of Economic Literature*, 35(1), 13–39.
8. Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
9. OpenAI (2022). *Introducing ChatGPT*, <https://openai.com/index/chatgpt/>.
10. Yahoo Finance / yfinance — dokumentacja API, <https://github.com/ranaroussi/yfinance>.