

AI Boom Premium?

Dlaczego pierwsza odpowiedź nie była wystarczająca: analiza zwrotów, ryzyka i pre-event ekspozycji AI

Projekt zaliczeniowy IAD — Metody Badań w Finansach, ćwiczenia 3

Sylwia Malinowska

22 maja 2026

Repozytorium kodu i danych

github.com/Smalou/metody_badania_w_finansach

Wszystkie skrypty Pythona, cache danych (parquet/csv), wygenerowane wykresy i źródło niniejszego raportu LaTeX są dostępne w powyższym repozytorium.

Streszczenie

Raport sprawdza, czy spółki powiązane z infrastrukturą i platformami AI osiągnęły anormalne stopy zwrotu po publicznej premierze ChatGPT (30 listopada 2022). Analiza rozpoczyna się od prostych porównań względem benchmarku, a następnie progresywnie dodaje kontrole metodologiczne: abnormal returns skorygowane o CAPM, test placebo, pre-event AI Exposure Score zbudowany z raportów 10-K SEC, cross-sectional regression, robustness checks oraz walidację przez modele czynnikowe (CAPM, Fama-French 3 i Carhart 4). Wyniki pokazują, że spółki AI infrastructure wyraźnie pobiły benchmark w surowych i benchmark-relative zwrotach. Dowody słabną jednak istotnie po kontroli pre-event bety, zmienności, momentum i ekspozycji czynnikowych. Disclosure-based AI Exposure Score jest dodatnio związany z post-event abnormal returns w prostej specyfikacji, lecz efekt zanika po kontrolach ryzyka w głównym oknie sześciomiesięcznym. Walidacja semantyczna przez LLM ujawnia, że dowody są wrażliwe na sposób pomiaru: miara LLM-based pozostaje istotna nawet po kontroli ryzyka, ale opiera się na podpróbie z samo-selekcją. Główny wniosek brzmi: *dowody na samodzielną premię AI są mieszane i wrażliwe na specyfikację*; pozorna AI Boom Premium jest częściowo efektem high-beta technologicznego, a nie wyraźnie potwierdzoną fundamentalną premią. Raport ilustruje także wagę walidacji human-in-the-loop w AI-wspomaganej analityce inwestycyjnej.

Słowa kluczowe: asset pricing, event study, factor models, 10-K text analysis, AI exposure, model risk.

Streszczenie dla czytelnika nieakademickiego

Raport sprawdza, czy po premierze ChatGPT spółki infrastruktury AI osiągały wyższe zwroty niż grupy kontrolne. Wyniki wskazują silną przewagę segmentu **AI infrastructure** w analizowanym okresie. Najmocniejszym elementem raportu jest **część rozszerzona**: konstrukcja *pre-event AI Exposure Score* z raportów 10-K, cross-sectional regression oraz walidacja wyników przez modele czynnikowe. Zadanie 2 pozostaje najsilniejszym z trzech pierwotnych zadań statystycznych, ale dopiero rozszerzenie o NLP i modele czynnikowe pozwala właściwie ocenić ryzyko błędnej interpretacji prostego wyniku. Zadania 1 i 3 traktujemy jako opisowe, a nie przyczynowe.

Spis treści

1	Wprowadzenie i hipoteza projektowa	4
2	Zadanie 1 — AI infrastructure vs Defensive: miesięczne zwroty względem SPY	6
2.1	Opis zmiennych	6
2.2	Hipotezy badawcze	6

2.3	Procedura statystyczna	6
2.4	Kod źródłowy (fragment)	7
2.5	Wyniki	7
2.6	Interpretacja	8
3	Zadanie 2 — Metryki efektywności w czterech grupach spółek	10
3.1	Opis zmiennych	10
3.2	Hipotezy badawcze	10
3.3	Procedura statystyczna — drzewo decyzyjne	10
3.4	Kod źródłowy (fragment)	11
3.5	Wyniki — zmienna główna: Sharpe Ratio	12
3.6	Wyniki — zmienna uzupełniająca: CAPM alpha	13
3.7	Kontrola odporności — Kruskal-Wallis + Dunn	14
3.8	Interpretacja	14
4	Zadanie 3 — A/B testing na próbach zależnych wokół 30.11.2022	16
4.1	Opis zmiennych i schemat A/B	16
4.2	Hipotezy badawcze	16
4.3	Procedura statystyczna	16
4.4	Kod źródłowy (fragment)	16
4.5	Wyniki	17
4.6	Interpretacja	18
4.7	Dodatkowa kontrola odporności — CAPM-adjusted returns	19
5	Pre-event AI Exposure Score z raportów 10-K (centralna innowacja)	21
5.1	Motywacja	21
5.2	Dane wejściowe — 10-K SEC	21
5.3	Konstrukcja deterministyczna — specyfikacja główna	21
5.4	Walidacja LLM (Claude Haiku, robustness)	21
6	Cross-sectional regression: AI Premium AI Exposure	24
6.1	Specyfikacja	24
6.2	Inference	24
6.3	Wyniki głównej regresji	24
6.4	Macierz korelacji zmiennych regresji	25
6.5	Diagnostyka multicollinearity (VIF, M4)	26
6.6	Interpretacja	26
7	Robustness checks dla cross-sectional regresji	27
7.1	(1) Leave-one-out	27
7.2	(2) Excluding extreme firms (M3)	27
7.3	(3) Alternative AI scores (M3)	27
7.4	(4) Alternative windows Y (M3)	28
7.5	(5) Alternative scaling X (M3)	28
8	Modele czynnikowe (CAPM / FF3 / Carhart 4) dla portfeli EW	30
8.1	Specyfikacja	30
8.2	Wyniki — annualized α per grupa	30
8.3	Interpretacja	31

9	Dyskusja: model risk w AI-wspomaganej analityce inwestycyjnej	32
9.1	Co nasze wyniki znaczą	32
9.2	Powiązanie z literaturą	32
9.3	Co przeoczyła pierwsza wersja analizy generowana przez AI	32
9.4	Praktyczna implikacja dla inwestora	33
10	Reproducibility note	34
11	Limitations	35
12	Dodatek — wykresy uzupełniające	37
13	Bibliografia	38

1 Wprowadzenie i hipoteza projektowa

W projekcie przyjęto premierę ChatGPT (30 listopada 2022) jako symboliczny punkt startu masowej fazy boomu generatywnej AI. W kolejnych kwartałach temat AI stał się jednym z głównych motywów inwestycyjnych na rynku amerykańskim, szczególnie w segmencie półprzewodników, infrastruktury obliczeniowej i usług chmurowych. Niniejszy projekt sprawdza empirycznie, czy po tej dacie wystąpiły mierzalne różnice w średnich zwrotach oraz profilu ryzyko–zwrot między spółkami o różnym stopniu ekspozycji na sztuczną inteligencję. Analiza ma charakter statystyczny i porównawczy; nie jest dowodem przyczynowym w ścisłym sensie ekonometrycznym.

Hipoteza badawcza. *Spółki silnie powiązane z infrastrukturą AI (producenci półprzewodników i sprzętu) osiągnęły po 30.11.2022 wyższe średnie zwroty i/lub lepszy profil ryzyko–zwrot niż grupy kontrolne (Defensive, Broad Tech, AI Platforms).* Hipotezę tę traktujemy jako przedmiot testu, a nie tezę do udowodnienia.

Uwaga interpretacyjna: Najważniejsze ograniczenie metodologiczne dotyczy definicji spreadów w Zadaniach 1 i 3. Użyty spread względem SPY zakłada implícite $\beta = 1$. Tymczasem estymowane bety dziennych portfeli EW są bardzo różne: po ewencie AI infrastructure ma $\beta \approx 1,98$, a Defensive tylko $\beta \approx 0,24$. Oznacza to, że część przewagi AI infrastructure może być premią za wysokie ryzyko systematyczne, a nie czystą premią związaną z AI.

Trzy zadania spójne tematycznie.


- **Zadanie 1** — porównanie średnich miesięcznych zwrotów względem SPY portfela AI infrastructure i portfela Defensive control *po* rozpoczęciu boomu (próby niezależne). To test opisowy, nie pełne CAPM event study.
- **Zadanie 2** — porównanie średnich metryk efektywności ryzyko–zwrot (*Sharpe Ratio* jako zmienna główna, *CAPM alpha* jako uzupełnienie) między czterema grupami spółek.
- **Zadanie 3** — A/B testing na próbach zależnych: średnie dzienne zwroty względem SPY tej samej spółki w oknie przed (wariant A) i po (wariant B) 30.11.2022, z analizą wrażliwości i testem placebo. Wynik placebo traktujemy jako ostrzeżenie o misspecification.

Dane. Źródło: Yahoo Finance przez bibliotekę `yfinance`. 41 spółek notowanych na NYSE/NASDAQ podzielonych na cztery grupy (definicje w `data_cache/metadata_tickers.csv`) plus benchmark SPY i stopa wolna od ryzyka $\sim$ IRX (13-tygodniowy T-bill). Okres: 04.01.2021–14.05.2026 (1347 dni sesyjnych). Ceny skorygowane (`auto_adjust=True`), brak braków danych.

Grupy spółek (11+10+10+10 = 41).

- **AI infrastructure / półprzewodniki (11):** NVDA, AMD, AVGO, TSM, ASML, AMAT, LRCX, KLAC, MU, MRVL, SMCI.
- **AI platforms / cloud / software (10):** MSFT, GOOGL, AMZN, META, ORCL, CRM, NOW, ADBE, IBM, SNOW.
- **Broad technology control (10):** AAPL, CSCO, INTC, TXN, QCOM, INTU, ACN, PANW, CDNS, ADSK.
- **Defensive control (10):** KO, PEP, PG, WMT, JNJ, MRK, MCD, COST, CL, GIS.

Kontekst graficzny — skumulowane zwroty względem SPY per grupa. Poniższy wykres przedstawia skumulowany dzienny spread portfela równoważonego (EW) każdej grupy względem SPY. Pionowa linia oznacza moment zdarzenia 30.11.2022.



Widoczne jest wyraźne rozejście trajektorii AI infrastructure od pozostałych grup po listopadzie 2022. Wykres pełni jednak wyłącznie funkcję diagnostyczną i opisową. Nie rozstrzyga, czy przewaga wynika z ekspozycji na AI, z wysokiej bety względem rynku, czy z innych czynników wspólnych dla spółek technologicznych.

Uwaga interpretacyjna: Wykres skumulowanych spreadów względem SPY pomaga zrozumieć kontekst, ale nie zastępuje testów statystycznych. Dodatkowo jest liczony względem SPY bez korekty o indywidualną betę, dlatego nie powinien być czytany jako pełny abnormal return w sensie CAPM.

2 Zadanie 1 — AI infrastructure vs Defensive: miesięczne zwroty względem SPY

2.1 Opis zmiennych

Dla każdej grupy zbudowano portfel równoważony (EW). Dzienna stopa zwrotu portfela:

$$r_t^{\text{port}} = \frac{1}{N} \sum_{i=1}^N r_{i,t},$$

gdzie $r_{i,t}$ to dzienna log-stopa zwrotu spółki i . Następnie:

- agregacja miesięczna: $r_m^{\text{port}} = \sum_{t \in m} r_t^{\text{port}}$ (suma log-zwrotów, ekwiwalentnie miesięczny log-zwrot);
- spread względem SPY: $S_m^{\text{port}} = r_m^{\text{port}} - r_m^{\text{SPY}}$. W kodzie część zmiennych i plików ma historyczną nazwę z wcześniejszej wersji projektu, ale w interpretacji finansowej traktujemy tę zmienną jako *spread vs SPY*, nie jako pełny abnormal return z modelu CAPM;
- filtracja czasowa: tylko obserwacje *po* 30.11.2022.
Porównywane zmienne (próby niezależne, $n_1 = n_2 = 42$ miesiące):
- X : miesięczny spread vs SPY portfela **AI infrastructure** (11 spółek),
- Y : miesięczny spread vs SPY portfela **Defensive control** (10 spółek).

Ostatni miesiąc w próbie (maj 2026) jest miesiącem częściowym ze względu na datę pobrania danych. W głównym wyniku zachowano go dla zgodności z cache danych; w praktycznej analizie inwestycyjnej warto dodatkowo sprawdzić wariant z jego wykluczeniem.

Ograniczenie specyfikacji. Definicja $S_m^{\text{port}} = r_m^{\text{port}} - r_m^{\text{SPY}}$ jest prosta i czytelna, ale narzuca ukryte założenie $\beta = 1$ względem rynku. To założenie jest mało realistyczne dla porównywanych portfeli: dzienna beta EW portfela AI infrastructure po 30.11.2022 wynosi ok. 1,98, a portfela Defensive ok. 0,24. W silnej hossie technologicznej wysoka beta może mechanicznie generować przewagę nad SPY. Wynik Zadania 1 należy więc traktować jako test różnicy prostych zwrotów względem benchmarku, a nie jako dowód czystej alfy AI.

2.2 Hipotezy badawcze

- H_0 : średnie miesięczne spready vs SPY obu portfeli są równe, $\mu_{\text{spread,AI}} = \mu_{\text{spread,Def}}$.
- H_1 : średnie różnią się, $\mu_{\text{spread,AI}} \neq \mu_{\text{spread,Def}}$.

2.3 Procedura statystyczna

1. Sprawdzenie założeń: Shapiro-Wilk (normalność) + Levene (homogeniczność wariancji).
2. **Test główny:** *Welch t-test* dla dwóch prób niezależnych (bez założenia równych wariancji).
3. **Analiza odporności:** bootstrap ($B = 10\,000$, ziarno 42) 95% przedziału ufności różnicy średnich.
4. Wielkość efektu: *Hedges' g* (poprawiona Cohen's d dla małych prób).
5. **Test pomocniczy:** Mann-Whitney U. Przy nierównych wariancjach nie interpretujemy go jako czystego testu median; traktujemy go jako test różnic w rangach / stochastycznej dominacji.

2.4 Kod źródłowy (fragment)

```
1 N_BOOT = 10_000
2
3
4 def hedges_g(x, y):
5     n1, n2 = len(x), len(y)
6     s1, s2 = x.std(ddof=1), y.std(ddof=1)
7     sp = np.sqrt(((n1 - 1) * s1 ** 2 + (n2 - 1) * s2 ** 2) / (n1 + n2 - 2))
8     d = (x.mean() - y.mean()) / sp
9     J = 1 - 3 / (4 * (n1 + n2) - 9)
10    return float(d * J)
11
12
13 def welch_with_ci(x, y, alpha=ALPHA):
14     n1, n2 = len(x), len(y)
15     m1, m2 = float(x.mean()), float(y.mean())
16     v1, v2 = float(x.var(ddof=1)), float(y.var(ddof=1))
17     diff = m1 - m2
18     se = np.sqrt(v1 / n1 + v2 / n2)
19     df = (v1 / n1 + v2 / n2) ** 2 / ((v1 / n1) ** 2 / (n1 - 1) + (v2 / n2) ** 2 / (n2 - 1))
20     t_stat = diff / se
21     p = 2 * (1 - st.t.cdf(abs(t_stat), df))
22     t_crit = st.t.ppf(1 - alpha / 2, df)
23     return {
24         "t": float(t_stat), "df": float(df), "p_value": float(p),
25         "mean_x": m1, "mean_y": m2, "mean_diff": diff, "se_diff": float(se),
26         "ci_low": float(diff - t_crit * se), "ci_high": float(diff + t_crit * se),
27     }
28
29
30 def bootstrap_ci_diff(x, y, n_boot=N_BOOT, alpha=ALPHA, seed=SEED):
31     rng = np.random.default_rng(seed)
32     xa, ya = np.asarray(x), np.asarray(y)
33     n1, n2 = len(xa), len(ya)
34     boot = np.empty(n_boot)
35     for i in range(n_boot):
36         boot[i] = rng.choice(xa, size=n1, replace=True).mean() - rng.choice(ya, size=n2,
37                                     replace=True).mean()
38     lo, hi = np.percentile(boot, [100 * alpha / 2, 100 * (1 - alpha / 2)])
39     return {"boot_mean_diff": float(boot.mean()), "boot_ci_low": float(lo),
40             "boot_ci_high": float(hi), "n_boot": n_boot}
41
42 def main():
43     prices = load_prices()
```

2.5 Wyniki

Statystyki opisowe.

Portfel	n	średni spread vs SPY	odch. std.
AI infrastructure	42	0,02638	0,07774
Defensive control	42	-0,01089	0,04133

Założenia.

- Shapiro-Wilk AI infra: $W = 0,956$; $p = 0,1053$ (rozkład zbliżony do normalnego);
- Shapiro-Wilk Defensive: $W = 0,987$; $p = 0,9141$ (rozkład zbliżony do normalnego);


- Levene (median): stat = 13,23; $p = 0,0005$ (wariancje istotnie różne → uzasadnia *Welch*, a nie klasyczny *t*-Student).

Test główny — Welch t-test, bootstrap i Mann-Whitney.

Test	wartość	uwaga
Welch t (df $\approx 62,5$)	2,744	
p -value	0,00792	odrzućenie H_0
Różnica średnich ($\bar{X} - \bar{Y}$)	+0,03728	na korzyść AI infra
95% CI (Welch)	[+0,01012; +0,06443]	nie zawiera 0
Hedges' g	+0,593	umiarkowany efekt
95% CI bootstrap (B = 10 000)	[+0,01199; +0,06365]	spójne z Welch
Mann-Whitney U (pomocniczy)	1122,0	różnica rang / dominacja stochastyczna
p -value (M-W)	0,0321	spójne z H_1

Najważniejszy wynik: Portfel AI infrastructure miał średnio o +3,73 p.p. miesięcznie wyższy zwrot względem SPY niż portfel Defensive, a 95% przedziały ufności nie obejmują zera. Nie jest to jednak wynik skorygowany o różnice w beczie.

Wykres rozkładów.



2.6 Interpretacja

- **Zmienna:** miesięczny zwrot portfela EW względem SPY, $n = 42$ miesięcy (12.2022–05.2026).
- **Test zastosowany:** Welch t-test (główny) + bootstrap (odporność) + Mann-Whitney U (pomocniczy; przy nierównych wariacjach nie jako prosty test median).
- **Wynik:** $p = 0,0079$; $\bar{X} - \bar{Y} = +3,73$ p.p. miesięcznie; 95% CI Welch [+1,01; +6,44] p.p.; Hedges' $g = 0,59$. Bootstrap CI praktycznie pokrywa się z Welch.
- **Decyzja statystyczna:** odrzucamy H_0 przy $\alpha = 0,05$.
- **Interpretacja ekonomiczna:** w okresie 42 miesięcy po premierze ChatGPT portfel AI infrastructure dostarczył średnio ok. 3,7 p.p. *na miesiąc* wyższego zwrotu względem SPY niż portfel defensywny. Wynik jest spójny z obserwacją silnej przewagi segmentu infrastruktury AI, ale nie pozwala samodzielnie oddzielić efektu AI od premii za wysoką betę i wyższe ryzyko systematyczne.

Uwaga interpretacyjna: Wynik z Zadania 1 pokazuje istotną różnicę średnich spreadów względem SPY, ale nie kontroluje ryzyka systematycznego. Dlatego wniosek powinien brzmieć: „AI infrastructure pobiło SPY i Defensive w prostym porównaniu”, a nie: „AI infrastructure wygenerowało czystą alfę związaną wyłącznie z AI”.

3 Zadanie 2 — Metryki efektywności w czterech grupach spółek

3.1 Opis zmiennych

Dla każdej z 41 spółek obliczono komplet 7 metryk na bazie dziennych log-zwrotów za cały okres 04.01.2021–14.05.2026:

- *Annualized return* $= \bar{r}_t \cdot 252$,
- *Annualized volatility* $= s(r_t) \cdot \sqrt{252}$,
- *Sharpe Ratio* $= (\bar{r}_t - r_f) / s(r_t - r_f) \cdot \sqrt{252}$,
- *Sortino Ratio* (downside deviation względem $MAR = 0$),
- *Maximum drawdown* liczony na wealth-curve $\exp(\sum r_t)$,
- *CAPM beta* z regresji nadwyżkowych zwrotów na SPY,
- *CAPM alpha* (annualized).

Główna zmienna testowana : **Sharpe Ratio** (najszerzej akceptowana miara ryzyko–zwrot w finansach). Dla kompletności — równolegle ten sam test przeprowadzono dla **CAPM alpha**, bezpośrednio mierzącego „nadwyżkę po kontroli ryzyka systematycznego” i najbliższego pojęciu *AI Premium*.

Statystyki opisowe (średnie metryk per grupa).

Grupa	Ann. ret	Ann. vol	Sharpe	Sortino	Max DD	beta	alpha
AI infrastructure	0,362	0,501	0,674	0,684	−0,584	1,854	+0,119
AI platforms	0,072	0,374	0,154	0,159	−0,567	1,296	−0,107
Broad tech	0,111	0,349	0,228	0,228	−0,452	1,262	−0,064
Defensive	0,082	0,192	0,250	0,244	−0,297	0,336	+0,011

Tabela pokazuje jednocześnie, dlaczego interpretacja Zadania 1 wymaga ostrożności: AI infrastructure ma znacznie wyższą średnią betę niż grupa Defensive, więc część przewagi w prostym spreadzie względem SPY jest naturalną konsekwencją wyższej ekspozycji na rynek.

3.2 Hipotezy badawcze

- H_0 : średnie Sharpe Ratio (alpha) są równe we wszystkich czterech grupach.
- H_1 : co najmniej jedna grupa ma średnią różną od pozostałych.

3.3 Procedura statystyczna — drzewo decyzyjne

1. Shapiro-Wilk per grupa → czy rozkłady normalne?
2. Levene (median) → czy wariancje jednorodne?
3. Decyzja:
 - normalne + jednorodne → **ANOVA** + Tukey HSD,
 - normalne + nierówne wariancje → **Welch ANOVA** + Games-Howell,
 - nienormalne → **Kruskal-Wallis** + Dunn (Bonferroni).
4. Wielkość efektu: η^2 i ω^2 (mniej obciążone dla małych prób).

5. Ze względu na małe liczebności grup ($n = 10-11$) raportujemy także kontrolę odporności: Kruskal-Wallis + Dunn (Bonferroni).

Uwaga interpretacyjna: Przy $n \approx 10$ test Shapiro-Wilka ma niską moc. Brak odrzucenia normalności nie jest silnym dowodem normalności rozkładów metryk finansowych. Dlatego wyniki ANOVA traktujemy jako główne zgodnie z drzewem decyzyjnym, ale weryfikujemy je nieparametrycznie.

3.4 Kod źródłowy (fragment)

```
1 from common import CACHE, BENCHMARK, load_prices, load_metadata, log_returns, daily_rf
2 from metrics import compute_all_metrics
3 from plot_utils import setup_style, savefig
4
5 ALPHA = 0.05
6 GROUP_ORDER = ["AI_infra", "AI_platforms", "Broad_tech", "Defensive"]
7 GROUP_PALETTE = {
8     "AI_infra": "#1f77b4",
9     "AI_platforms": "#9467bd",
10    "Broad_tech": "#2ca02c",
11    "Defensive": "#d62728",
12 }
13
14
15 def compute_metrics_df(prices, meta) -> pd.DataFrame:
16     rets = log_returns(prices)
17     rf_d = daily_rf(prices)
18     bench = rets[BENCHMARK]
19     frames = []
20     for g in GROUP_ORDER:
21         tickers = meta.loc[meta["group"] == g, "ticker"].tolist()
22         frames.append(compute_all_metrics(rets, bench, rf_d, tickers, g))
23     return pd.concat(frames, ignore_index=True)
24
25
26 def normality_per_group(df: pd.DataFrame, col: str) -> pd.DataFrame:
27     rows = []
28     for g, sub in df.groupby("group"):
29         W, p = st.shapiro(sub[col].dropna())
30         rows.append({"group": g, "n": len(sub), "W": W, "p": p, "normal": p > ALPHA})
31     return pd.DataFrame(rows)
32
33
34 def variance_homogeneity(df: pd.DataFrame, col: str):
35     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
36     stat, p = st.levene(*groups, center="median")
37     return {"stat": float(stat), "p_value": float(p), "homogeneous": p > ALPHA}
38
39
40 def anova_with_tukey(df, col):
41     groups = [sub[col].dropna().values for _, sub in df.groupby("group")]
42     F, p = st.f_oneway(*groups)
43     all_vals = np.concatenate(groups)
44     N, k = len(all_vals), len(groups)
45     grand = all_vals.mean()
46     ss_b = sum(len(g) * (g.mean() - grand) ** 2 for g in groups)
47     ss_w = sum(((g - g.mean()) ** 2).sum() for g in groups)
48     ss_t = ss_b + ss_w
49     eta2 = ss_b / ss_t
50     ms_w = ss_w / (N - k)
51     omega2 = (ss_b - (k - 1) * ms_w) / (ss_t + ms_w)
52     tuk = pairwise_tukeyhsd(endog=df[col].values, groups=df["group"].values, alpha=ALPHA)
53     return {"test": "ANOVA", "F": float(F), "df_b": k - 1, "df_w": N - k,
```

```

54         "p_value": float(p), "eta_squared": float(eta2), "omega_squared": float(omega2)},
    tuk
55
56
57 def welch_anova_with_games_howell(df, col):
58     res = anova_oway(df[col].values, df["group"].values, use_var="unequal",
    welch_correction=True)
59     gh = sp.posthoc_games_howell(df, val_col=col, group_col="group")
60     return {"test": "Welch ANOVA", "F": float(res.statistic), "df_b": float(res.df_num),
61             "df_w": float(res.df_denom), "p_value": float(res.pvalue)}, gh
62
63
64 def kruskal_with_dunn(df, col):

```

3.5 Wyniki — zmienna główna: Sharpe Ratio

Założenia. Shapiro-Wilk: wszystkie cztery grupy spełniają normalność ($p > 0,05$). Levene: $\text{stat} = 1,25$; $p = 0,299$ — wariancje jednorodne. Decyzja: **ANOVA + Tukey HSD**.


ANOVA jednoczynnikowa. $F(3, 37) = 4,956$; $p = 0,00543$; $\eta^2 = 0,287$; $\omega^2 = 0,225$. Odrzucamy H_0 . Wartość $\omega^2 \approx 0,22$ wskazuje na duży efekt (próg 0,14 pochodzi z konwencji Cohena dla η^2 ; ω^2 traktujemy tu jako mniej obciążony estymator tej samej populacyjnej wielkości efektu).

Tukey HSD (FWER = 0,05). Różnica oznacza średnią grupy 1 minus średnią grupy 2.

Grupa 1	Grupa 2	różnica (1-2)	p_{adj}	95% CI	istotne
AI infra	AI platforms	+0,519	0,0076	[+0,113; +0,925]	tak
AI infra	Broad tech	+0,445	0,0269	[+0,039; +0,851]	tak
AI infra	Defensive	+0,424	0,0380	[+0,018; +0,829]	tak
AI platforms	Broad tech	-0,074	0,9633	[-0,489; +0,341]	nie
AI platforms	Defensive	-0,096	0,9253	[-0,511; +0,320]	nie
Broad tech	Defensive	-0,022	0,9990	[-0,437; +0,394]	nie

Najważniejszy wynik: AI infrastructure ma istotnie wyższy średni Sharpe Ratio niż każda z trzech pozostałych grup. Między AI platforms, Broad tech i Defensive nie widać istotnych różnic w parach.

Wykres — Sharpe per grupa.



3.6 Wyniki — zmienna uzupełniająca: CAPM alpha

Założenia. Wszystkie grupy spełniają normalność (Shapiro $p > 0,05$); Levene stat = 2,57; $p = 0,066$ — nieznacznie powyżej α , wariacje uznajemy za jednorodne. Decyzja: **ANOVA + Tukey HSD**.


ANOVA jednoczynnikowa. $F(3, 37) = 7,621$; $p = 4,3 \cdot 10^{-4}$; $\eta^2 = 0,382$; $\omega^2 = 0,326$. Odrzucamy H_0 z silnym efektem ($\omega^2 \approx 0,33$).

Tukey HSD (FWER = 0,05). Różnica oznacza średnią grupy 1 minus średnią grupy 2.


Grupa 1	Grupa 2	różnica α (1–2)	p_{adj}	95% CI	istotne
AI infra	AI platforms	+0,226	0,0004	[+0,089; +0,363]	tak
AI infra	Broad tech	+0,183	0,0049	[+0,046; +0,320]	tak
AI infra	Defensive	+0,108	0,1665	[−0,029; +0,245]	nie
AI platforms	Broad tech	−0,043	0,8450	[−0,183; +0,098]	nie
AI platforms	Defensive	−0,118	0,1247	[−0,259; +0,022]	nie
Broad tech	Defensive	−0,076	0,4791	[−0,216; +0,065]	nie

Najważniejszy wynik: Dla CAPM alpha przewaga AI infrastructure jest istotna względem AI platforms i Broad tech, ale nie względem Defensive. To sugeruje, że sama premia AI nie jest równomiernie rozłożona między wszystkie spółki technologiczne.

Wykres — CAPM alpha per grupa.



Forest plot — różnice metryk vs grupa Defensive.



3.7 Kontrola odporności — Kruskal-Wallis + Dunn

Ze względu na małe próby w grupach ($n = 10\text{--}11$) dodatkowo sprawdzono nieparametryczny odpowiednik analizy wariancji. Wyniki są spójne z ANOVA:

Zmienna	Kruskal H	p -value	Wniosek
Sharpe Ratio	12,880	0,0049	różnice między grupami istotne
CAPM alpha	13,971	0,0029	różnice między grupami istotne

Test Dunna z korektą Bonferroniego lokalizuje różnice podobnie jak Tukey: dla Sharpe istotne są pary AI infrastructure vs AI platforms ($p = 0,0104$), AI infrastructure vs Broad tech ($p = 0,0317$) oraz AI infrastructure vs Defensive ($p = 0,0424$). Dla CAPM alpha istotne są AI infrastructure vs AI platforms ($p = 0,0036$) oraz AI infrastructure vs Broad tech ($p = 0,0202$), natomiast różnica AI infrastructure vs Defensive pozostaje nieistotna ($p = 0,3445$).

Najważniejszy wynik: Nieparametryczna kontrola odporności potwierdza główną strukturę wniosków z ANOVA. Zadanie 2 jest więc silniejsze metodologicznie niż Zadania 1 i 3, ponieważ łączy ocenę relacji zysku do zmienności przez Sharpe Ratio z kontrolą ryzyka systematycznego przez CAPM alpha.

3.8 Interpretacja

- **Zmienna:** Sharpe Ratio (główna) oraz CAPM alpha (uzupełniająca) liczone per spółka na dziennych log-zwrotach 2021–2026; $n = 41$ spółek w 4 grupach.
- **Test zastosowany:** ANOVA + Tukey HSD (oba przypadki: założenia spełnione według testów formalnych) oraz kontrola nieparametryczna Kruskal-Wallis + Dunn.
- **Wynik (Sharpe):** $F(3, 37) = 4,96$; $p = 0,005$; $\omega^2 = 0,23$. Tukey lokalizuje różnice: AI infrastructure ma istotnie wyższy średni Sharpe Ratio niż każda z pozostałych grup; pozostałe trzy grupy nie różnią się między sobą.
- **Wynik (alpha):** $F(3, 37) = 7,62$; $p = 4,3 \cdot 10^{-4}$; $\omega^2 = 0,33$. AI infrastructure ma istotnie wyższą α niż AI platforms i Broad tech; różnica względem Defensive jest dodatnia, ale nie osiąga istotności statystycznej ($p = 0,17$). Defensive ma $\alpha \approx 0$, przy wyraźnie niższym poziomie ryzyka.

- **Decyzja statystyczna:** odrzucamy H_0 w obu testach.
- **Interpretacja ekonomiczna:** wyniki sugerują, że premia AI ma wyraźny charakter *sektorowy* (półprzewodniki i sprzęt) — platformy chmurowe (MSFT, GOOGL, AMZN itd.) nie wyróżniły się istotnie ani Sharpe Ratio, ani α względem reszty rynku. Jedną z możliwych interpretacji jest taka, że hyperscalerzy ponoszą wysokie nakłady inwestycyjne na infrastrukturę AI, natomiast dostawcy półprzewodników i sprzętu są jej bezpośrednimi beneficjentami przychodowymi.

Ograniczenie próby. Liczebności grup są niewielkie i nierówne (11 spółek w AI infrastructure oraz po 10 spółek w pozostałych grupach). Jest to próba dobrana *celowo* (reprezentatywne spółki z ekspozycją na dany typ ryzyka/tematu inwestycyjnego), a nie losowo z populacji. Wnioski statystyczne dotyczą analizowanej próby i okresu 2021–2026 — nie należy ich uogólniać na „cały rynek”. Dodatkowo grupy Broad tech i Defensive są sektorowo niejednorodne wewnętrznie, co zwiększa wariancję wewnątrzgrupową i tym samym zmniejsza moc testu.

4 Zadanie 3 — A/B testing na próbach zależnych wokół 30.11.2022

4.1 Opis zmiennych i schemat A/B

Zdarzenie: **publiczna premiera ChatGPT, 30.11.2022** — przyjęta jako data rozpoczęcia masowej fazy boomu generatywnej AI. Próba: 21 spółek z połączonej grupy „AI” = AI infrastructure $\cup$ AI platforms (11 + 10 = 21 spółek).

Dla każdej spółki i liczymy dwie wartości prostego zwrotu względem SPY:

- **Wariant A:** $\bar{S}_i^{(A)}$ — średni dzienny spread względem SPY w oknie K sesji *przed* 30.11.2022,
- **Wariant B:** $\bar{S}_i^{(B)}$ — średni dzienny spread względem SPY w oknie K sesji *po* 30.11.2022.

Jednostką pary jest *ta sama spółka*. Próby są więc zależne (paired). Statystyka testowa: $d_i = \bar{S}_i^{(B)} - \bar{S}_i^{(A)}$.

Ograniczenie doboru próby. Grupa zdarzeniowa została zdefiniowana z perspektywy projektu przygotowanego po boomie AI. Oznacza to ryzyko *look-ahead bias*: w zestawie znajdują się spółki rozpoznane już *ex post* jako beneficjenci trendu AI (np. infrastruktura GPU i serwerów). Test przed-po dla tak dobranej grupy może zawyżać efekt zdarzenia, bo analizuje częściowo historycznych zwycięzców, a nie portfel skonstruowany wyłącznie na podstawie informacji dostępnych 30.11.2022.

4.2 Hipotezy badawcze

- H_0 : $\mu_d = 0$ — średnia różnica spreadów względem SPY między wariantem B i A wynosi zero.
- H_1 : $\mu_d \neq 0$.

4.3 Procedura statystyczna

1. Test normalności różnic d_i (Shapiro-Wilk).
2. **Test główny:** paired t -test (jeśli różnice normalne).
3. **Test odporności:** Wilcoxon signed-rank (zawsze raportowany). W przypadku odrzucenia normalności Wilcoxon staje się testem głównym.
4. Wielkość efektu: Cohen’s $d_z = \bar{d}/s_d$; 95% przedział ufności dla $\bar{d}$ (rozkład t z $n - 1$ stopniami swobody).
5. **Analiza wrażliwości** na długość okna: $K \in \{30, 60, 120, 250\}$ sesji. Okno bazowe: $K = 120$ (6 miesięcy ekspozycji *ex post*).
6. **Placebo test:** cała procedura powtórzona dla daty 30.11.2021 (rok przed boomem AI). W dobrze wyspecyfikowanym modelu placebo powinno być nieistotne. Istotny wynik placebo interpretujemy jako ostrzeżenie, że prosty spread względem SPY nie usuwa trendów i różnic w ryzyku systematycznym.

4.4 Kod źródłowy (fragment)

```
1
2 ALPHA = 0.05
3 WINDOWS = [30, 60, 120, 250]
4 PRIMARY_WINDOW = 120
5
6
7 def select_windows(returns_idx: pd.DatetimeIndex, event: pd.Timestamp, k: int):
8     days = returns_idx[returns_idx != event]
9     before = days[days < event][-k:]
```



```

10     after = days[days > event][:k]
11     return before, after
12
13
14 def per_stock_paired(ar_df: pd.DataFrame, event: pd.Timestamp, k: int) -> pd.DataFrame:
15     before, after = select_windows(ar_df.index, event, k)
16     rows = []
17     for t in ar_df.columns:
18         mb = ar_df.loc[before, t].dropna().mean()
19         ma = ar_df.loc[after, t].dropna().mean()
20         rows.append({"ticker": t, "mean_A_before": mb, "mean_B_after": ma, "diff_B_minus_A": ma
21                     - mb})
22     df = pd.DataFrame(rows)
23     df["window_sessions"] = k
24     df.attrs["window_before"] = (before[0], before[-1]) if len(before) else None
25     df.attrs["window_after"] = (after[0], after[-1]) if len(after) else None
26     return df
27
28 def paired_summary(diffs: np.ndarray, alpha=ALPHA) -> dict:
29     diffs = np.asarray(diffs, dtype=float)
30     n = len(diffs)
31     mean_d = float(diffs.mean())
32     sd_d = float(diffs.std(ddof=1))
33     se_d = sd_d / np.sqrt(n)
34     W_sh, p_sh = st.shapiro(diffs)
35     t_crit = st.t.ppf(1 - alpha / 2, n - 1)
36     ci_low, ci_high = mean_d - t_crit * se_d, mean_d + t_crit * se_d
37     cohen_dz = mean_d / sd_d if sd_d > 0 else np.nan
38     t_stat, t_p = st.ttest_1samp(diffs, 0.0)
39     w_stat, w_p = st.wilcoxon(diffs, alternative="two-sided")
40     use_t = p_sh > alpha
41     main_test = "Paired t-test" if use_t else "Wilcoxon signed-rank"
42     main_stat = float(t_stat) if use_t else float(w_stat)
43     main_p = float(t_p) if use_t else float(w_p)
44     return {
45         "n": n, "mean_diff": mean_d, "sd_diff": sd_d, "se_diff": se_d,
46         "ci_low": ci_low, "ci_high": ci_high, "cohen_dz": cohen_dz,
47         "shapiro_W": float(W_sh), "shapiro_p": float(p_sh), "normal_diffs": bool(use_t),
48         "t_stat": float(t_stat), "t_p_value": float(t_p),
49         "wilcoxon_stat": float(w_stat), "wilcoxon_p_value": float(w_p),
50         "main_test": main_test, "main_stat": main_stat, "main_p_value": main_p,
51     }
52
53
54 def run_sensitivity(ar_df, event, windows, label):

```

4.5 Wyniki

Główny test — okno bazowe $K = 120$ sesji. Shapiro-Wilk: $W = 0,897$; $p = 0,0227$ — różnice odbiegają od rozkładu normalnego, więc testem głównym jest Wilcoxon, a paired t -test raportujemy jako wspierający.

$$\bar{d} = +0,00243; \quad 95\% \text{ CI: } [+0,00123; +0,00363]; \quad d_z = +0,92 \text{ (duży efekt);}$$

$$\text{Wilcoxon } p = 8,4 \cdot 10^{-5}; \quad \text{paired } t(20) = 4,11; \quad p = 4,2 \cdot 10^{-4}.$$


Oba testy zgodnie odrzucają H_0 .

Najważniejszy wynik: W oknie bazowym 120 sesji różnica po-przed jest dodatnia i istotna, ale istotny test placebo oznacza, że model referencyjny jest zbyt prosty. Wynik Zadania 3 jest sygnałem opisowym, nie mocnym dowodem event-study.


Pełna analiza wrażliwości + placebo.

Wariant	K	$\bar{d}$	95% CI	d_z	p (główny)	test
Event: 30.11.2022 (premiera ChatGPT)						
event	30	-0,00177	[-0,00502; +0,00149]	-0,25	0,2707	paired t
event	60	+0,00147	[-0,00024; +0,00317]	+0,39	0,0760	Wilcoxon
event	120	+0,00243	[+0,00123; +0,00363]	+0,92	$8,4 \cdot 10^{-5}$	Wilcoxon
event	250	+0,00231	[+0,00143; +0,00319]	+1,20	$< 10^{-4}$	paired t
Placebo: 30.11.2021 (rok przed boomem AI)						
placebo	30	-0,00385	[-0,00672; -0,00098]	-0,61	0,0110	paired t
placebo	60	-0,00290	[-0,00447; -0,00134]	-0,84	0,0010	paired t
placebo	120	-0,00260	[-0,00412; -0,00108]	-0,78	0,0020	paired t
placebo	250	-0,00156	[-0,00248; -0,00064]	-0,77	0,0021	paired t

Wykres — histogram różnic + sensitivity z placebo.



Event-window spread vs SPY — portfele EW per grupa wokół 30.11.2022.



4.6 Interpretacja

- **Zmienna:** $d_i = \bar{S}_i^{(B)} - \bar{S}_i^{(A)}$ dla $n = 21$ spółek z grupy AI; $\bar{S}$ to średni dzienny spread względem SPY w oknie K sesji.
- **Test zastosowany:** Wilcoxon signed-rank (główny, bo Shapiro odrzucił normalność dla okna 120) + paired t -test (wspierający).

- **Wynik (okno bazowe $K = 120$):** $\bar{d} = +0,243$ p.p. *dziennie*; 95% CI $[+0,123; +0,363]$ p.p.; $d_z = +0,92$ (duży efekt); Wilcoxon $p = 8,4 \cdot 10^{-5}$.
- **Decyzja statystyczna:** odrzucamy H_0 z wysokim marginesem dla okien 120 i 250 sesji. Brak istotności dla okna 30 sesji i istotność dla dłuższych okien sugerują, że dodatni efekt w danych rozwijał się stopniowo, ale przy obecnej specyfikacji nie można rozstrzygnąć, czy wynikał z samego zdarzenia, zmiany reżimu rynkowego, czy innych czynników technologicznych.
- **Placebo:** dla 30.11.2021 efekt jest *ujemny i istotny* we wszystkich oknach. Nie wzmacnia to interpretacji przyczynowej. Przeciwnie: falsyfikuje prostą specyfikację spreadów względem SPY i pokazuje, że metoda przed-po wychwytytuje także silne trendy rynkowe, np. spadki technologii w okresie 2021/2022.
- **Interpretacja ekonomiczna:** po publicznej premierze ChatGPT spółki z grupy AI generowały średnio o ok. 0,24 p.p. *dziennie* wyższy spread względem SPY niż w analogicznym oknie przed premierą. Prosta annualizacja tej średniej ($0,243\% \times 252$) daje ok. 61 p.p. rocznie. Ponieważ operujemy na log-zwrotach, taka liniowa agregacja jest matematycznie spójna jako przybliżenie addytywne. Nie należy jej jednak czytać jako prognozy ani jako oczekiwanej rocznej stopy zwrotu; to historyczny, lokalny efekt w bardzo specyficznym oknie.

Ograniczenia. Analiza ma charakter *uproszczonego testu A/B przed-po*: nie modeluje oczekiwanego abnormal returnu względem CAPM ani modelu czynnikowego (Fama-French 3/5 czynników); raportujemy jedynie spready względem SPY. Istotny wynik placebo oraz dobór grupy zdarzeniowej ex post istotnie ograniczają siłę wnioskowania.

Uwaga interpretacyjna: Po uwzględnieniu testu placebo wniosek z Zadania 3 musi być sceptyczny: dodatni efekt po 30.11.2022 istnieje w danych, ale prosta specyfikacja nie pozwala przypisać go jednoznacznie premierze ChatGPT ani „czystej” premii AI.

4.7 Dodatkowa kontrola odporności — CAPM-adjusted returns

Jako minimalną kontrolę problemu $\beta \neq 1$ przeliczono kluczowe wyniki po korekcie CAPM. Dla portfeli i spółek estymowano betę na danych *przed* analizowaną datą: dla eventu przed 30.11.2022, a dla placebo przed 30.11.2021, aby ograniczyć look-ahead bias w samej korekcie. Dzienny komponent skorygowany liczono jako:

$$AR_t^{CAPM} = (r_t - r_{f,t}) - \hat{\beta}_{pre} (r_t^{SPY} - r_{f,t}).$$

Korekta CAPM zakłada zerową alfę w modelu CAPM; nie jest to pełny market model z estymowanym interceptem. Nie jest to także event study z modelem wieloczynnikowym, ale pozwala sprawdzić, czy podstawowe wnioski przetrwają najprostszą korektę o ryzyko systematyczne.

Analiza	Metryka	Spread vs SPY	CAPM-adjusted
Zad. 1	różnica średnich	+3,73 p.p./mies.	+2,23 p.p./mies.
Zad. 1	<i>p</i> -value	0,0079	0,0685
Zad. 3 event $K = 120$	$\bar{d}$	+0,243 p.p./dzień	+0,225 p.p./dzień
Zad. 3 event $K = 120$	95% CI	[+0,123; +0,363]	[+0,107; +0,342]
Zad. 3 event $K = 120$	d_z	+0,921	+0,871
Zad. 3 event $K = 120$	<i>p</i> -value / test	$8,4 \cdot 10^{-5}$ / Wilcoxon	$1,6 \cdot 10^{-4}$ / Wilcoxon
Zad. 3 placebo $K = 120$	$\bar{d}$	−0,260 p.p./dzień	−0,162 p.p./dzień
Zad. 3 placebo $K = 120$	95% CI	[−0,412; −0,108]	[−0,309; −0,015]
Zad. 3 placebo $K = 120$	d_z	−0,777	−0,501
Zad. 3 placebo $K = 120$	<i>p</i> -value / test	0,0020 / paired <i>t</i>	0,0327 / paired <i>t</i>

W Zadaniu 1 korekta CAPM istotnie osłabia wynik: różnica pozostaje dodatnia, ale przy $\alpha = 0,05$ nie jest już statystycznie istotna. To potwierdza, że część prostego spreadu względem SPY była

związana z wysoką betą portfela AI infrastructure. W Zadaniu 3 wynik pozostaje dodatni i istotny także po korekcie CAPM. Jednocześnie CAPM-adjusted placebo nadal jest istotne statystycznie ($p = 0,0327$), choć słabsze niż placebo na prostym spreadzie. Oznacza to, że korekta CAPM nie wystarcza do usunięcia problemu placebo: metoda nadal wychwytuje reżimy rynkowe/trendy, więc nie pozwala na mocne wnioskowanie przyczynowe. Nadal obowiązują wcześniejsze zastrzeżenia: look-ahead bias w doborze spółek, model jednoczynnikowy oraz brak pełnego modelu Fama-French / market model z interceptem.

5 Pre-event AI Exposure Score z raportów 10-K (centralna innowacja)

5.1 Motywacja

Standardowe klasyfikacje spółek jako „AI-related” powstają po fakcie i są podatne na look-ahead bias: do grupy wpadają firmy uznane za beneficjentów AI boom dopiero w okresie 2023–2025. Aby częściowo ograniczyć ten problem, wprowadzamy własną *pre-event* miarę ekspozycji każdej spółki na sztuczną inteligencję, zbudowaną wyłącznie z dokumentów dostępnych publicznie *przed* 30.11.2022. Miara ta służy następnie jako zmienna objaśniająca w cross-sectional regression post-event abnormal returns (sekcja 6).

5.2 Dane wejściowe — 10-K SEC

Dla każdej z 41 spółek pobrano *najnowszy* formularz 10-K złożony publicznie przed 30.11.2022 (foreign filers TSM i ASML — 20-F). Źródło: SEC EDGAR submissions API z User-Agent zawierającym kontakt grupy zgodnie z polityką *fair access*. Filtr: `filing_date < 2022-11-30`. Pełna metadata (CIK, accession number, filing date, period of report) w `data_cache/10k_metadata.csv`; surowe teksty po ekstrakcji z iXBRL/HTML w `data_cache/10k_filings/`. Skrypt: `src/sec_edgar_fetcher.py`.

5.3 Konstrukcja deterministyczna — specyfikacja główna

Dla każdej spółki liczymy liczbę wystąpień fraz z dwóch słowników:

Słownik konserwatywny (main) — terminy obecne w finansowym dyskursie pre-2022, chroniące przed *semantic look-ahead bias*:

artificial intelligence, machine learning, deep learning, neural network, natural language processing, computer vision, predictive analytics, autonomous systems, recommendation system, data science, automation, algorithmic decision-making.

Słownik rozszerzony (robustness) — terminy spopularyzowane post-ChatGPT:

generative AI, large language model, foundation model, transformer model, inference, training compute, AI accelerator.

Termin GPU — liczony kontekstowo tylko gdy w oknie ± 50 słów występuje co najmniej jeden z: AI / machine learning / training / inference / data center / accelerator / neural network / deep learning. Bez kontekstu GPU może oznaczać gaming chips bez związku z AI.

Normalizacja : $\text{mentions_per_10k} = \frac{\text{raw_count}}{\text{doc_length}/10000}$; następnie $\log(1 + \cdot)$, winsoryzacja [1%, 99%], percentile rank po próbie 41 spółek. Wynik: `ai_exposure_det_main` $\in [0, 1]$. Percentile rank chroni przed dominacją outlierów (np. NVDA) i jest interpretowalny jako „w którym kwantylu ekspozycji AI plasuje się spółka” względem analizowanej próby.

5.4 Walidacja LLM (Claude Haiku, robustness)

Dla każdej spółki generujemy wycinki zdań zawierające terminy AI ze słowników i przekazujemy do modelu Anthropic Claude Haiku (slug API: `claude-haiku-4-5`; pełna nazwa wersji modelu logowana w `data_cache/llm_raw_responses.jsonl`), przy `temperature=0` i fixed prompt SHA-256. Prompt klasyfikacyjny 0–3 (brak / marginalna wzmianka / istotny element / core business). Wszystkie raw responses i metadane (model version, prompt hash, timestamp) zapisywane do

data_cache/llm_raw_responses.jsonl. Skrypt: src/llm_classifier.py z flagą -no-llm dla pełnej reprodukcji bez API key.

Wynik walidacji LLM. Pipeline LLM uruchomiono dla pełnej listy 41 spółek, natomiast faktyczne wywołanie klasyfikacyjne wykonano **tylko dla 34 spółek**, dla których skrypt znalazł fragmenty zawierające frazy ze słownika konserwatywnego. Dla pozostałych 7 spółek (AAPL, PG, MRK, MCD, COST, CL, GIS) brak excerptów potraktowano jako *brak wystarczającego materiału do klasyfikacji LLM* i zapisano `ai_exposure_llm = NaN`. Wszystkie surowe odpowiedzi z metadanymi (model version, prompt SHA-256, timestamp) są zapisane w data_cache/llm_raw_responses.jsonl, co pozwala na pełną reprodukcję analizy bez ponownego wywoływania API. W robustness checks (sekcja 7) testujemy także wariant `ai_exposure_llm_missing0`, w którym brakujące wartości zastępujemy zerem, aby sprawdzić wrażliwość wyniku na samo-selekcję pod próby.

Korelacja Spearmana `det_main` vs `llm`: $\rho = 0,463$ ($n = 34$). Umiarkowana, dodatnia korelacja oznacza, że *obie miary uchwytują częściowo różne aspekty* pre-event AI exposure: `det_main` łapie literalne występowanie fraz słownikowych, `llm` łapie semantyczny sens (na skali 0–3 odpowiadającej kategoriom brak / marginalna wzmianka / istotny element / core business).

Najciekawsze rozbieżności (wybór z 34 ważnych obserwacji).

Ticker	det_main	llm	Komentarz
NVDA	1,00	1,00	spójne — core business AI
MSFT	0,46	1,00	LLM widzi semantykę AI w działalności cloud, mimo mniejszej liczby literalnych fraz
GOOGL	0,46	1,00	analogicznie — LLM identyfikuje ekspozycję AI w działalności search/cloud
ADBE	0,83	1,00	LLM interpretuje AI jako istotny komponent działalności software/creative tools
TXN	1,00	0,00	LLM identyfikuje analog/embedded jako non-AI mimo wysokiej liczby fraz słownikowych
AAPL	0,00	NaN	brak fraz w 10-K → brak excerptów do LLM

Powyższe komentarze interpretują wyłącznie zawartość 10-K dostępnych *przed* 30.11.2022; nie odnoszą się do żadnych konkretnych produktów spółek wprowadzonych w późniejszym okresie.

Najważniejszy wynik: LLM validation potwierdza ogólny kierunek deterministycznego scoringu ($\rho = 0,46$), ale ujawnia istotne rozbieżności semantyczne (MSFT, GOOGL, TXN). To jest dokładnie typ *measurement risk*, który motywował naszą decyzję o pre-rejestracji deterministic scoru jako specyfikacji głównej i LLM jako miary robustness — a nie arbitralnym mixu (np. 0.6/0.4). Wyniki LLM służą jako uczciwie raportowane uzupełnienie, nie jako sterownik narracji. Pełna analiza obu miar w robustness checks (sekcja 7).

Statystyki opisowe per grupa.

Grupa	n	średnia S	odch. std.	min	max
AI infrastructure	11	0,499	0,249	0,195	1,000
AI platforms	10	0,734	0,188	0,415	0,976
Broad technology	10	0,641	0,250	0,098	0,951
Defensive control	10	0,176	0,107	0,098	0,366

Top 10 spółek wg ai_exposure_det_main. NVDA 1,00, IBM 0,98, PANW 0,95, SNOW 0,93, NOW 0,90, INTU 0,88, ADBE 0,85, ACN 0,83, AVGO 0,81, ADSK 0,78.

Najważniejszy wynik: Nowa miara plasuje NVDA na pierwszym miejscu, a klasyczne FMCG/healthcare na ostatnim — co stanowi sanity check sensowności konstrukcji.

Paradoks AI platforms vs AI infrastructure. Istotnym wynikiem samym w sobie jest fakt, że **najwyższą średnią ujawnioną ekspozycję AI mają AI platforms (0,73), a nie AI infrastructure (0,50)** — mimo że to drugi segment wygenerował później dramatycznie wyższe stopy zwrotu. Oznacza to, że rynek po 30.11.2022 nie nagradzał po prostu firm najczęściej raportujących AI w 10-K. Najsilniejsze zwroty pojawiły się raczej w segmencie infrastrukturalnym, który był bezpośrednim beneficjentem capexu na obliczenia, GPU i data centers. To osłabia prostą interpretację „więcej AI disclosure = większa premia” i wspiera główną tezę raportu o ryzyku prostych narracji łączących disclosure z post-event returns.

Obserwacja wymagająca komentarza. AAPL w 10-K za FY2022 ma 0 wystąpień z naszego konserwatywnego słownika, mimo że jest powszechnie uznawany za firmę z istotną ekspozycją na technologie AI/ML. Jest to prawdopodobnie efekt językowy: Apple unika żargonu „machine learning” w SEC filings i częściej używa frazeologii produktowej lub ogólnych określeń inteligencji urządzeń. Tego typu efekty są nieuniknione w dictionary-based NLP i ilustrują, dlaczego walidacja LLM jest cenna jako miara robustness.

6 Cross-sectional regression: AI Premium AI Exposure

6.1 Specyfikacja

Cross-sectional OLS na próbie $n = 41$ spółek:

$$AR_i = \beta_0 + \beta_1 \cdot AI_Exposure_i + \gamma' \mathbf{X}_i + \varepsilon_i,$$

gdzie:

- AR_i — post-event abnormal return spółki i , w specyfikacji głównej 6-miesięczny (2022-11-30 $\rightarrow$ 2023-05-31);
- $AI_Exposure_i$ — `ai_exposure_det_main` z sekcji 5;
- $\mathbf{X}_i$ — kontrole liczone z okna pre-event (2021-01-01 $\rightarrow$ 2022-11-29): β_{pre} , annualized volatility, momentum 12M, `log(market_cap)`.

Cztery zagnieżdżone modele (parsymonia przy $n = 41$ — bez 11 GICS dummies, bez interakcji):

Model	Specyfikacja
M1	AI_Exp
M2	+ β_{pre} + vol_pre
M3	+ momentum 12M
M4	+ log market cap

6.2 Inference

Dla każdego modelu raportujemy łącznie:

- OLS standardowy SE i White (HC1) robust SE (White, 1980),
- bootstrap 95% CI dla β_1 ($B = 10\,000$, ziarno 42),
- współczynnik determinacji R^2 .

Zgodnie z pre-rejestracją: „Given the small cross-section, inference is interpreted through coefficient direction, economic magnitude, confidence intervals, and robustness across specifications rather than through mechanical significance thresholds.”


6.3 Wyniki głównej regresji

Model	n	R^2	$\hat{\beta}_1$	HC1 SE	95% CI HC1	95% CI boot
M1	41	0,094	+0,259*	0,129	[+0,007; +0,512]	[+0,017; +0,515]
M2	41	0,439	−0,009	0,108	[−0,221; +0,203]	[−0,219; +0,231]
M3	41	0,447	+0,013	0,112	[−0,206; +0,232]	[−0,192; +0,274]
M4	41	0,535	+0,044	0,109	[−0,169; +0,257]	[−0,150; +0,296]


* $p_{HC1} = 0,044$ dla M1; $p > 0,68$ dla M2–M4.

Najważniejszy wynik: β_1 jest istotnie dodatnia w *prostej* regresji bez kontroli ryzyka (M1: +0,26, $p = 0,044$), ale **całkowicie zanika** po dodaniu β_{pre} i pre-event volatility (M2–M4: $|\hat{\beta}_1| < 0,05$, wszystkie $p > 0,68$). Jednocześnie R^2 rośnie z 0,09 do 0,54 — to znaczy, że **większość wyjaśnionej zmienności w M4 pochodzi z kontroli ryzyka i charakterystyk pre-event** (zwłaszcza beta i volatility), a nie z samej miary ekspozycji na AI.

Wykres scatter + linia OLS z M1.



Coefficient plot $\hat{\beta}_1$ per model.



6.4 Macierz korelacji zmiennych regresji

	AI_Exp	beta	vol	mom12	log_mc	AR_6m
AI_Exp	1,00					
beta_pre	+0,50	1,00				
vol_pre	+0,48	+0,93	1,00			
mom_12m_pre	-0,49	-0,70	-0,63	1,00		
log_mkt_cap	+0,03	+0,15	-0,02	-0,30	1,00	
AR_6m	+0,31	+0,61	+0,66	-0,36	+0,22	1,00

6.5 Diagnostyka multicollinearity (VIF, M4)

Zmienna	VIF
ai_exposure_det_main	1,42
beta_pre	9,31
vol_pre	8,41
momentum_12m_pre	2,29
log_market_cap	1,35

6.6 Interpretacja

Macierz korelacji bezpośrednio dokumentuje mechanizm znikania efektu w M2–M4: **AI Exposure jest dodatnio skorelowane z pre-event betą (+0,50) i zmiennością (+0,48)**, a te z kolei są bardzo silnymi predyktorami AR_6m (odpowiednio +0,61 i +0,66). Po dodaniu beta i vol do modelu większość cross-sectional wariancji AR_6m zostaje wyjaśniona przez kontrole ryzyka, a sam komponent „AI exposure” nie wnosi już istotnej dodatkowej informacji.

VIF wskazują na **istotną współliniowość** między *beta* i *vol* ($\rho = 0,93$, $VIF \approx 8-9$). Nie podważa to głównego wniosku, ale sugeruje, że indywidualnych współczynników dla *beta* i *volatility* nie należy interpretować oddzielnie — w tej pracy pełnią one rolę **łącznego bloku kontroli ryzyka**. Sama AI Exposure ma niski VIF (1,42), więc nie cierpi z powodu collinearity z innymi predyktorami — oznacza to, że brak istotności $\hat{\beta}_1$ w M2–M4 **nie wygląda na prosty artefakt technicznej współliniowości** AI Exposure z pozostałymi predyktorami. Nadal jednak należy interpretować go ostrożnie ze względu na małą próbę i szerokie przedziały ufności. Wobec $n = 41$ wyniki regresji interpretujemy **przede wszystkim** przez stabilność współczynników i przedziały ufności, a nie precyzyjną identyfikację przyczynową.


Wniosek metodologiczny. *Prima facie* AI exposure wydaje się tłumaczyć post-event premium, ale po wprowadzeniu kontroli ryzyka sam komponent disclosure-based AI exposure nie ma wykrywalnego niezależnego wpływu na 6-miesięczne abnormal returns. To jest dokładnie typ wniosku, którego nie wygenerowała prostsza analiza Zadania 1 (między-portfelowa) ani Zadania 3 (przed/po).

7 Robustness checks dla cross-sectional regresji

Pre-rejestrowane (docs/PRE_REGISTRATION.md, sekcja 9): leave-one-out, excluding extreme firms, alternative AI scores, alternative windows i alternative scaling. Wszystkie sprawdzane na baseline M3.

7.1 (1) Leave-one-out

41 regresji, każda bez jednej spółki. Baseline M3 $\hat{\beta}_1 = +0,013$. **7 z 41 LOO regresji odwraca znak $\hat{\beta}_1$ (17%)** — $\hat{\beta}_1 \in [-0,036; +0,081]$, mediana $+0,013$. Najbardziej wpływową: **IBM** (AI_platforms) — po jej wykluczeniu $\hat{\beta}_1 = +0,081$.



7.2 (2) Excluding extreme firms (M3)

Wariant	n	$\hat{\beta}_1$	p_{HC1}	95% CI
full sample	41	+0,013	0,909	$[-0,206; +0,232]$
bez NVIDIA	40	-0,036	0,721	$[-0,234; +0,162]$
bez top-3 AI exposure	38	+0,059	0,649	$[-0,196; +0,315]$
bez top-3 post-event AR	38	+0,005	0,949	$[-0,155; +0,166]$
bez bottom-3 AR	38	+0,082	0,503	$[-0,158; +0,321]$

Obserwacja. Bez NVIDIA znak się odwraca (z $+0,013$ na $-0,036$), choć wszystkie warianty pozostają nieistotne. To uczciwe pokazanie, że nawet mały efekt dodatni w M3 jest częściowo napędzany przez pojedynczą obserwację.

7.3 (3) Alternative AI scores (M3)

Specyfikacja X	n	$\hat{\beta}_1$	p_{HC1}	95% CI
ai_exposure_det_main (główna)	41	+0,013	0,909	$[-0,206; +0,232]$
ai_exposure_det_main_gpu	41	+0,019	0,870	$[-0,207; +0,245]$
ai_exposure_det_main_no_automation	41	+0,044	0,710	$[-0,189; +0,277]$
ai_exposure_det_extended	41	+0,087	0,777	$[-0,514; +0,687]$
ai_exposure_llm (Claude Haiku)	34	+0,379**	0,0022	$[+0,136; +0,622]$
ai_exposure_llm_missing0 (NaN $\rightarrow$ 0)	41	+0,176*	0,0408	$[+0,007; +0,345]$

* $p < 0,05$; ** $p < 0,01$.

Cztery miary deterministyczne dają nieistotne $\hat{\beta}_1$ w M3 (w tym `no_automation`, co potwierdza, że szerokie pojęcie „automation” nie sterowało wynikiem). **Obie miary LLM-based są istotnie dodatnie po kontroli ryzyka:** na podpróbie $n = 34$ silnie ($\hat{\beta}_1 = +0,38$, $p = 0,002$), a w wariancie z brakami $= 0$ na pełnym $n = 41$ słabiej, ale nadal istotnie ($\hat{\beta}_1 = +0,18$, $p = 0,041$). Spadek o połowę między wariantami sugeruje, że samo-selekcja podpróby (wykluczenie 7 spółek o niskiej ekspozycji AI) wzmacnia ale nie tworzy efektu LLM.

Uwaga interpretacyjna: Wynik LLM-based ($n = 34$) wzmacniany jest samo-selekcją 7 spółek, głównie Defensive (PG, MRK, MCD, COST, CL, GIS) plus AAPL — systematycznie spółek o niskiej ekspozycji AI. Wariant `missing0` ($n = 41$) jest słabszy, ale wciąż istotny: samo-selekcja prawdopodobnie wzmacnia wynik LLM, a `missing0` **ogranicza obawę**, że efekt jest wyłącznie artefaktem podpróby, ale **nie usuwa ryzyka biasu pomiarowego** (zależność od prompta, wyboru excerptów, wersji modelu). Wynik traktujemy jako sygnał motywujący dalsze badania, nie jako rozstrzygnięcie tezy AI Premium.

Interpretacja merytoryczna. Rozbieżność deterministic (nieistotne) vs LLM (istotne na obu próbach) jest dokładnie tym, czego oczekiwaliśmy w sekcji 5 przy korelacji $\rho_{\text{Spearman}} = 0,46$: dwie miary uchwytują różne aspekty ekspozycji AI. Deterministic łapie literalne frazy, więc spółki o mniejszej ilości żargonu otrzymują niski score, mimo że LLM klasyfikuje je wyżej na skali ekspozycji. LLM score **może lepiej uchwycić semantyczną ekspozycję** firm, których dokumenty nie używają literalnego słownictwa AI. Nie można jednak traktować go jako bezpośredniego pomiaru rzeczywistej ekspozycji operacyjnej, ponieważ wynik zależy od prompta, wyboru excerptów, wersji modelu oraz systematycznego braku klasyfikacji dla części spółek.

7.4 (4) Alternative windows Y (M3)

Okno Y	$\hat{\beta}_1$	p_{HC1}	95% CI
3 miesiące	+0,012	0,828	[−0,098; +0,122]
6 miesięcy (główne)	+0,013	0,909	[−0,206; +0,232]
12 miesięcy	+0,254*	0,031	[+0,023; +0,485]





Ciekawa obserwacja. Dla 12-miesięcznego okna $\hat{\beta}_1$ staje się *istotnie* dodatnia (+0,25, $p = 0,031$, CI nie zawiera zera) nawet po kontroli ryzyka. To sugeruje, że *ile* z AI premium było fundamentalnie powiązane z disclosed exposure, ujawniało się dopiero w dłuższym horyzoncie. Ten wynik raportujemy jako pre-rejestrowany robustness check — nie jako efekt główny — bo specyfikacja długoterminowa jest bardziej narażona na confounding events (Q4 2023, rajdy NVDA w 2024).

7.5 (5) Alternative scaling X (M3)

Skala X	$\hat{\beta}_1$	p_{HC1}	95% CI
percentile rank (główna)	+0,013	0,909	[−0,206; +0,232]
z-score	+0,015	0,739	[−0,072; +0,101]
$\log(1 + \cdot)$	+0,019	0,756	[−0,102; +0,141]
raw mentions / 10k	+0,010	0,739	[−0,047; +0,067]

Wszystkie skale produkują niemal identyczne (zerowe) szacunki w M3.

Pełny wykres summary.



Najważniejszy wynik: Robustness checks potwierdzają wniosek z M3: po kontroli ryzyka $\hat{\beta}_1$ jest nieodróżnialna od zera dla większości specyfikacji. Jedynym istotnym wyjątkiem jest okno 12-miesięczne ($p = 0,031$), które sygnalizuje, że dłuższy horyzont może uwidocznić efekt fundamentalny — ale wymaga to oddzielnego badania z lepszą kontrolą confounding events.

8 Modele czynnikowe (CAPM / FF3 / Carhart 4) dla portfeli EW

8.1 Specyfikacja

Dla każdego z czterech portfeli równoważonych (EW) per grupa estymujemy trzy modele asset pricing na dziennych danych 2021-01-04 – 2026-03-31:

$$\text{CAPM: } r_i^p - r_f = \alpha + \beta_{\text{MKT}}(\text{Mkt-RF}) + \varepsilon$$

$$\text{FF3: } r_i^p - r_f = \alpha + \beta_{\text{MKT}}(\text{Mkt-RF}) + \beta_{\text{SMB}}\text{SMB} + \beta_{\text{HML}}\text{HML} + \varepsilon$$

$$\text{Carhart 4: } r_i^p - r_f = \alpha + \beta_{\text{MKT}}(\text{Mkt-RF}) + \beta_{\text{SMB}}\text{SMB} + \beta_{\text{HML}}\text{HML} + \beta_{\text{MOM}}\text{MOM} + \varepsilon$$

Czynniki: *Kenneth French Data Library* (F-F_Research_Data_Factors_daily + F-F_Momentum_Factor_daily), pobrane bezpośrednio z Tuck/Dartmouth. Risk-free w modelach czynnikowych = RF z serii Famy-Frencha (nie $\hat{IRX}$); decyzja udokumentowana w docs/decision_log.md (spójność z definicją RF użytą do konstrukcji Mkt-RF, SMB, HML, MOM). Inference: Newey-West HAC SE (maxlags = 5) (Newey i West, 1987).


8.2 Wyniki — annualized α per grupa

Grupa	CAPM		FF3		Carhart 4	
	$\hat{\alpha}$	p_{HAC}	$\hat{\alpha}$	p_{HAC}	$\hat{\alpha}$	p_{HAC}
AI infrastructure	+0,087	0,41	+0,147	0,15	+0,132	0,19
AI platforms	−0,093	0,13	−0,044	0,39	−0,039	0,44
Broad tech	−0,089	0,05	−0,065	0,14	−0,062	0,16
Defensive	+0,026	0,62	−0,008	0,87	−0,003	0,95

Główne pytanie testowane : czy AI infrastructure ma trwałą α także po kontroli momentum?

Najważniejszy wynik: AI infrastructure ma dodatnią szacowaną alfę (+8,7 – +14,7% rocznie), ale w żadnym z trzech modeli (CAPM, FF3, Carhart 4) nie osiąga ona istotności na poziomie 0,10 przy HAC SE. Po dodaniu momentum $\hat{\alpha}$ *nieznacznie spada* (z +14,7% w FF3 do +13,2% w Carhart 4) — czyli momentum nie tłumaczy istotnej części portfelowej alfy, ale rozszerzenie modelu nie zmienia werdyktu o (nie)istotności. Pozostałe trzy grupy mają $\hat{\alpha}$ statystycznie nieodróżnialne od zera we wszystkich modelach.

Wykres.



8.3 Interpretacja

Wynik factor-model jest spójny z wnioskami cross-sectional regresji: AI Premium jest *wizualnie* obecne, ale modele czynnikowe nie dostarczają **wystarczająco precyzyjnego dowodu** na dodatnią alfę AI infrastructure. Szacunki alfy są dodatnie (+8,7% – +14,7% rocznie), ale przy HAC SE statystycznie nieodróżnialne od zera. To nie oznacza, że efekt nie istnieje — przy małej próbie ($n = 41$ spółek w 4 portfelach EW, 1300 sesji dziennych) moc testu może być ograniczona. Hipoteza H4 (pre-rejestrowana w docs/PRE_REGISTRATION.md sekcja 2) **nie znajduje silnego empirycznego wsparcia** przy obecnej próbie i specyfikacji ($\alpha = 0,10$).

Z perspektywy publikacyjnej oznacza to, że *rygorystyczna kontrola ryzyka systematycznego i momentum nie pozwala jednoznacznie odróżnić „AI Premium” od pasywnej premii high-beta growth w okresie 2022–2026.*

9 Dyskusja: model risk w AI-wspomaganej analityce inwestycyjnej

9.1 Co nasze wyniki znaczą

Trzy niezależne testy — Zadanie 2 (Sharpe + CAPM α), cross-sectional regression (sekcja 6) oraz factor models (sekcja 8) — prowadzą do spójnego wniosku: AI Boom Premium jest *widoczne* w surowych zwrotach, ale jego niezależność od klasycznych ekspozycji na ryzyko **nie jest stabilnie potwierdzona** w głównej specyfikacji.

Najważniejszy wynik: Dowody na samodzielną premię AI są mieszane i wrażliwe na specyfikację. W większości specyfikacji efekt znika po kontroli ryzyka systematycznego, ale w dwóch istotnych wariantach (LLM-based score oraz okno 12-miesięczne) wynik pozostaje statystycznie istotny.

Zadanie 2 pokazuje, że na poziomie metryk efektywności AI infrastructure istotnie dominuje (Sharpe), ale ta przewaga w CAPM α wymaga ostrożnej interpretacji (różnica vs Defensive nieistotna). Cross-sectional regression pokazuje, że *deterministyczna* pre-event AI exposure nie ma niezależnego efektu na 6-miesięczny post-event AR po kontroli ryzyka, ale *semantyczna* miara LLM-based pozostaje istotna ($\hat{\beta}_1 = +0,38$ na $n = 34$; $\hat{\beta}_1 = +0,18$ na $n = 41$ z missing=0). Factor models pokazują, że portfelowa alfa AI infrastructure pozostaje dodatnia, ale przy HAC SE nieodróżnialna od zera.

Bardziej trafny opis niż „AI rajduje wszystko” to: *post-event premium spółek AI infrastructure może w znacznej mierze odzwierciedlać premię za wysoką betę i wysoką zmienność technologicznego sektora, a niezależny komponent fundamentalny pozostaje statystycznie nieprecyzyjnie zmierzony przy obecnej próbie i specyfikacji.*

9.2 Powiązanie z literaturą

Nasz wynik wpisuje się w nurt event studies w finansach (MacKinlay, 1997; Brown i Warner, 1985) pokazujący, że proste spready względem benchmarku często wychwytyują reżimy makro/sektorowe. Loughran i McDonald (2011) pokazali wagę słownika domain-specific w analizie tekstu 10-K — nasza decyzja o słowniku konserwatywnym (pre-2022 terms) jest analogiczna do ich krytyki słowników general-purpose sentiment. Hoberg i Phillips (2016) wprowadzili text-based industry classification z 10-K; nasza miara AI Exposure to bliska duchem aplikacja dla pojedynczej technologicznej kategorii. Babina i in. (2024) i Eisfeldt i in. (2023) dokumentują związki AI adoption z firm-level outcomes; nasz wynik dodaje uwagę metodologiczną: *prosta klasyfikacja spółek jako AI-related ex post podatna jest na look-ahead bias, a kontrola ryzyka rynkowego znacząco zmienia obraz post-event premium.*

9.3 Co przeoczyła pierwsza wersja analizy generowana przez AI

Pierwsza wersja tego projektu (commitowana w repozytorium) raportowała „silny AI Boom Premium” na podstawie wyników Zadania 1 i 3 bez kontroli bety. Dopiero pogłębiona diagnostyka pokazała:

1. dramatyczną różnicę bet ($\beta_{AI} \approx 1,98$ vs $\beta_{Def} \approx 0,24$),
2. istotny test placebo, który falsyfikuje prostą specyfikację,
3. brak istotności $\hat{\beta}_1$ w M2–M4 cross-sectional regression,
4. brak istotności Carhart 4 alfy dla AI infrastructure portfolio.

To jest precyzyjnie scenariusz, przed którym ostrzega literatura model risk (Christensen i Miguel, 2018): surowy wynik jest spójny z apriorycznym oczekiwaniem („AI = premium”), a pre-registracja, kontrola ryzyka oraz robustness checks pokazują, że narracja jest słabsza, niż się wydaje.

9.4 Praktyczna implikacja dla inwestora

- Wybór ekspozycji do segmentu AI infrastructure w okresie 2022–2026 historycznie generował wysokie zwroty, ale przy bardzo wysokiej zmienności i głębokich obsunięciach.
- Nasza analiza nie wspiera tezy o „fundamentalnej alfie AI” niezależnej od ryzyka rynkowego — po kontroli czynników ryzyka segment AI był *nieistotnie* różny od pozostałych high-beta sektorów.
- Dla decyzji *ex ante* (a nie *ex post*) implikacja jest taka, że pure-play strategię AI w okresie 2022–2026 były równoważne strategiom high-beta growth z większą koncentracją.

Wnioski statystyczne po korekcie metodologicznej.

- **Zad 1.** Welch t-test odrzuca H_0 ($p = 0,0079$, Hedges’ $g = 0,59$): portfel AI infrastructure ma istotnie wyższą średnią miesięczną nadwyżkę względem SPY niż portfel Defensive po 30.11.2022 (+3,7 p.p./miesiąc). Jest to jednak wynik obciążony różnicą bet: AI infrastructure ma dużo wyższą ekspozycję rynkową niż Defensive. Po korekcie CAPM różnica spada do +2,23 p.p./miesiąc i nie jest już istotna na poziomie 5% ($p = 0,0685$).
- **Zad 2.** ANOVA odrzuca H_0 dla obu zmiennych: Sharpe ($F = 4,96$; $p = 0,005$; $\omega^2 = 0,23$) i CAPM α ($F = 7,62$; $p = 4 \cdot 10^{-4}$; $\omega^2 = 0,33$). Dla Sharpe Tukey wskazuje istotną przewagę AI infrastructure nad wszystkimi pozostałymi grupami; dla CAPM α przewaga AI infrastructure jest istotna względem AI platforms i Broad tech, ale nie względem Defensive. Kontrola Kruskal-Wallis + Dunn potwierdza ten układ wyników.
- **Zad 3.** Wilcoxon ($K = 120$): $p = 8,4 \cdot 10^{-5}$; $\bar{d} = +0,24$ p.p./dzień; 95% CI [+0,12; +0,36] p.p.; $d_z = +0,92$. Jednocześnie placebo test jest istotny statystycznie w przeciwnym kierunku, co jest sygnałem błędnej specyfikacji, a nie argumentem wzmacniającym przyczynowość. CAPM-adjusted robustness pozostaje dodatni i istotny ($\bar{d} \approx +0,225$ p.p./dzień, $p \approx 1,6 \cdot 10^{-4}$), ale CAPM-adjusted placebo również pozostaje istotne ($\bar{d} \approx -0,162$ p.p./dzień, $p \approx 0,0327$). Wynik jest spójny z hipotezą, ale jego interpretacja zależy od kontroli placebo i specyfikacji modelu.

Nowe wnioski z części publikacyjnej (sekcje 5–8).

- **Sekcja 5 (Pre-event AI Exposure z 10-K).** Zbudowano deterministyczną miarę ekspozycji każdej z 41 spółek na AI wyłącznie z dokumentów dostępnych *przed* 30.11.2022 (najnowsze 10-K przed cutoff date). NVDA na pierwszym miejscu rankingu, Defensive z najniższymi wartościami — sanity check sensowności konstrukcji.
- **Sekcja 6 (Cross-sectional regression).** W modelu M1 (bez kontroli) $\hat{\beta}_1 = +0,26$ ($p = 0,044$): wyższa AI exposure pozytywnie koreluje z 6-mies. post-event AR. Po dodaniu β_{pre} i pre-event volatility w M2–M4 efekt **całkowicie zanika** ($|\hat{\beta}_1| < 0,05$, wszystkie $p > 0,68$), a R^2 rośnie z 0,09 do 0,54. Główna teza: surowe „AI premium” to artefakt korelacji AI exposure z high-beta tilt.
- **Sekcja 7 (Robustness).** Leave-one-out: 7/41 sign changes (17%), najbardziej wpływową IBM. Bez NVIDIA znak $\hat{\beta}_1$ się odwraca. **Istotne odstępstwa od wyniku zerowego** w dwóch wariantach: (a) okno 12-miesięczne ($\hat{\beta}_1 = +0,25$, $p = 0,031$); (b) miara LLM-based zamiast deterministycznej ($\hat{\beta}_1 = +0,38$, $p = 0,002$, $n = 34$). Oba raportowane uczciwie jako pre-rejestrowane robustness checks, nie jako wynik główny. Sygnał LLM jest najmocniejszy, ale obciążony samo-selekcją 7 spółek bez excerptów.
- **Sekcja 8 (Factor models).** AI infrastructure portfolio ma dodatnią szacowaną alfę we wszystkich trzech modelach (CAPM/FF3/Carhart 4), +8,7 – +14,7% rocznie, ale w żadnym nie osiąga istotności na poziomie 0,10 przy HAC SE. Pozostałe trzy grupy mają $\hat{\alpha} \approx 0$ we wszystkich modelach.

Werdykt metodologiczny.

- Raport pokazuje silną historyczną przewagę spółek infrastruktury AI, ale nie dowodzi jednoznacznie istnienia czystej *AI Boom Premium* po kontroli wszystkich czynników ryzyka.
- Najsilniejszą częścią empiryczną jest **sekcja 6 (Cross-sectional regression)** oraz **sekcja 8 (Factor models)**: wspólnie pokazują, że *dowody na samodzielne AI Premium są niestabilne i zależne od specyfikacji po kontroli ryzyka*. Najwiarygodniejszy klasyczny test to Zadanie 2, ale wzbogacenie o pre-event AI Exposure Score zmienia narrację: nawet ten najlepiej kontrolowany wynik nie daje jednoznacznego dowodu czystej fundamentalnej premii AI.
- Zadania 1 i 3 należy traktować jako analizę opisową spreadów względem SPY. Ich wyniki są informacyjne, ale metodologicznie słabsze przez ukryte założenie $\beta = 1$, istotne placebo oraz look-ahead bias.
- Praktyczny take-away dla inwestora jest ostrożny: segment AI infrastructure był historycznie bardzo silny, ale przewaga była związana z wysoką zmiennością, wysoką betą i dużymi obsunięciami. Sama wielkość zwrotu nie uzasadnia dużej alokacji bez kontroli ryzyka.

10 Reproducibility note

Środowisko. Analizy wykonano w Pythonie. Dokładne wersje bibliotek zostały utrwalone w pliku `requirements.txt` oraz przez środowisko repozytorium. Kluczowe pakiety: `pandas`, `numpy`, `scipy`, `statsmodels`, `scikit-posthocs`, `matplotlib`, `seaborn`, `yfinance`, `pyarrow`.

Dane. Źródło: Yahoo Finance via `yfinance`. Pobranie: 2026-05-20. Cache lokalny: `data_cache/prices.parquet` (43 tickery $\times$ 1347 dni sesyjnych). Mapowanie ticker $\rightarrow$ grupa: `data_cache/metadata_tickers.csv`.

Skrypty (kolejność wykonania).

1. `src/data_fetch.py` — pobranie cen i zapis do parquet.
2. `src/task1_two_portfolios.py` — Zadanie 1.
3. `src/task2_four_groups.py` — Zadanie 2 (Sharpe i alpha).
4. `src/task3_paired_event.py` — Zadanie 3 (event + placebo + CAPM-adj).
5. `src/sec_edgar_fetcher.py` — pobranie 10-K z SEC EDGAR.
6. `src/nlp_ai_exposure.py` — deterministic AI Exposure Score.
7. `src/llm_classifier.py` — LLM validation (Claude Haiku; `-no-llm` dla pełnej reprodukcji bez API key).
8. `src/cross_sectional.py` — regresja M1-M4 + bootstrap.
9. `src/robustness.py` — LOO, exclude-firms, alt scores/windows/scaling.
10. `src/factor_models.py` — CAPM/FF3/Carhart 4 z HAC SE.
11. `src/plots_extra.py` — wykresy uzupełniające.

Moduły wspólne: `src/common.py` (wczytywanie, log returns, portfele EW, spready względem SPY, RF), `src/metrics.py` (7 metryk per spółka), `src/plot_utils.py` (style i zapis wykresów).

Dokumenty metodologiczne.

- docs/PRE_REGISTRATION.md — pre-rejestracja hipotez, modelu głównego, kontroli i robustness checks. Plik utworzony 2026-05-22 09:51 (timestamp systemu plików). Główna regresja cross-sectional (data_cache/cross_sectional_regression.csv) została wygenerowana 2026-05-22 16:21, czyli ok. 6,5 godziny później — co dokumentuje, że pre-rejestracja powstała przed uruchomieniem testów centralnych.
- docs/decision_log.md — chronologiczny rejestr decyzji analitycznych z uzasadnieniem.
- docs/DATA_LICENSES.md — źródła danych i licencje.
- prompts/ai_exposure_llm_prompt.md — prompt LLM v1.0 (SHA-256 zapisywany przy każdym wywołaniu Claude).

Ziarno losowe. Bootstrap w Zad. 1 używa `numpy.random.default_rng(seed=42)` i $B = 10\,000$ powtórzeń. Pozostałe analizy są deterministyczne.

Reprodukcja end-to-end. Pełna analiza jest opakowana w Makefile, który jawnie określa kolejność wykonania skryptów (sekcja powyżej). Po sklonowaniu repozytorium i ustawieniu ANTHROPIC_API_KEY można uruchomić poszczególne etapy przez `make data`, `make sec`, `make nlp`, `make analysis`, `make robustness`, `make factors`, `make report`. Wariant bez ponownego wywoływania LLM (deterministic-only fallback, `ai_exposure_llm = NaN`):

```
python src/llm_classifier.py --no-llm
```

Recenzent bez API key może odtworzyć wyniki LLM z committowanego `data_cache/llm_raw_responses.jsonl` (zawiera parsed scores z metadanymi reprodukcyjnymi).

Kompilacja PDF. Raport zakłada strukturę repozytorium z folderem `figures/` jeden poziom wyżej względem `report/`. Kompilacja:

```
cd report
latexmk -pdf raport.tex
```

Pinned dependencies. Plik `requirements-lock.txt` (`pip freeze`) zawiera dokładne wersje wszystkich pakietów użytych w czasie kompilacji raportu — zwiększa szansę odtworzenia wyników w możliwie zbliżonym środowisku. Pełna bit-exact reprodukcja zależy dodatkowo od systemu operacyjnego, wersji BLAS/NumPy, dystrybucji LaTeX oraz stabilności zewnętrznych API (yfinance, SEC EDGAR, Anthropic).

Repozytorium. github.com/Smalou/metody_badania_w_finansach — pełny kod, dane cache, prompty LLM, dokumenty metodologiczne (pre-registration, decision log, data licenses) i źródło LaTeX dostępne publicznie. Licencje: LICENSE-CODE (MIT) dla kodu, LICENSE-DOCS (CC BY 4.0) dla raportu i dokumentacji.


11 Limitations

- **Selection bias / próby celowe.** Wszystkie cztery grupy spółek dobrane są ręcznie na bazie eksperckiej oceny ekspozycji na AI — nie są losowymi próbami z populacji. Wnioski dotyczą tej konkretnej próby.
- **Look-ahead bias.** Skład grup, szczególnie AI infrastructure i grupa eventowa w Zadaniu 3, powstał z perspektywy 2026 roku. Oznacza to ryzyko, że do analizy trafiły spółki rozpoznane ex post jako zwycięzcy boomu AI.

- **Niejednorodność wewnątrzgrupowa.** Grupy Broad tech i Defensive zawierają spółki o zróżnicowanych modelach biznesowych, co zwiększa wewnętrzną wariancję metryk.
- **Założenie $\beta = 1$ w Zad. 1 i 3.** Zwroty względne liczone są jako prosty spread względem SPY. To jest równoważne założeniu, że beta portfela względem rynku wynosi 1. W danych beta AI infrastructure jest dużo wyższa niż beta Defensive, więc część wyniku może być premią za ryzyko systematyczne.
- **Single-factor benchmark w Zad. 1 i 3.** Podstawowe spread-based testy w Zadaniach 1 i 3 używają prostego benchmarku SPY i nie kontrolują czynników Fama-French ani momentum. Modele czynnikowe dodane w sekcji 8 ograniczają ten problem na poziomie portfeli EW (CAPM/FF3/Carhart 4 z HAC SE), ale nie usuwają go całkowicie z pierwotnych testów opisowych ani z cross-sectional regression spółek w sekcji 6.
- **Istotny test placebo.** Placebo 30.11.2021 daje istotne wyniki, co wskazuje, że prosta metoda przed-po nie usuwa trendów rynkowych. To osłabia interpretację przyczynową Zadania 3.
- **Małe próby w Zad. 2.** Grupy mają tylko 10–11 obserwacji. Testy normalności mają niską moc, dlatego wyniki ANOVA uzupełniono kontrolą nieparametryczną Kruskal-Wallis + Dunn.
- **Definicja zdarzenia.** Premiera ChatGPT (30.11.2022) jest symbolicznym punktem startu boomu AI, ale realna fala kapitałowa następowała stopniowo przez kolejne 6–12 miesięcy. Stąd wrażliwość wyników Zad. 3 na długość okna.
- **Częściowy ostatni miesiąc.** W Zad. 1 maj 2026 jest miesiącem częściowym. Nie zmienia to głównej logiki testu, ale w wersji produkcyjnej warto dodać wariant z wykluczeniem niepełnego miesiąca.
- **Dane yfinance.** Ceny są korygowane wstecznie (split, dywidenda); dostawca może okresowo modyfikować historyczne wartości. Cache lokalny zapewnia reprodukowalność tej analizy, ale ponowne pobranie może dać minimalnie inne wyniki.
- **Spojrzenie ex-post.** Cały kierunek hipotezy („AI Premium”) jest motywowany obserwacjami z lat 2023–2025. Test jest konfirmacyjny, nie predykcyjny.
- **Disclosure $\neq$ operational exposure.** Raporty 10-K mierzą *ujawnioną* ekspozycję, a nie faktyczną skalę wdrożenia AI, przychody z AI ani zależność operacyjną od AI. Spółka może raportować AI w narracji marketingowej bez istotnego biznesu AI, i odwrotnie.
- **Dictionary measurement risk.** Wyniki AI Exposure Score zależą od doboru słownika (main/extended), normalizacji (mentions per 10k words), długości dokumentów (10-K vs 20-F) i stylu raportowania firm. Wariant `no_automation` dał podobne wyniki, ale inne słowniki mogłyby zmienić obraz.
- **LLM classification risk.** Walidacja LLM zależy od prompta (wersjonowanego w `prompts/ai_exposure_llm_prompt.md`, SHA-256 logowany), wyboru excerptów ($\pm$ kontekst zdań), wersji modelu (logowana w `llm_raw_responses.jsonl`) i braku klasyfikacji dla 7 spółek bez fraz słownikowych. Wariant `missing0` jest słabszy ($\hat{\beta}_1 = +0,18$ vs $+0,38$): samo-selekcja jest materialna, a wariant `missing0` sugeruje jednak, że sygnał LLM nie znika całkowicie po uwzględnieniu brakujących klasyfikacji.
- **Small cross-section.** Cross-sectional regression opiera się na 41 spółkach, więc wyniki są wrażliwe na obserwacje wpływowe (leave-one-out: 7/41 sign changes) i nie powinny być interpretowane jako precyzyjny estimator populacyjny. Przy małej próbie moc testu może być ograniczona, więc brak istotności $\neq$ brak efektu.


12 Dodatek — wykresy uzupełniające

Heatmapa korelacji dziennych log-zwrotów.



Wizualnie widoczne są bloki wysokiej korelacji wewnątrz grup AI (infra, platforms) oraz niska korelacja grupy Defensive z technologiami.

Rolling annualized volatility (okno 63 sesji).



AI infrastructure utrzymuje najwyższy poziom zmienności w całym okresie, ze szczytami wokół wybuchu AI capex 2023 i fazy korekt 2024–2025.

13 Bibliografia

1. Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442.
2. Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
3. Carhart, M. M. (1997). On persistence in mutual fund performance. *The Journal of Finance*, 52(1), 57–82.
4. Sharpe, W. F. (1994). The Sharpe Ratio. *The Journal of Portfolio Management*, 21(1), 49–58.
5. Sortino, F. A., & Price, L. N. (1994). Performance measurement in a downside risk framework. *Journal of Investing*, 3(3), 59–64.
6. MacKinlay, A. C. (1997). Event Studies in Economics and Finance. *Journal of Economic Literature*, 35(1), 13–39.
7. Brown, S. J., & Warner, J. B. (1985). Using daily stock returns: The case of event studies. *Journal of Financial Economics*, 14(1), 3–31.
8. Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35.
9. White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4), 817–838.
10. Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
11. Games, P. A., & Howell, J. F. (1976). Pairwise multiple comparison procedures with unequal N ’s and/or variances. *Journal of Educational Statistics*, 1(2), 113–125.
12. Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed., Lawrence Erlbaum Associates.
13. Hedges, L. V. (1981). Distribution theory for Glass’s estimator of effect size and related estimators. *Journal of Educational Statistics*, 6(2), 107–128.
14. Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65.
15. Hoberg, G., & Phillips, G. (2016). Text-based network industries and endogenous product differentiation. *Journal of Political Economy*, 124(5), 1423–1465.
16. Tetlock, P. C. (2007). Giving content to investor sentiment: The role of media in the stock market. *The Journal of Finance*, 62(3), 1139–1168.
17. García, D. (2013). Sentiment during recessions. *The Journal of Finance*, 68(3), 1267–1300.
18. Babina, T., Fedyk, A., He, A., & Hodson, J. (2024). Artificial intelligence, firm growth, and product innovation. *Journal of Financial Economics*, 151, 103745.
19. Eisfeldt, A. L., Schubert, G., & Zhang, M. B. (2023). Generative AI and firm values. *NBER Working Paper*, 31222.
20. Christensen, G., & Miguel, E. (2018). Transparency, reproducibility, and the credibility of economics research. *Journal of Economic Literature*, 56(3), 920–980.
21. OpenAI (2022). *Introducing ChatGPT*, <https://openai.com/index/chatgpt/>.

22. Yahoo Finance / yfinance — dokumentacja API, <https://github.com/ranaroussi/yfinance>.
23. Kenneth R. French Data Library — Tuck School of Business at Dartmouth, https://mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.
24. U.S. Securities and Exchange Commission — EDGAR system, <https://www.sec.gov/edgar>.

Format BibTeX. Pełna lista referencji w formacie BibTeX (biblatex z backend biber) jest dostępna w pliku `report/refs.bib` w repozytorium, gotowa do migracji raportu na `\parencite/\textcite`.